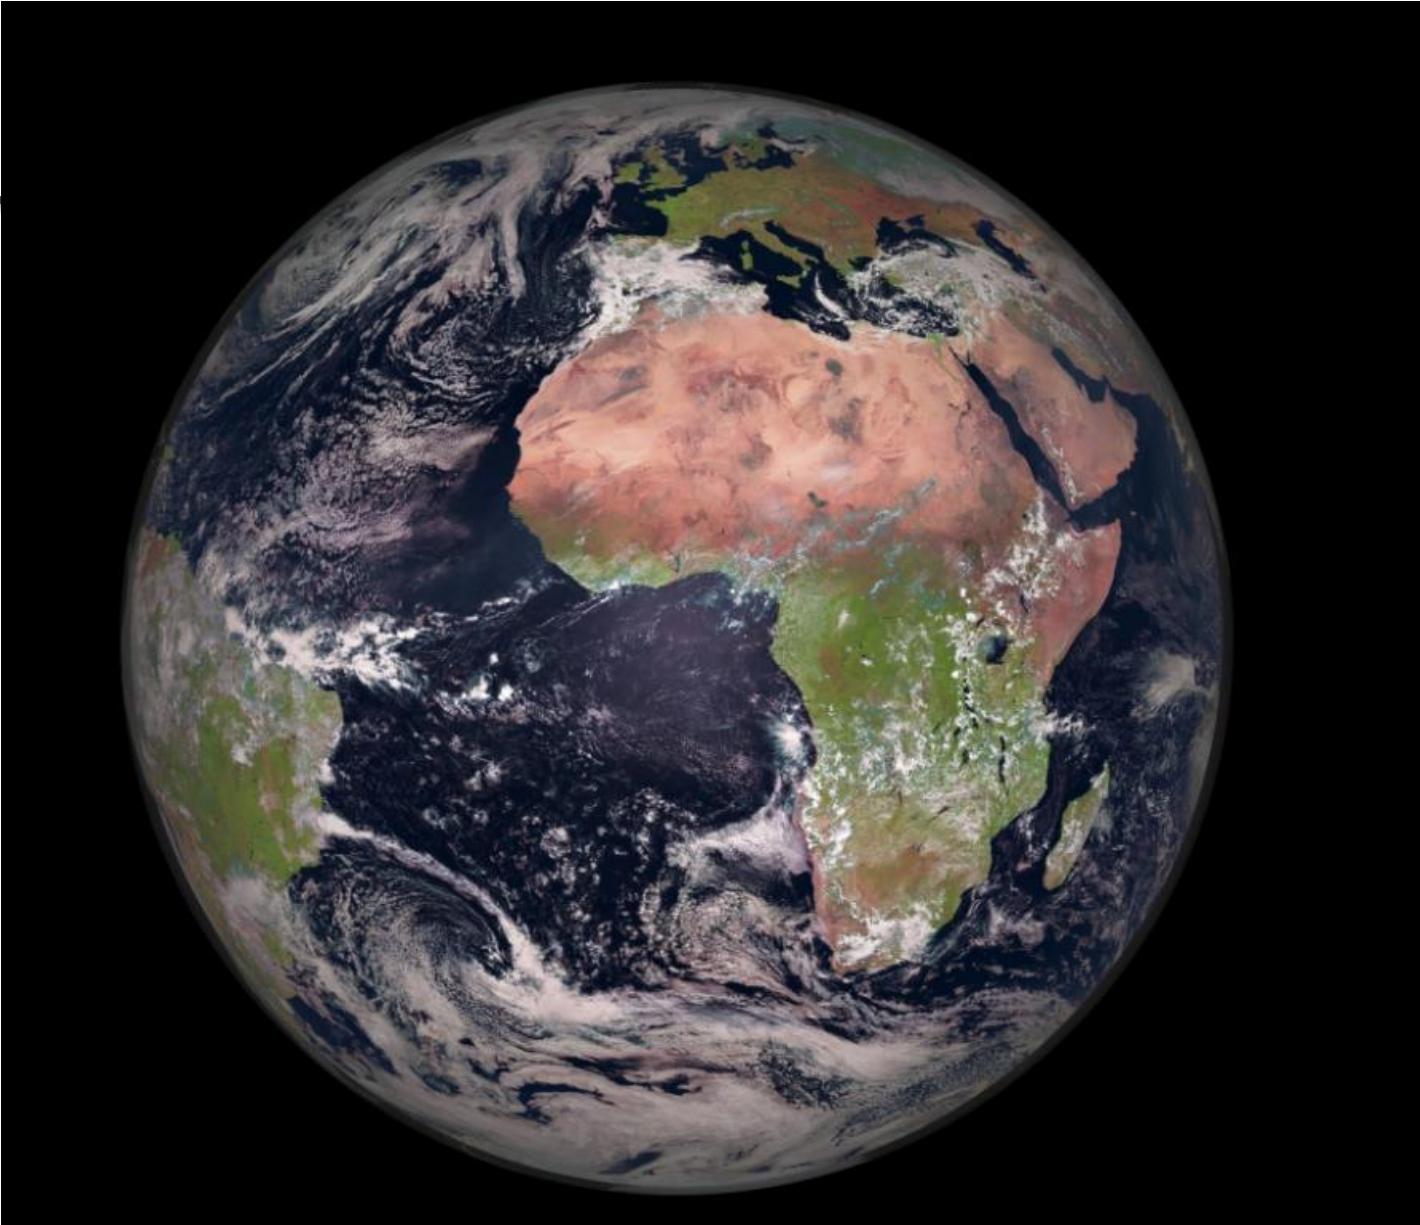


PRINCIPIOS E APLICAÇÕES DA DETECÇÃO REMOTA





https://www.esa.int/About_Us/Week_in_images/Week_in_images_18-22_April_2022



[Major Earth Satellite to Track Disasters, Effects of Climate Change \(nasa.gov\)](#)



This animation shows how the NISAR spacecraft will deploy its radar reflector antenna after launch. Nearly 40 feet (12 meters) in diameter, the reflector will sit at the end of a 30-foot-long (9-meter-long) boom, sending and receiving radar signals to and from Earth's surface. Credit: NASA/JPL-Caltech



An All-Weather Satellite

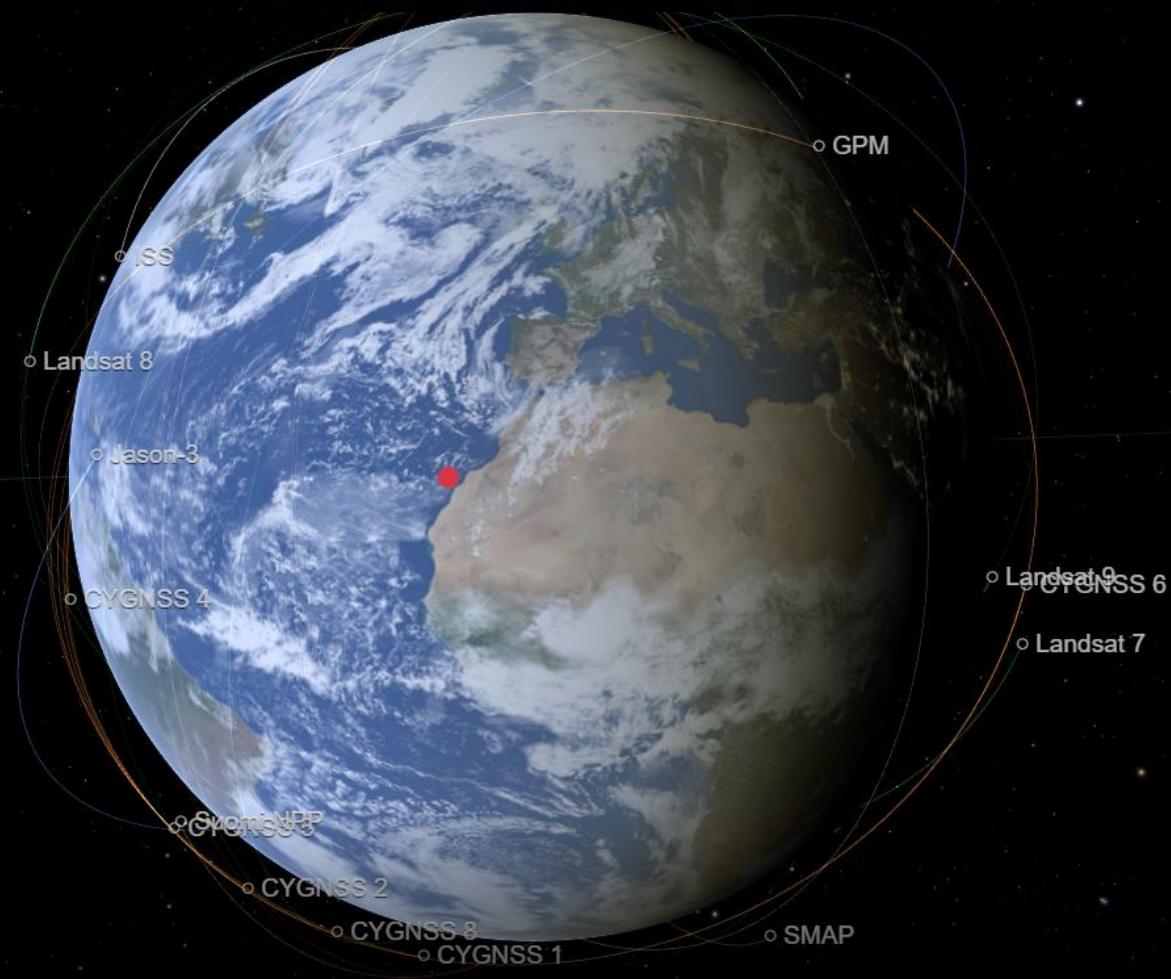
On March 19, NISAR's assembly, test, and launch team at JPL received a key piece of equipment – the S-band SAR – from its partner in India. Together with the L-band SAR provided by JPL, the two radars serve as the beating heart of the mission. The “S” and “L” denote the wavelength of their signal, with “S” at about 4 inches (10 centimeters) and “L” around 10 inches (25 centimeters). Both can see through objects like clouds and the leaves of a forest canopy that obstruct other types of instruments, although L-band SAR can penetrate further into dense vegetation than S-band. This ability will enable the mission to track changes in Earth’s surface day or night, rain or shine.

“NISAR is an all-weather satellite that’s going to give us an unprecedented ability to look at how Earth’s surface is changing,” said Paul Rosen, NISAR project scientist at JPL. “It’ll be especially important for scientists who have been waiting for this kind of measurement reliability and consistency to really understand what drives Earth’s natural systems – and for people who deal with natural hazards and disasters like volcanoes or landslides.”

Both radars work by bouncing microwave signals off of the planet’s surface and recording how long the signals take to return to the satellite as well as their strength when they return. The larger the antenna sending and receiving the signals, the higher the spatial resolution of the data. If researchers wanted to see something about 150 feet (45 meters) across with a satellite in low-Earth orbit operating an L-band radar, they’d need an antenna nearly 14,000 feet (4,250 meters) long – the equivalent of about 10 Empire State Buildings stacked on top of each other. Sending something that size into space just isn’t feasible.



LATEST EVENT: Dust Blows From Western Sahara >



Satellites Now ^

Satellites Now Visible Earth Air Temperature Carbon Dioxide Carbon Monoxide Sea Level Soil Moisture Ozone Water Vapor Gravity Field

Apr 2
05:29

Eyes on the Earth (nasa.gov)

Capítulo 4 – Classificação de Imagem

- Índices (empíricos) de Vegetação
- Classificação de Imagem
 - Unsupervised (K-Means, ISODATA)
 - Supervised
 - Classificação de Máxima Verosimilhança
 - Classificador Distância mínima
 - Classificador Paralelepípedo
 - Classificador Mahalanobis
- Avaliação da precisão da classificação

Radiative Transfer Model

Os dados de Deteção Remota devem ser corrigidos dos efeitos atmosféricos e solares se o objetivo for a comparação com curvas de reflectância espectral medidas no terreno.

$$L_\lambda^s(x, y) = \rho(x, y, \lambda) \frac{\tau_v(\lambda)}{\pi} \{ \tau_s(\lambda) E_\lambda^0 \cos(\theta(x, y)) + F(x, y) \cdot E_\lambda^d \} + L_\lambda^{sp}(x, y)$$

São necessárias correções atmosféricas relativas, se as assinaturas espectrais de uma imagem numa data são para comparar com imagens adquiridas numa outra data, i.e se o objetivo é um estudo multi-temporal.

Radiative Transfer Model

Os métodos de correção atmosférica das imagens dividem-se em dois grupos baseado no facto de haver ou não dados sobre as condições atmosféricas no momento da aquisição da imagem.

Como já vimos no capítulo anterior, não havendo observações meteorológicas, é calculada a reflectância espectral da superfície terrestre ao nível do topo da atmosfera:

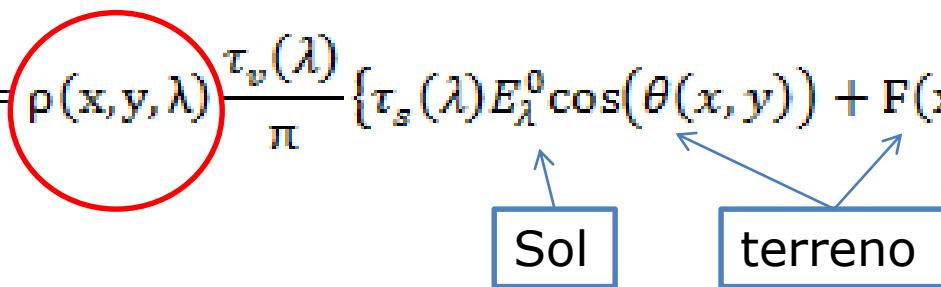
$$\rho_\lambda = \frac{\pi \cdot L_\lambda \cdot d^2}{E_{SUN_\lambda} \cos \theta_s}$$

Refletância Topo
da atmosfera

Equação simplificada da equação anterior.

Solar radiance at sensor

Como podemos usar a Deteção Remota para reconhecer diferentes ocupações do solo?

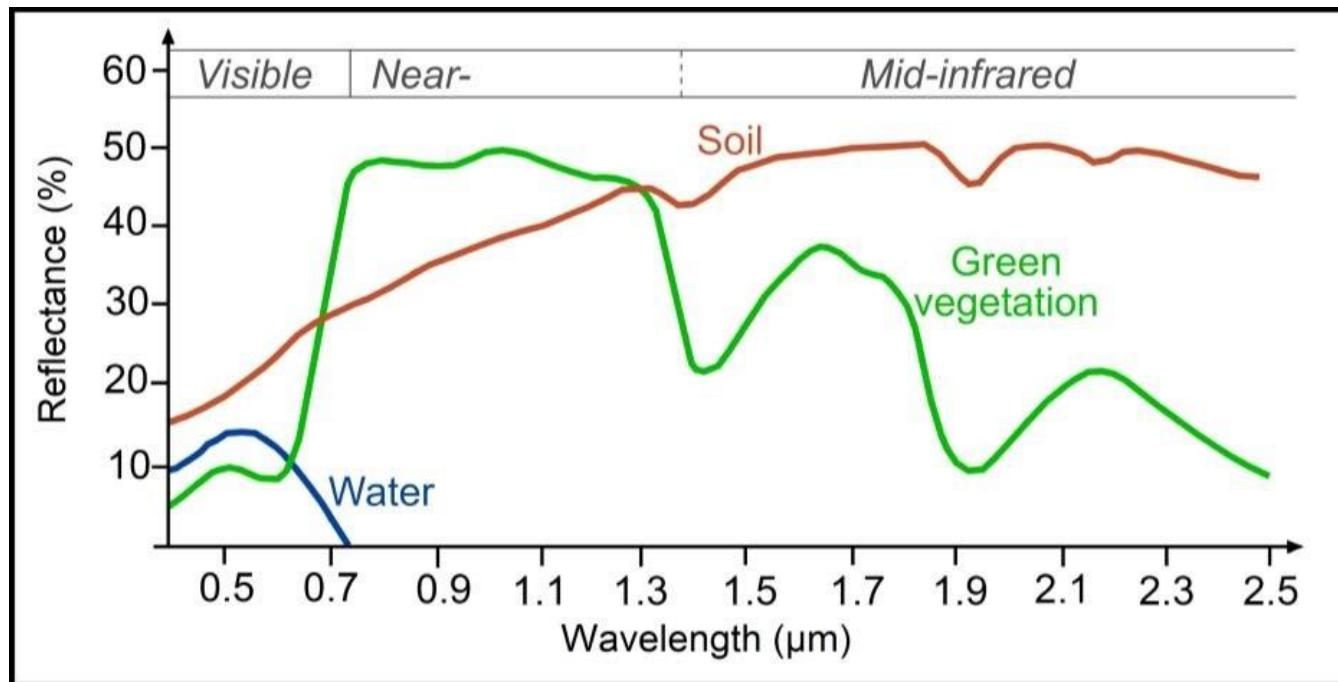
$$L_\lambda^s(x, y) = \rho(x, y, \lambda) \frac{\tau_v(\lambda)}{\pi} \{ \tau_s(\lambda) E_\lambda^0 \cos(\theta(x, y)) + F(x, y) \cdot E_\lambda^d \} + L_\lambda^{sp}(x, y)$$


(Radiative transfer model, RTM)

Esta equação tem solução em ordem à reflectância do píxel (ρ) se cada objecto na superfície tiver uma única assinatura espectral e distinta de todos os outros objectos.

Spectral Signature

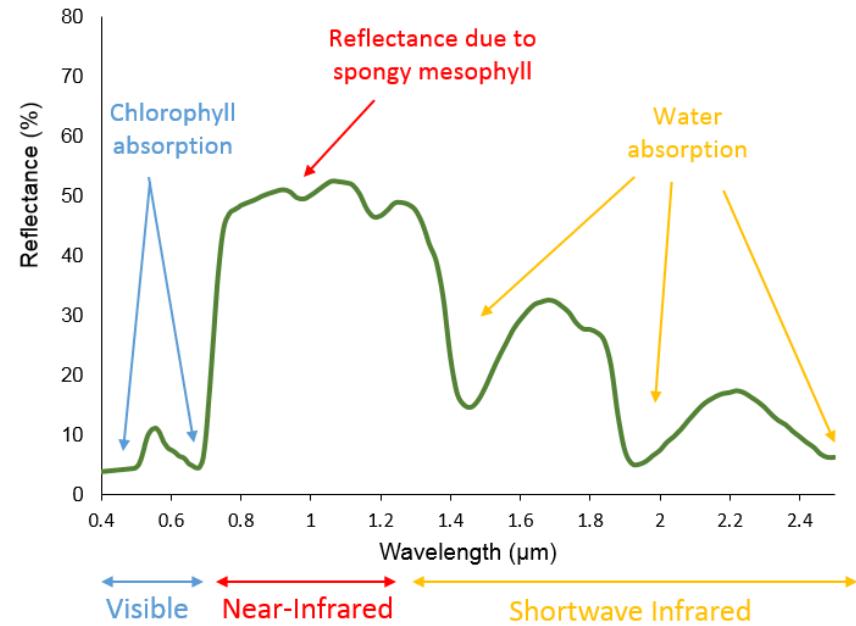
These differences in reflectance make it possible to identify different earth surface features or materials by analysing their spectral reflectance signatures. **Spectral reflectance curves** graph the spectral reflectance of objects as a function of wavelengths.



Spectral Signature

Red lights absorption start to decline at the edge of the visible range and infrared wave reflectance increases sharply.

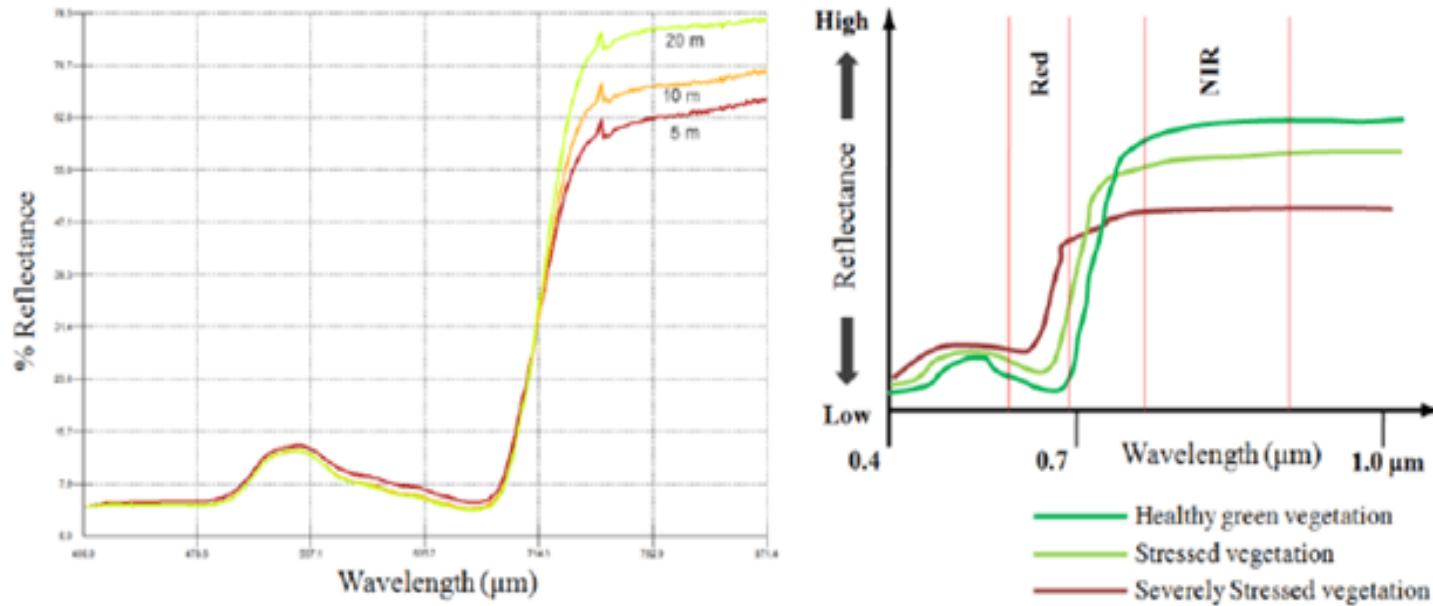
If reflectance is to be measured in both visible and infrared region then the curve will be very high in infrared region compared to visible range in a **healthy vegetation** leaf.



This infrared behaviour helps researchers to study the vegetation; also help to differentiate between **vegetation** and **non-vegetation**.

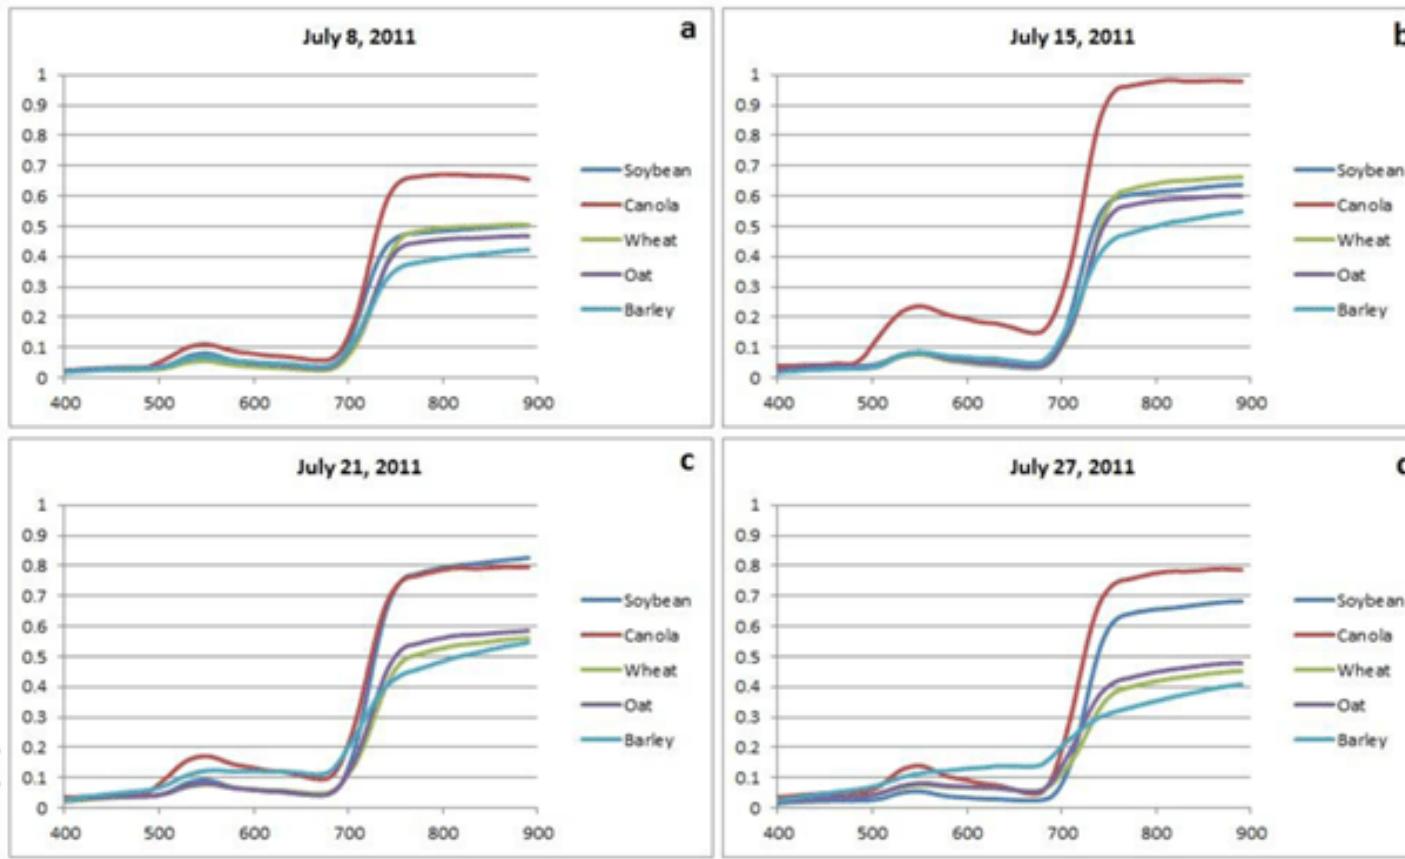
Spectral Signature

Infrared reflectance also helps to differentiate vegetation classes and different reflectance value for **different vegetation**. If plants **matured or under stress** they behave differently in infrared or in visible range. But this type characteristic is more recognizable in the infrared region.



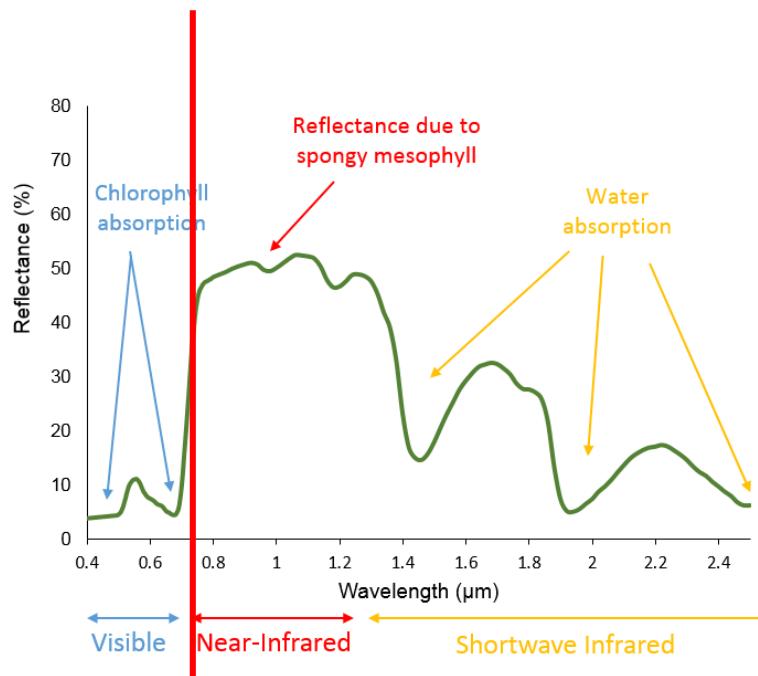
Spectral Signature

Spectral signatures for **different crops** organized by number of days after planting.



Vegetation Index

Baseiam-se no facto que a vegetação “verde” interage de forma característica com a radiação eletromagnética.



Os índices de vegetação relacionam a refletância na zona do infravermelho e na zona do visível.

Vegetation Index

Índice razão.

$$I_1 = \frac{BLand_{red}}{BLand_{NIR}} = \frac{\text{vermelho}}{\text{infravermelho} \quad \text{próximo}}$$

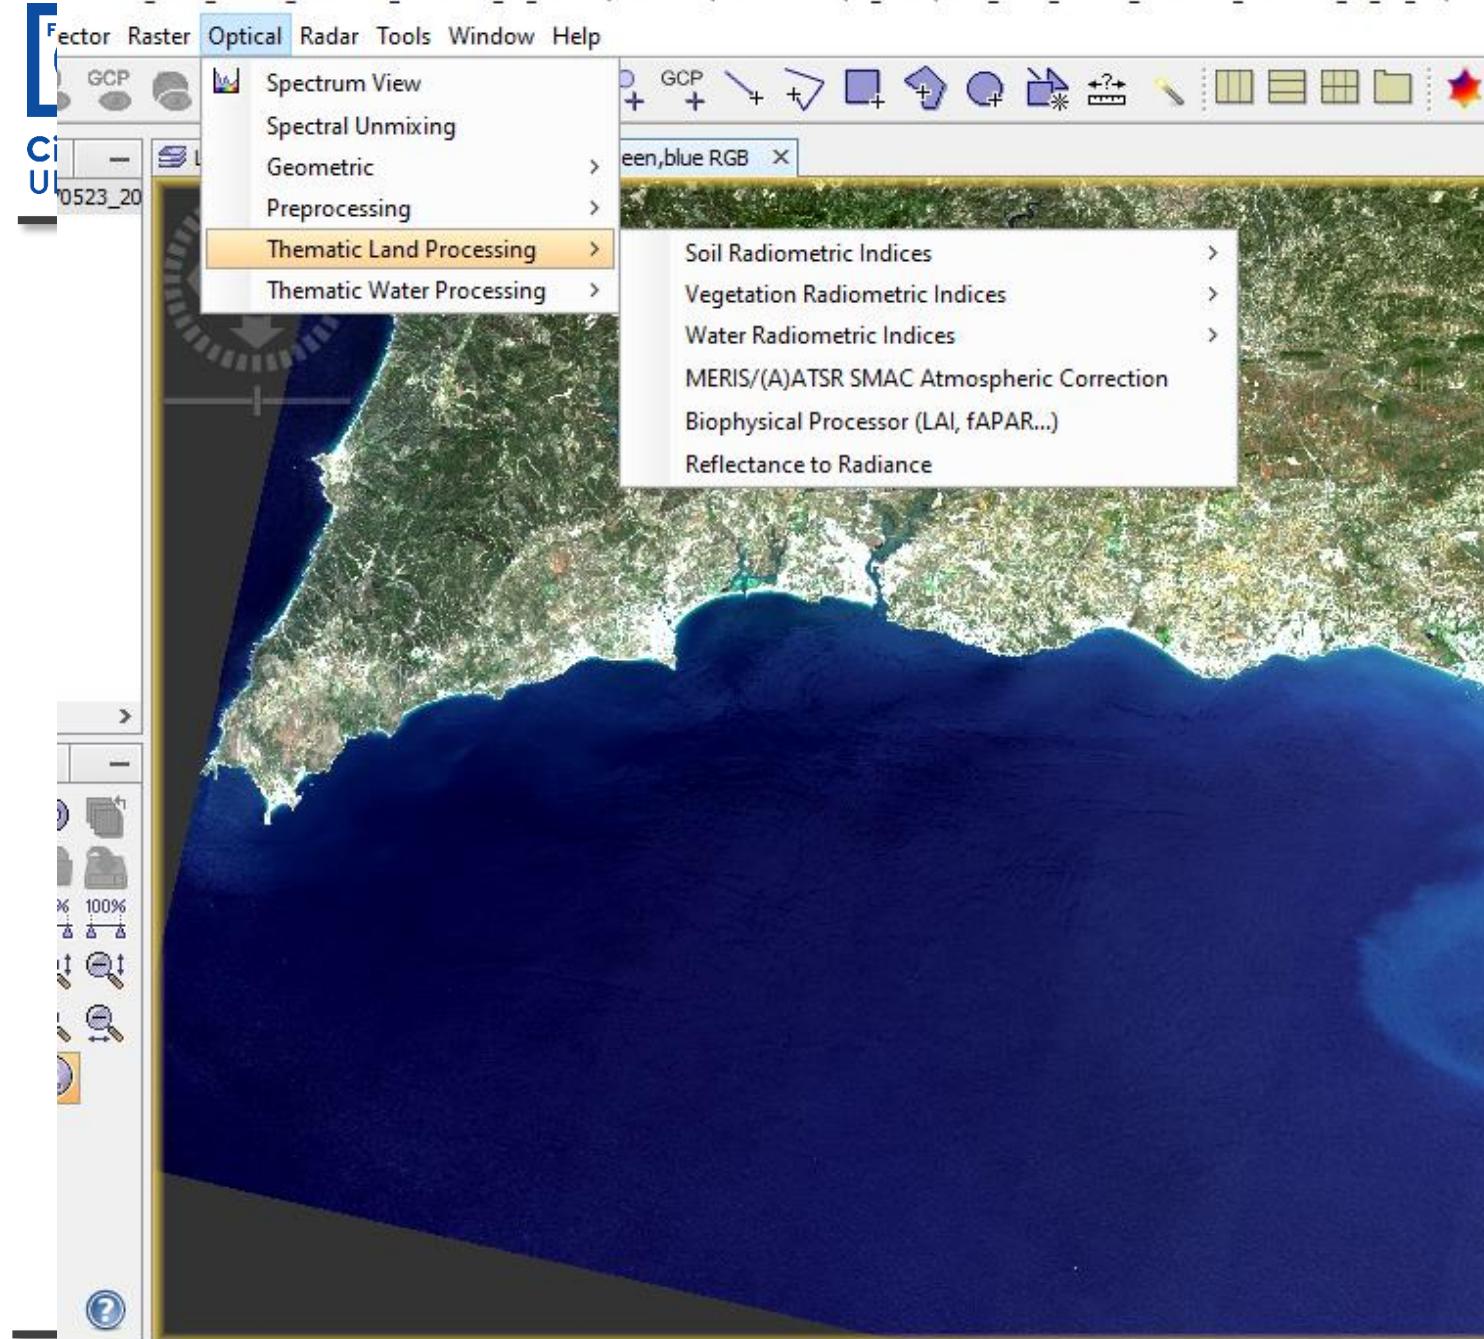
Índice de vegetação normalizado NDVI

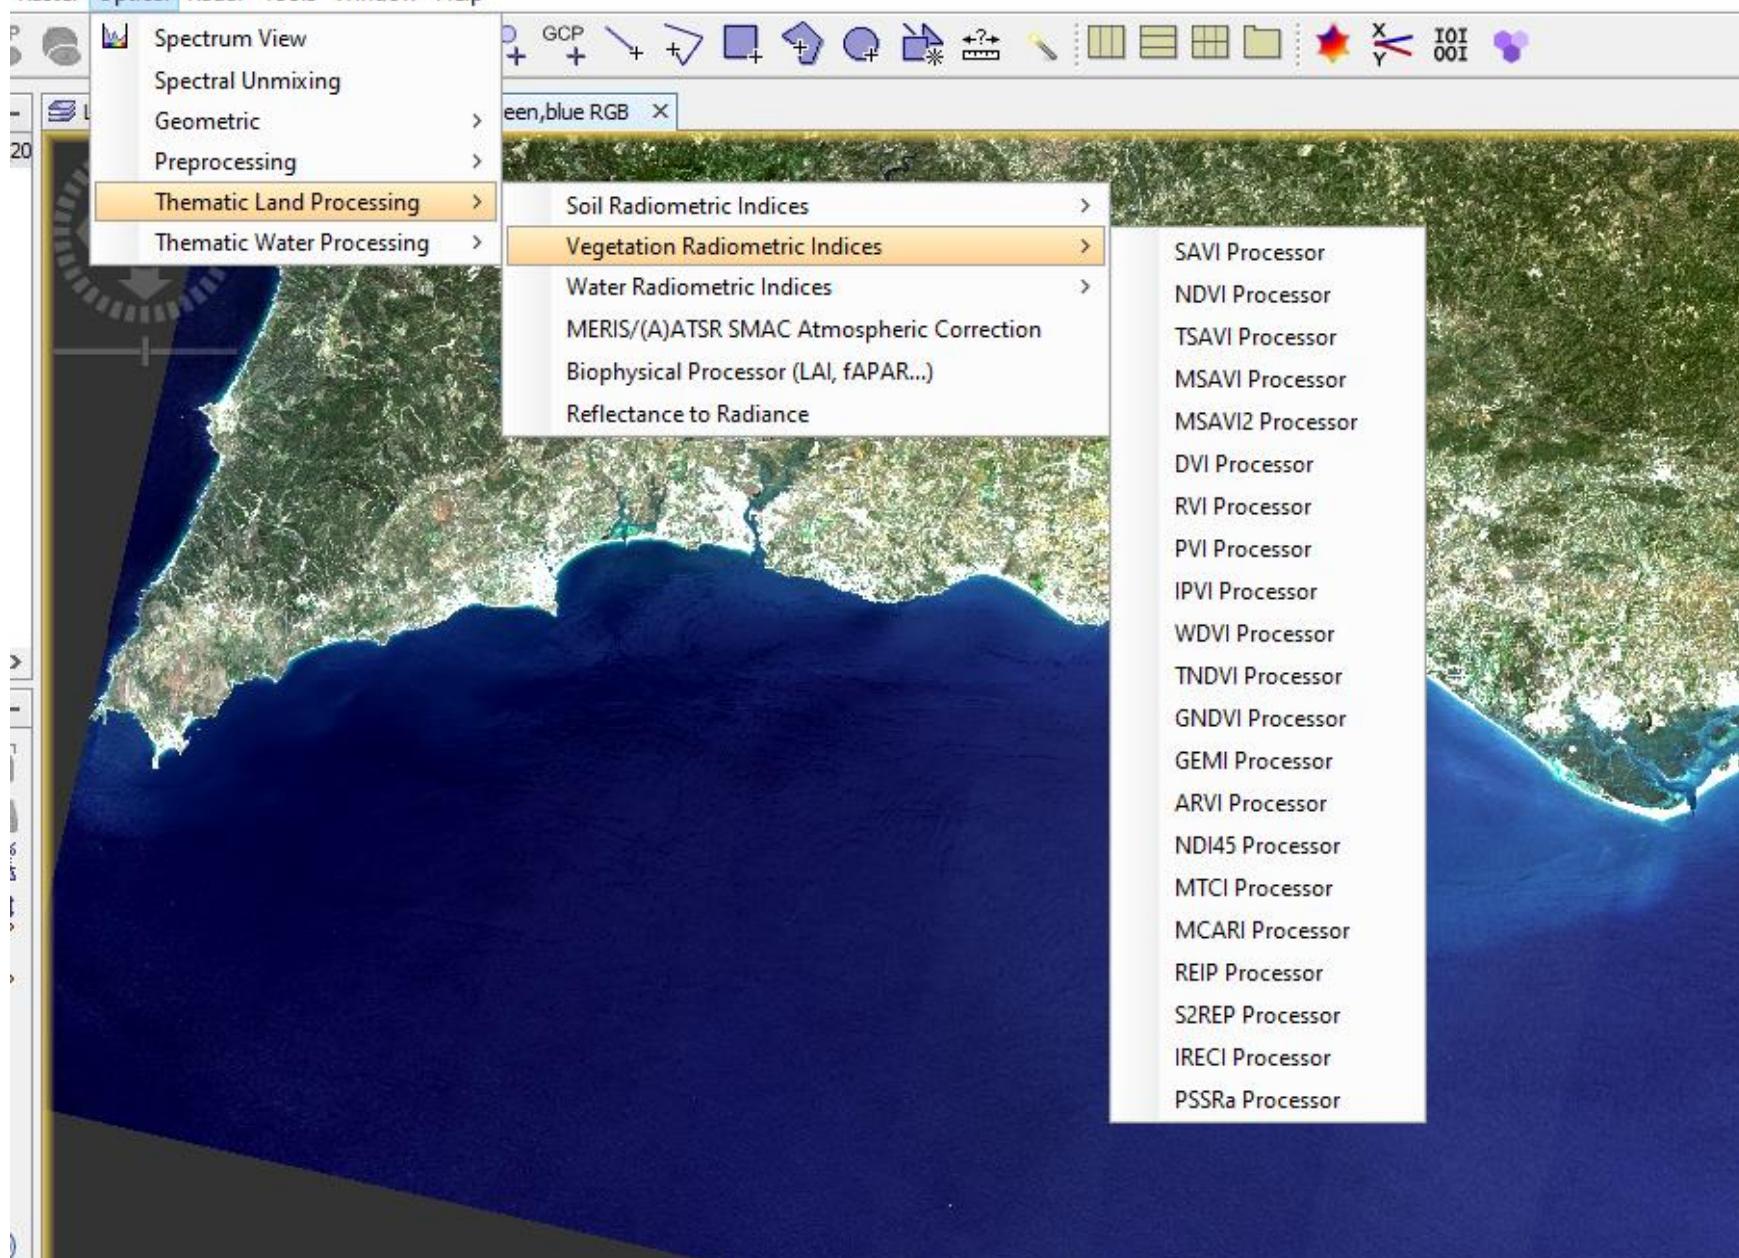
Normalized Difference Vegetation Index

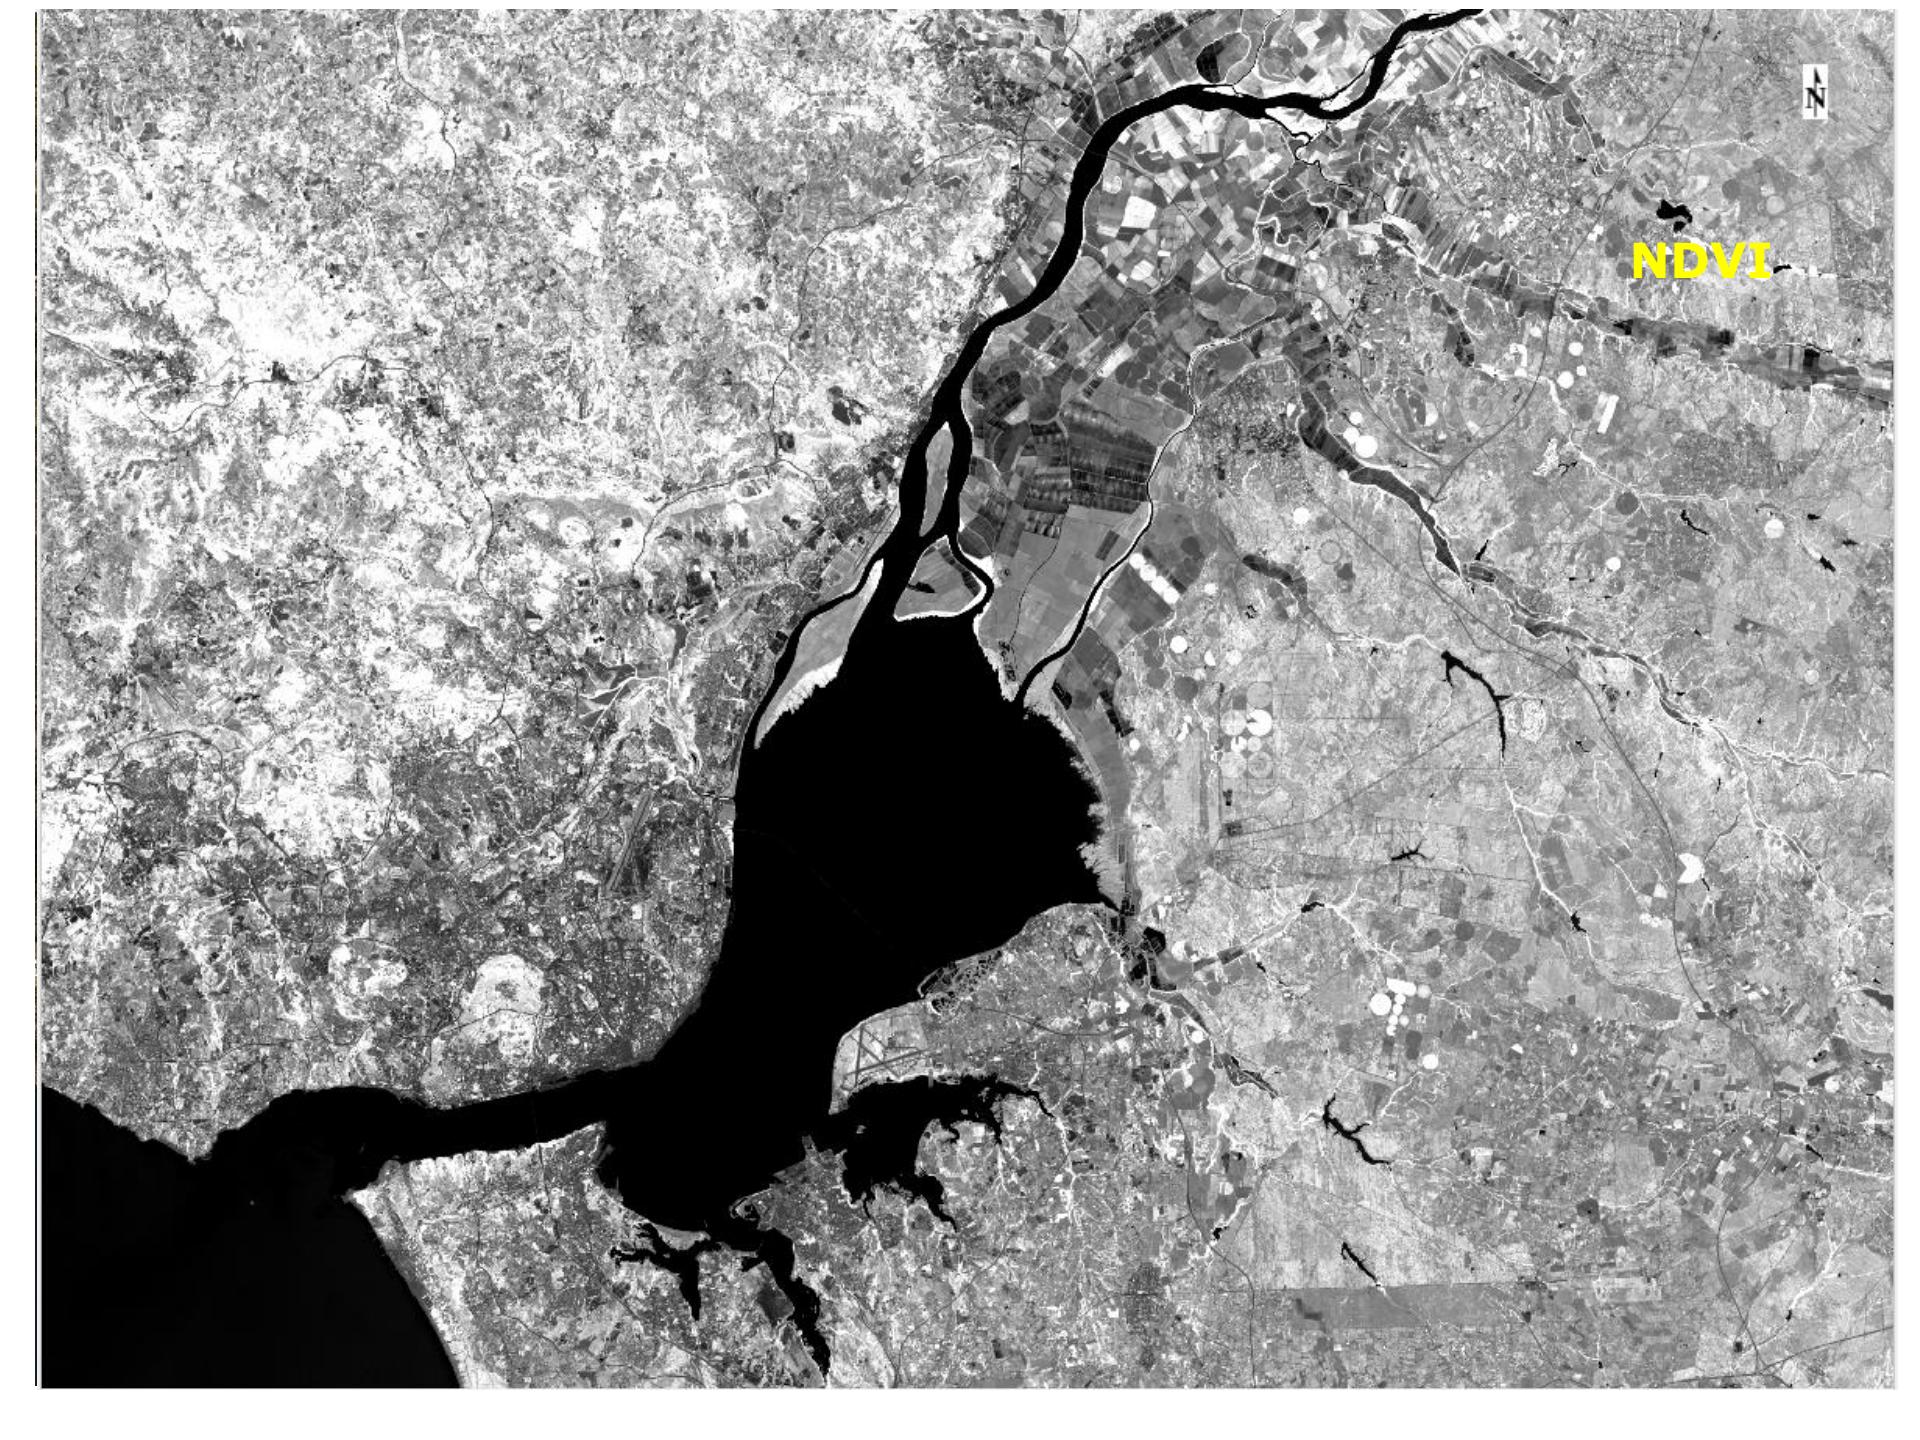
$$\text{NDVI} = \frac{\text{InfraRED} - \text{red}}{\text{InfraRed} + \text{Red}}$$

Sempre entre -1 e +1. Valores típicos para a vegetação são superiores a 0.3.

Valores superiores a 0.5 indicam a presença de vegetação no pleno do seu estado vegetativo.

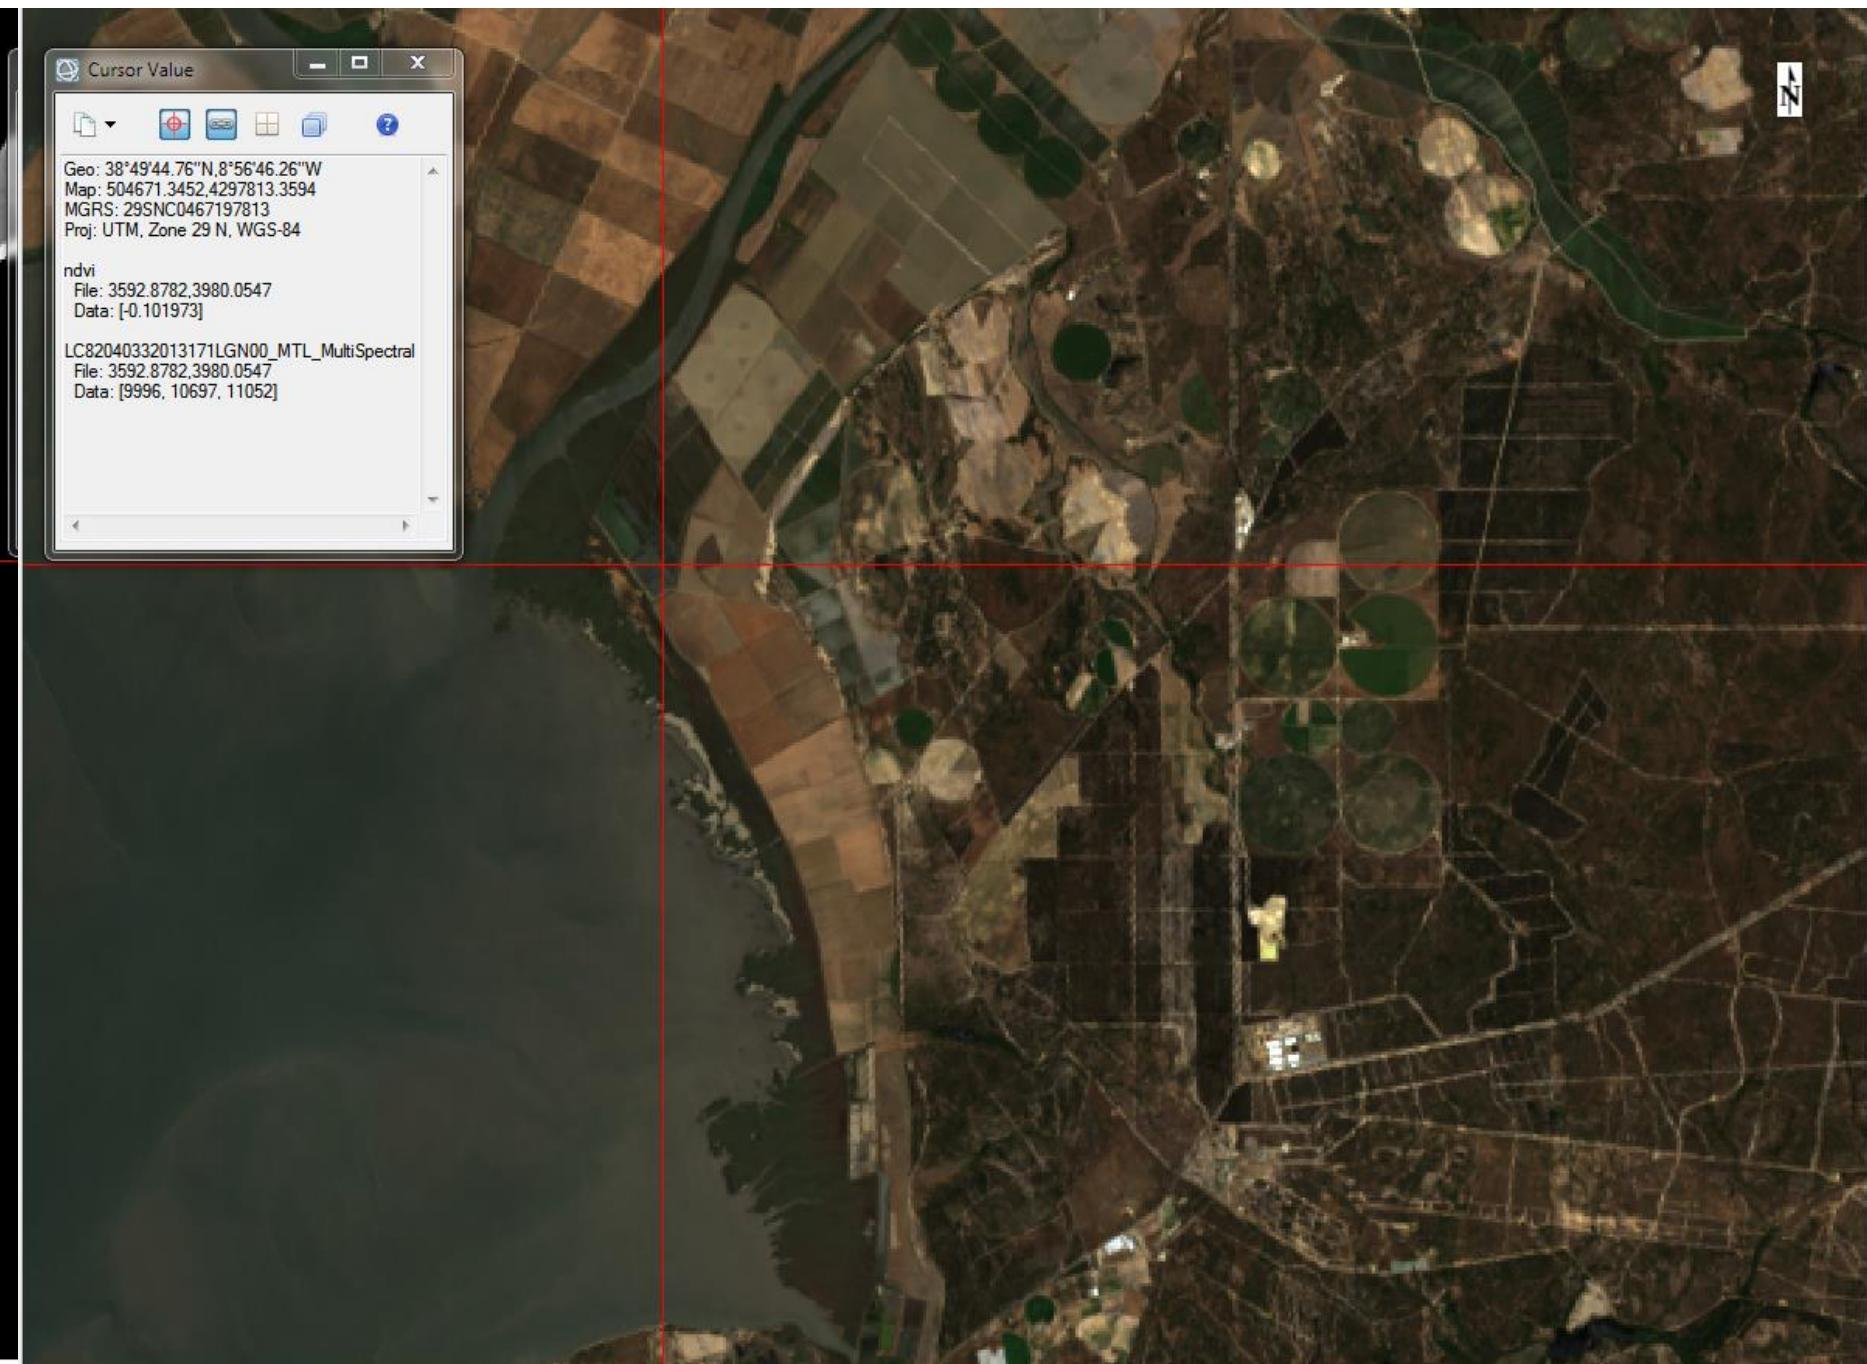


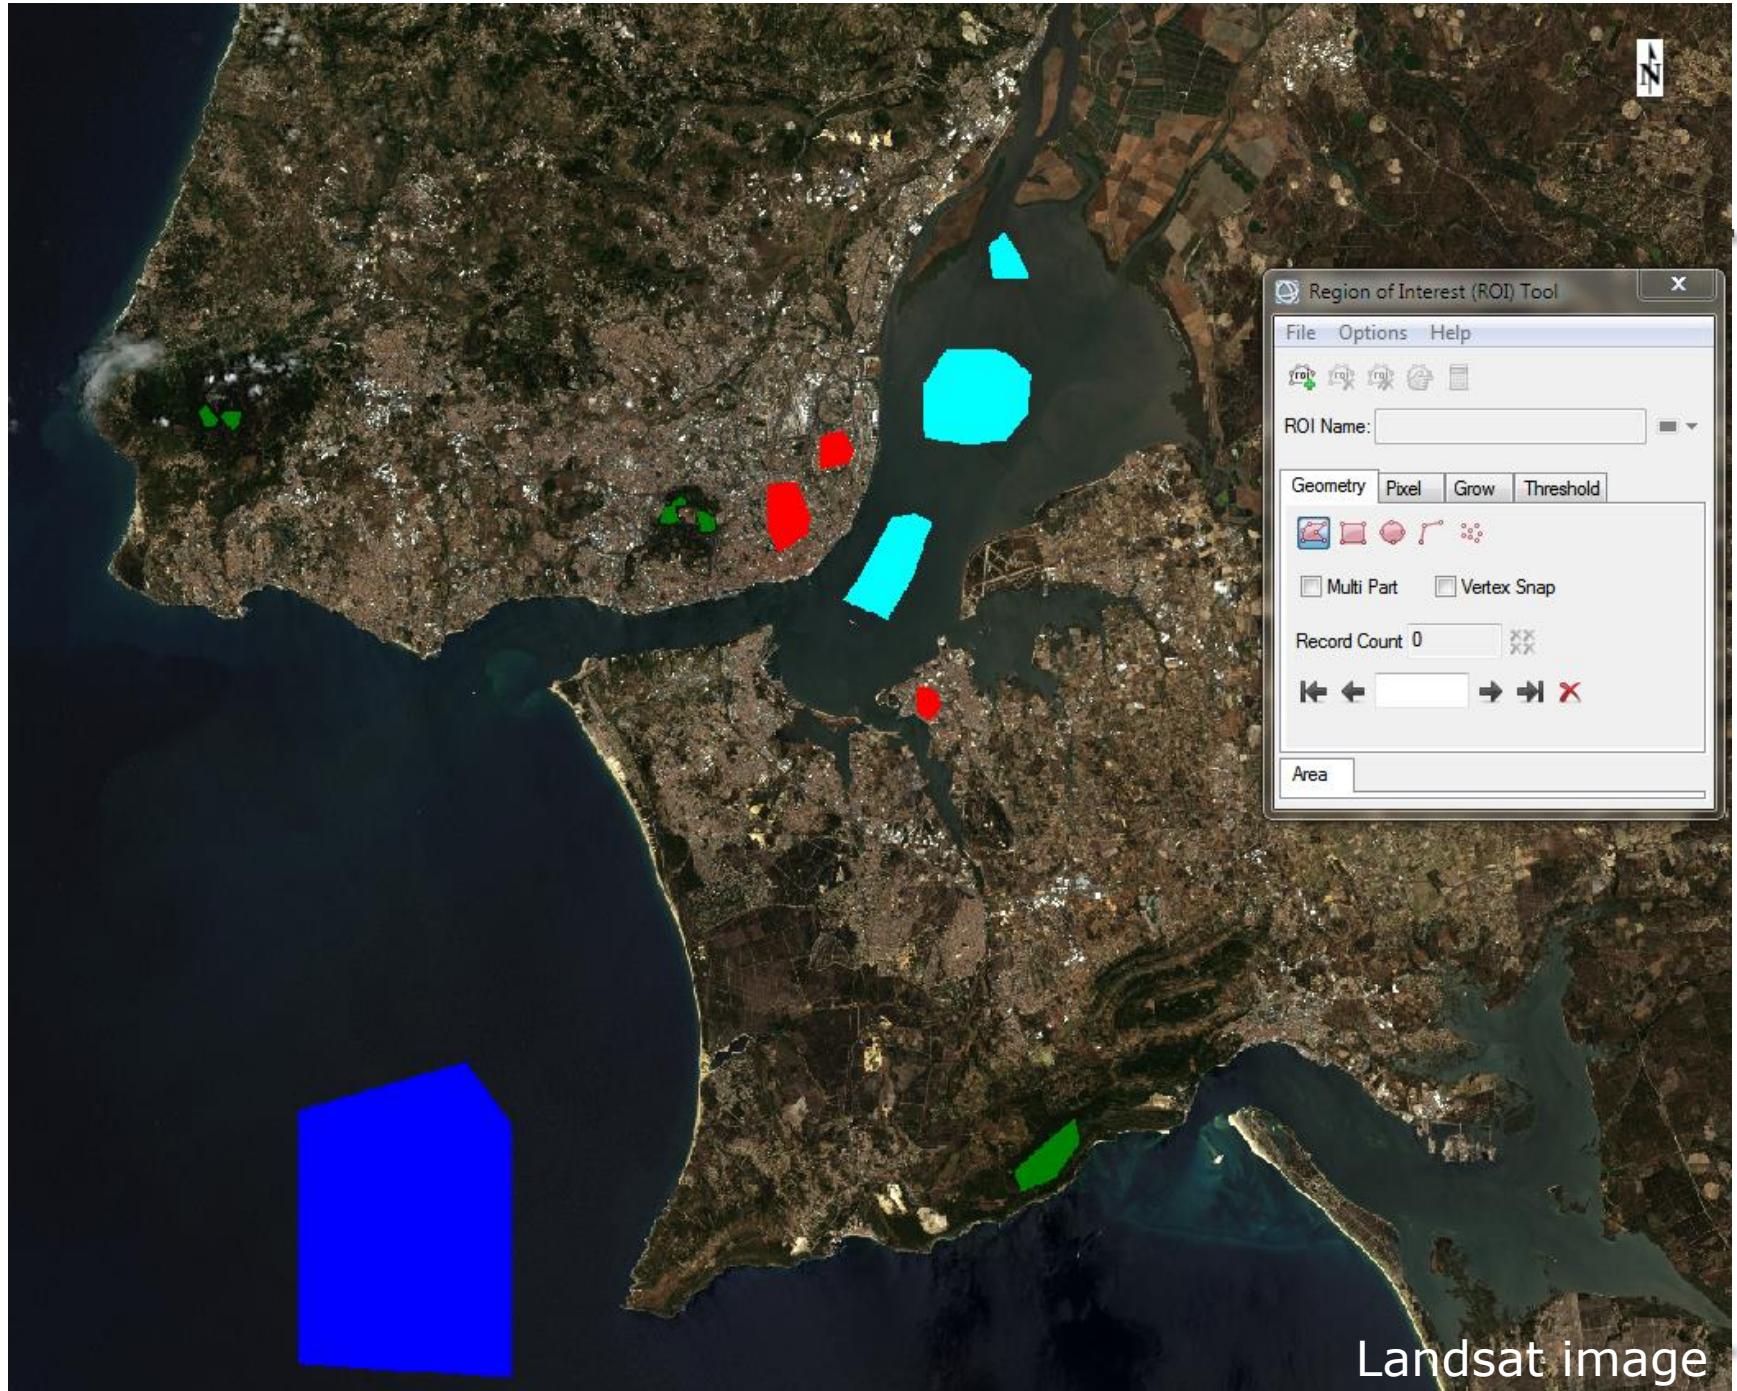




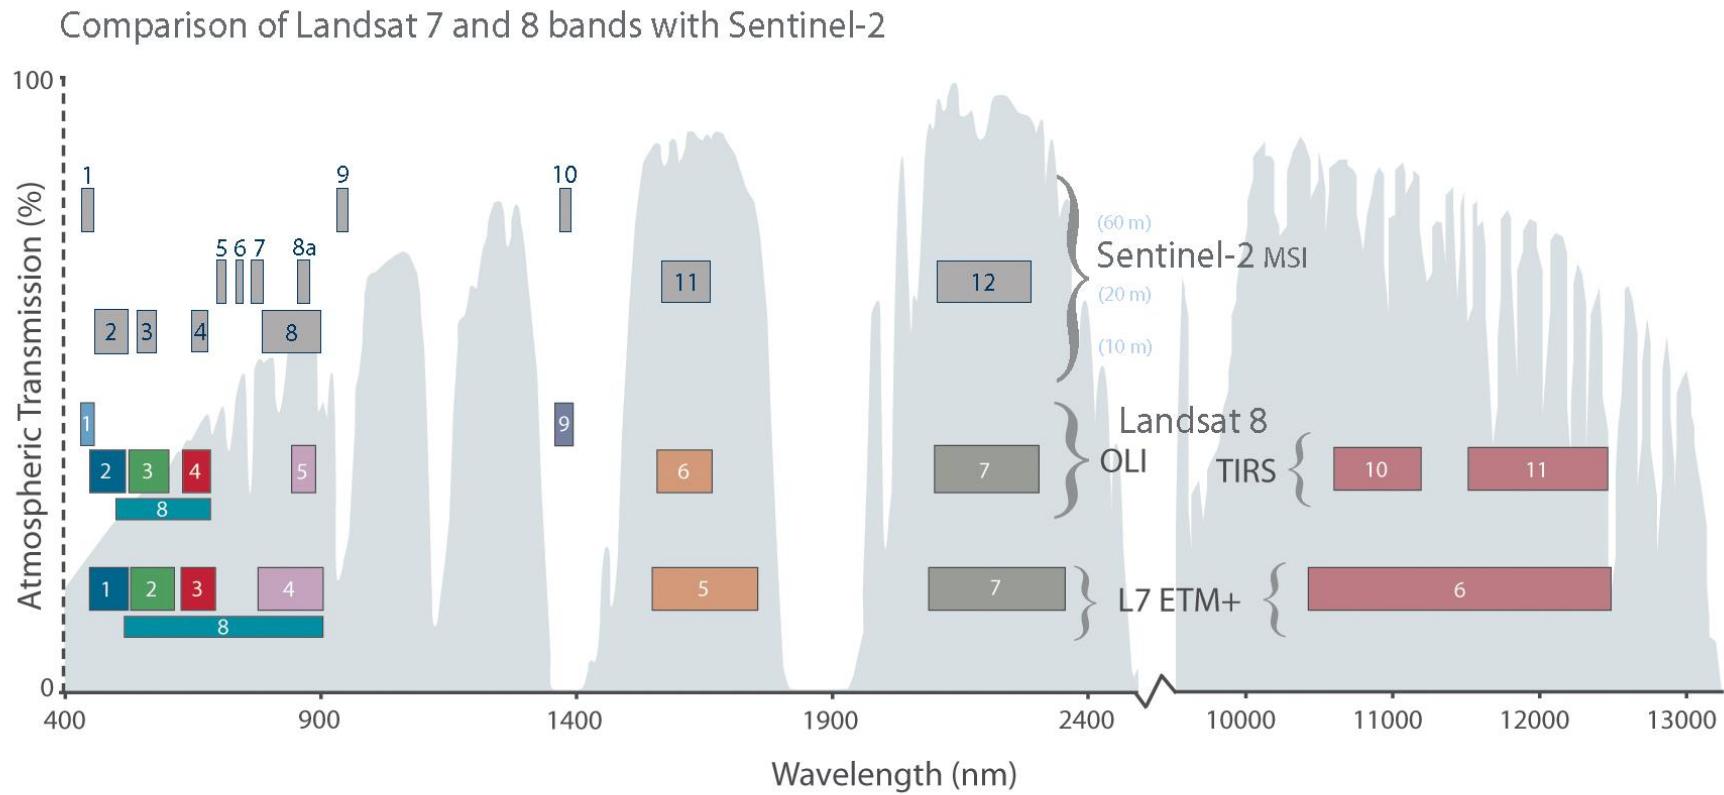
N

NDVI

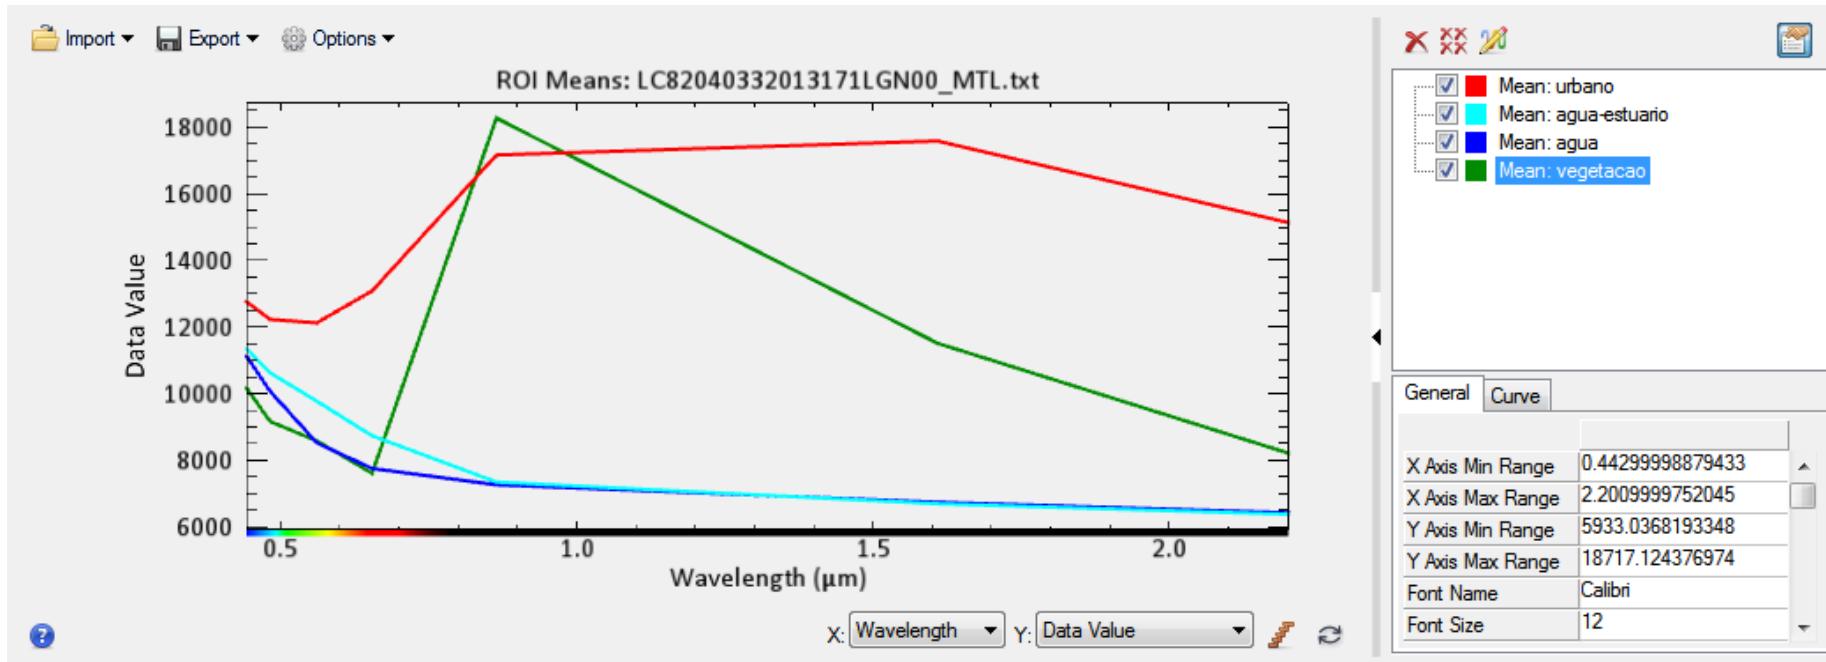




Landsat & Sentinel-2 Spectral bands



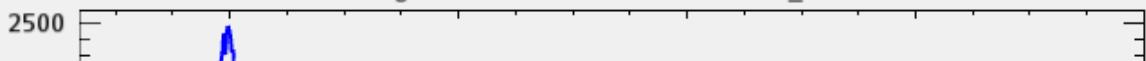
Spectral Reflectance



Import Export Options



Histograms: LC82040332013171LGN00_MTL.txt



- Histogram: Band 2: urbano
- Histogram: Band 2: agua-estuario
- Histogram: Band 2: agua

Import Export Options



Histograms: LC82040332013171LGN00_MTL.txt



- Histogram: Band 3: urbano
- Histogram: Band 3: agua-estuario
- Histogram: Band 3: agua
- Histogram: Band 3: vegetacao

Import Export Options



Histograms: LC82040332013171LGN00_MTL.txt

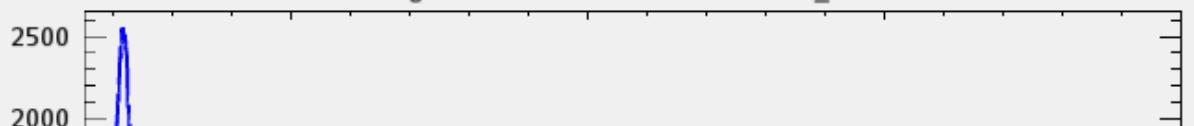


- Histogram: Band 4: urbano
- Histogram: Band 4: agua-estuario
- Histogram: Band 4: agua
- Histogram: Band 4: vegetacao

Import Export Options



Histograms: LC82040332013171LGN00_MTL.txt

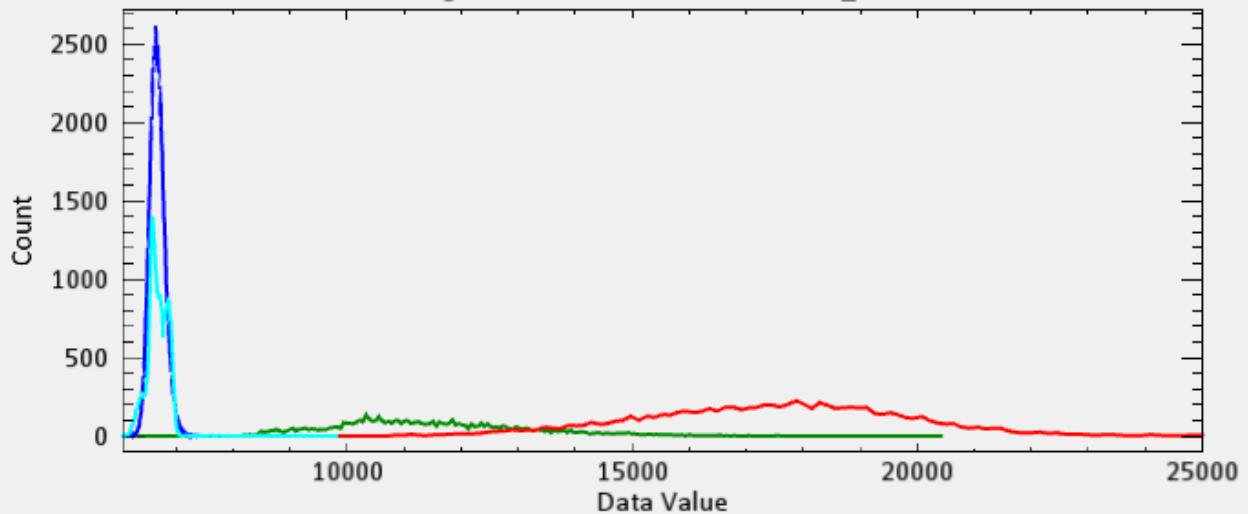


- Histogram: Band 5: urbano
- Histogram: Band 5: agua-estuario
- Histogram: Band 5: agua
- Histogram: Band 5: vegetacao

Import Export Options



Histograms: LC82040332013171LGN00_MTL.txt



- Histogram: Band 6: urbano
- Histogram: Band 6: agua-estuario
- Histogram: Band 6: agua
- Histogram: Band 6: vegetacao

General Curve

X Axis Min Range	6067
X Axis Max Range	25000
Y Axis Min Range	-98.137503899634
Y Axis Max Range	2715.1375038996
Font Name	Calibri
Font Size	12

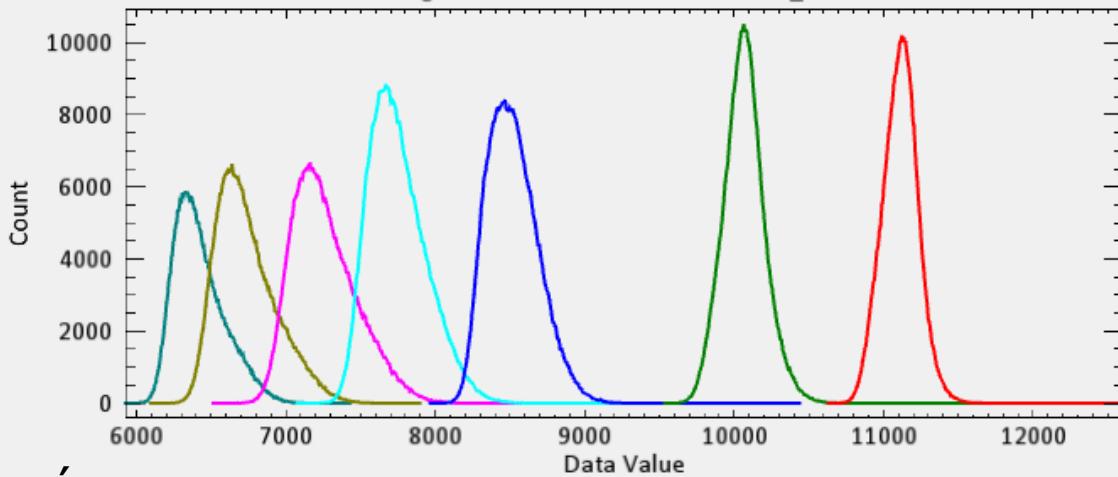


X: Data Value Y: Data Value



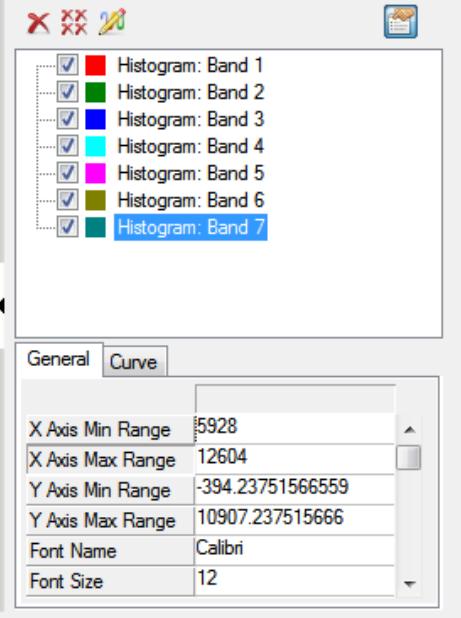
Import Export Options

Histograms: LC82040332013171LGN00_MTL.txt



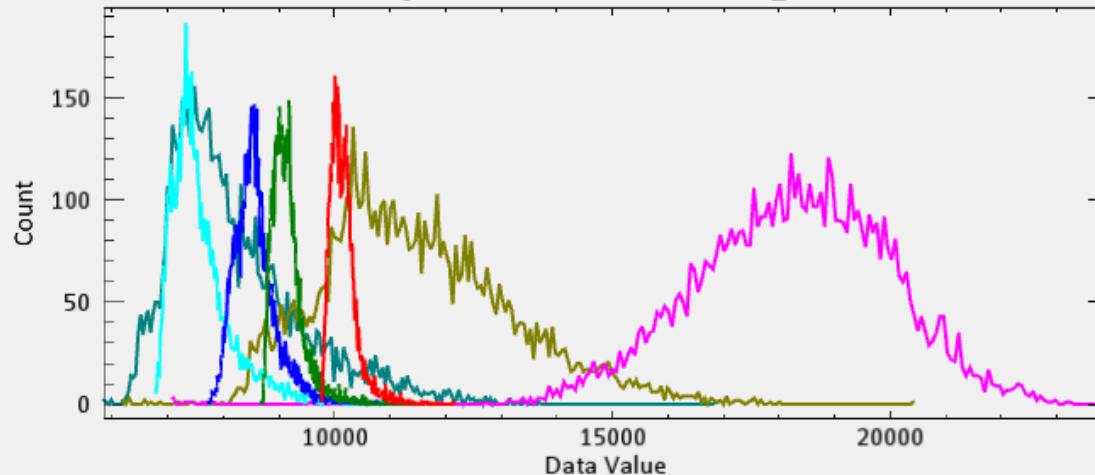
Água Oceano

X: Data Value Y: Data Value



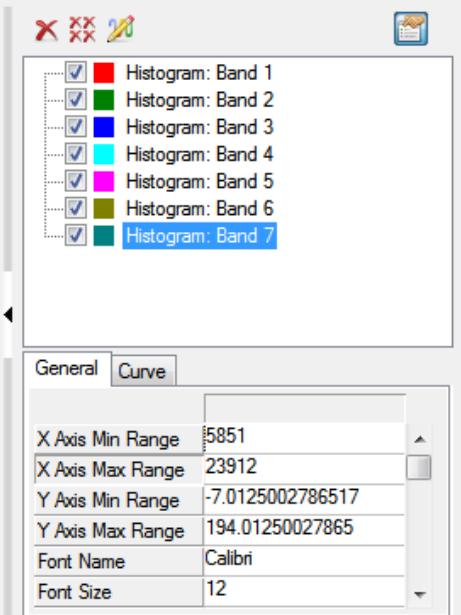
Import Export Options

Histograms: LC82040332013171LGN00_MTL.txt

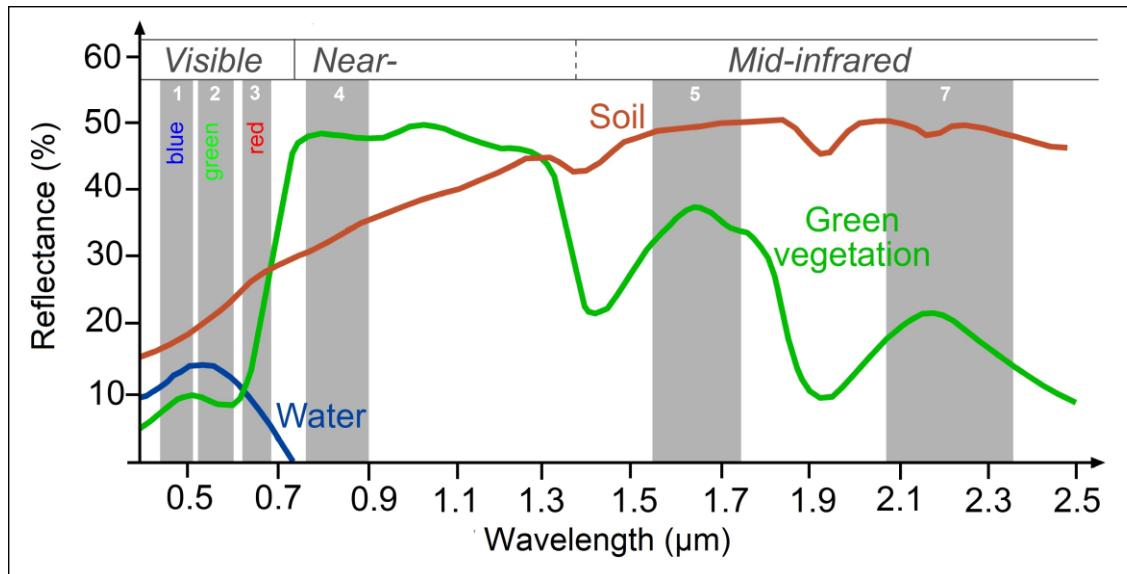


Vegetação

X: Data Value Y: Data Value



Índice da Água

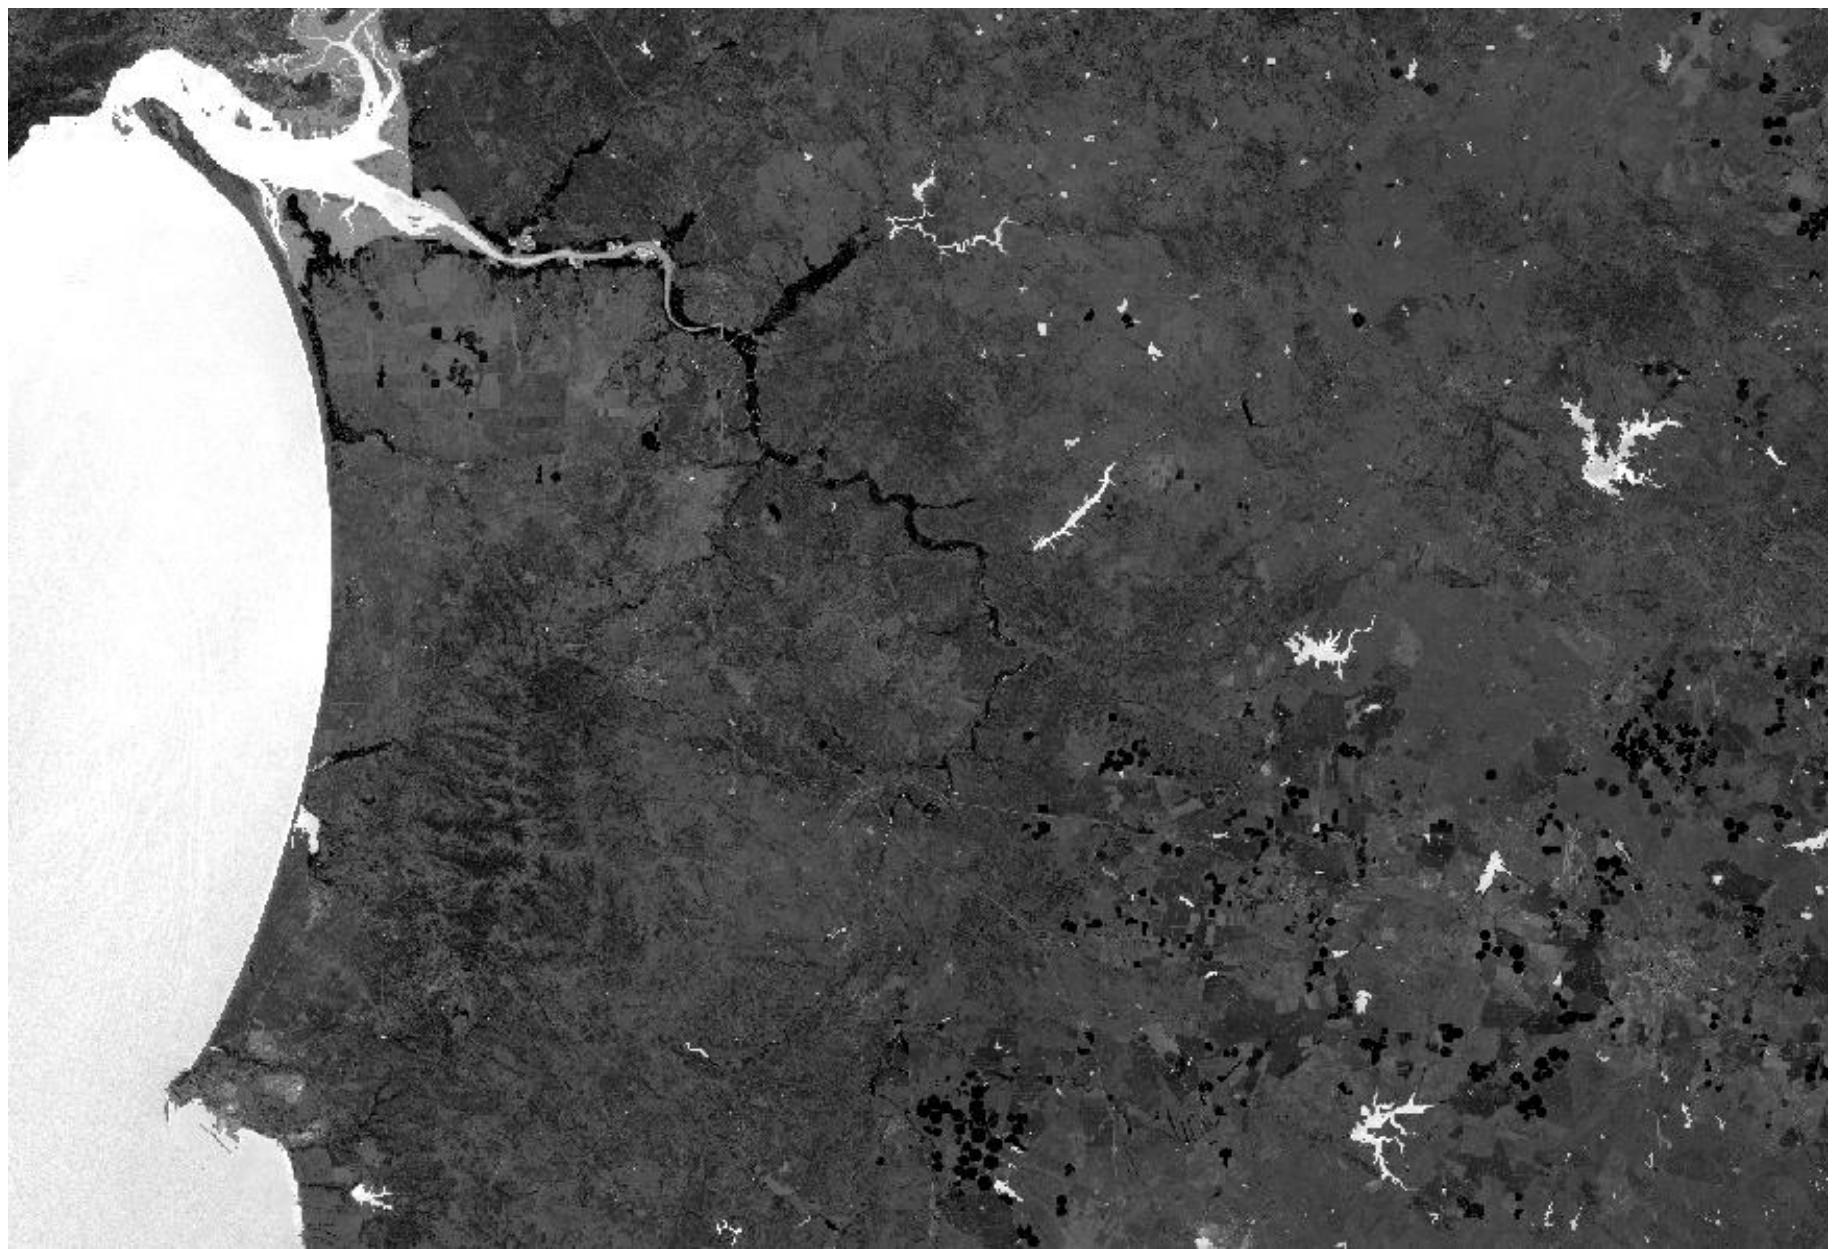


$$NDWI = \frac{NIR(B8) - SWIR2(B12)}{NIR(B8) + SWIR2(B12)}$$

(conteúdo de água na vegetação)

$$NDWI2 = \frac{GREEN(B3) - NIR(B8)}{GREEN(B3) + NIR(B8)}$$

Elemento Água



Sentinel-2, T29SNC, 3/8/2019

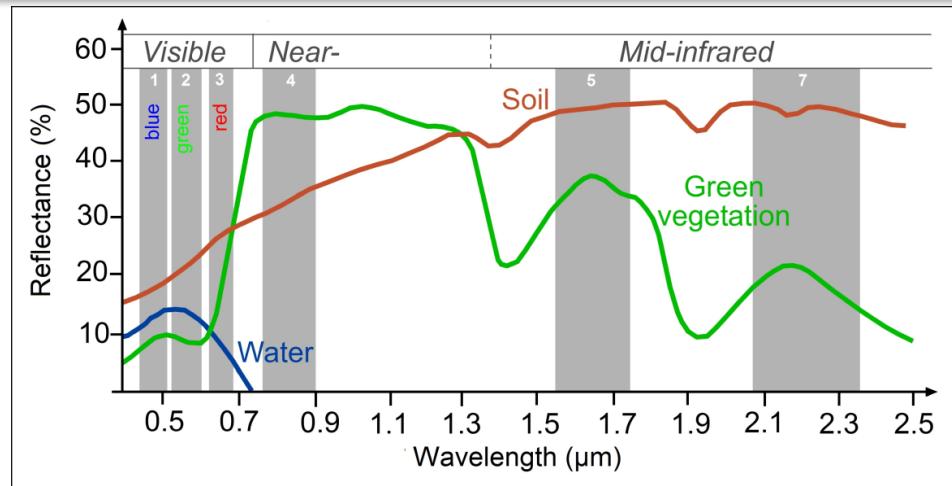
NDWI2



Sentinel-2, T29SNC, 3/8/2019

NDWI

Índice de área ardida



Índices	Designação	Referência
NDVI	Normalized Difference Vegetation Index	Rouse et al., 1974
GEMI	Global Environmental Monitoring Index	Pinty & Verstraete, 1992
BAI	Burned Area Index	Martín et al., 1998
BAIMS		Martín et al., 2005
BAIML		
NBRS	Normalized Burn Ratio	Key & Benson, 1999
NBRL		
MIRBI	Mid Infrared Burned Index	Trigg & Flasse, 2001

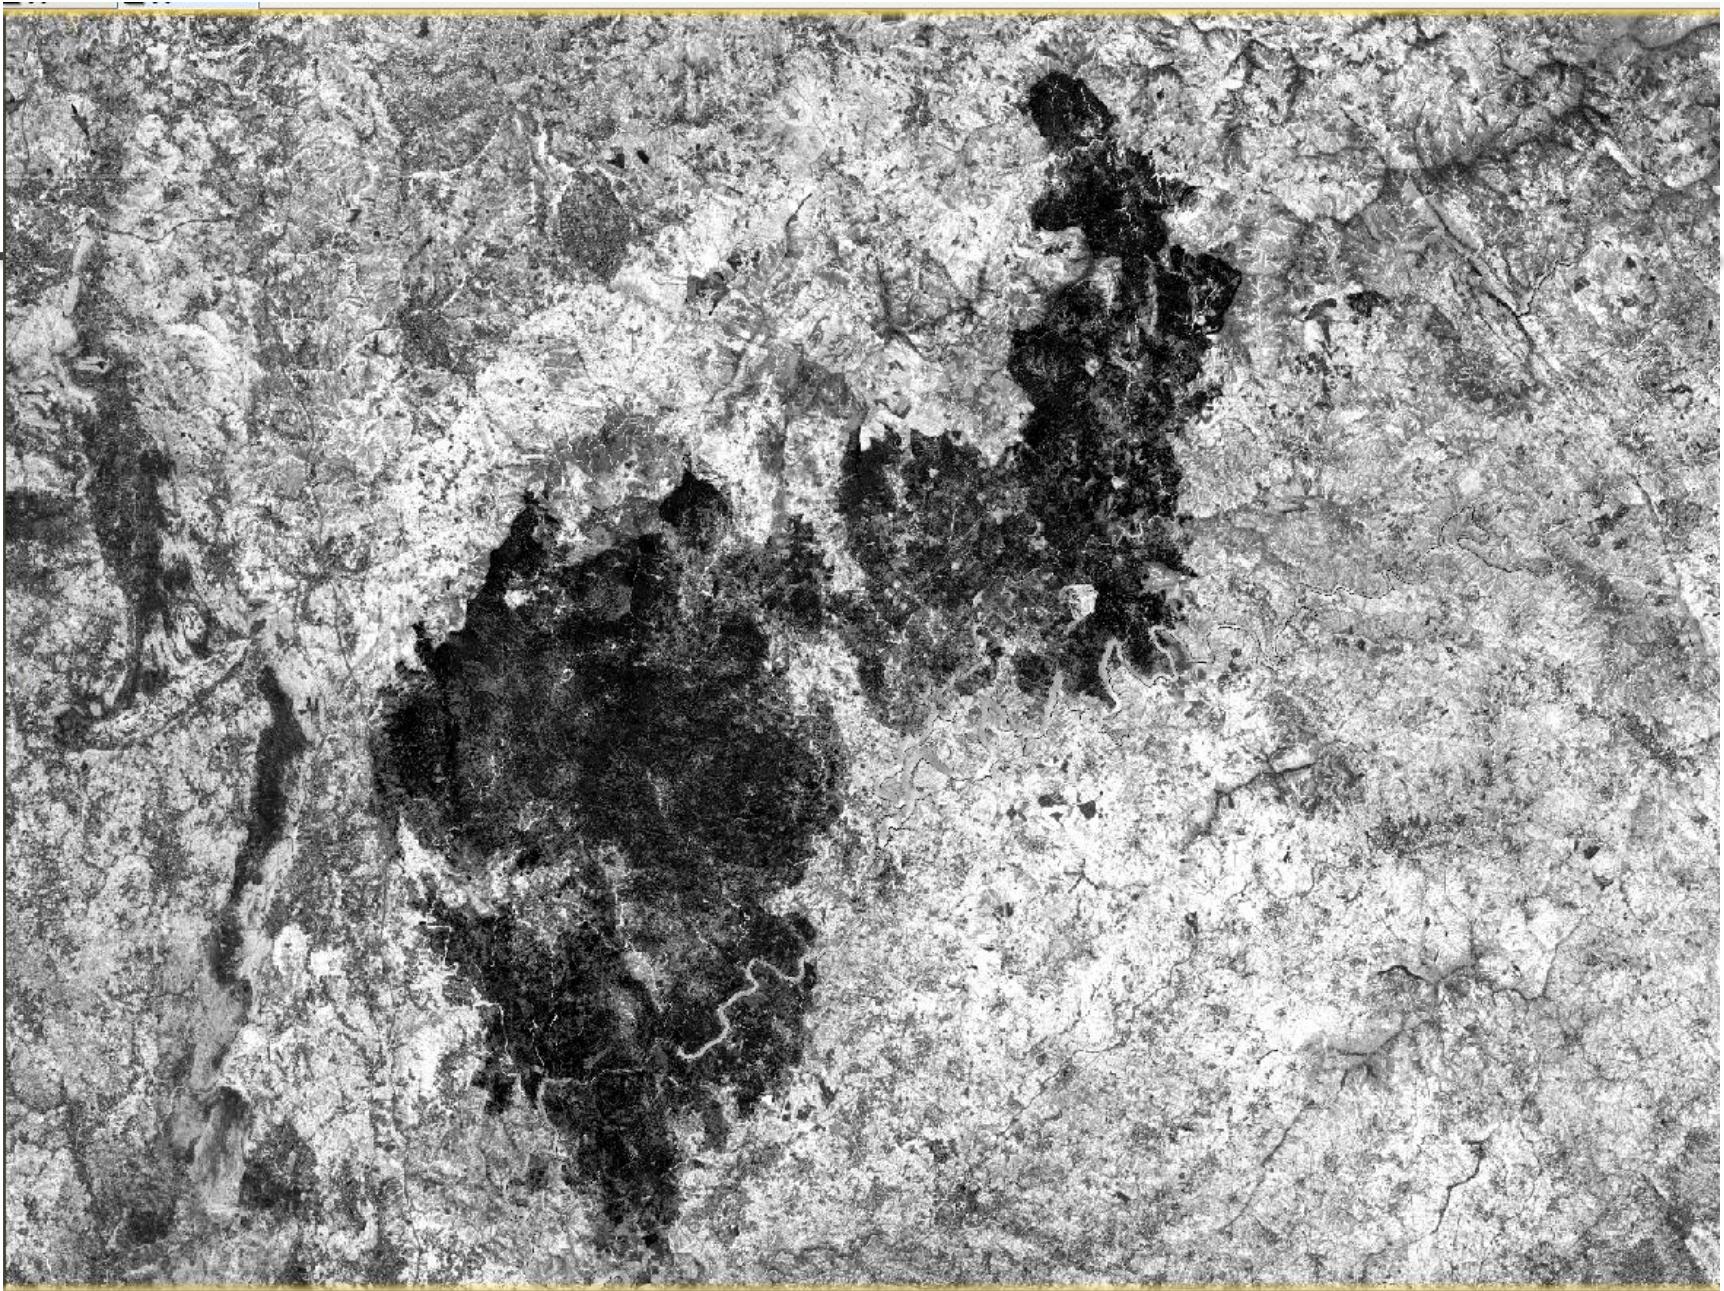
$$BAI = \frac{1}{(\rho_{NIR} - 0.06)^2 + (\rho_{Red} - 0.1)^2}$$

$$NBRS = \frac{\rho_{NIR} - \rho_{SWIR}}{\rho_{NIR} + \rho_{SWIR}}$$



Sentinel-2, T29TNE, 4/7/2017

Burned Area Index (Post_BAI > 188.88)



Sentinel-2, T29TNE, 4/7/2017

Normalized Burn ratio, Post_NBRS < -0.17079

Aplicações dos Índices

Segmentação de Imagem

(Divisão da imagem em regiões ou objectos, segundo um critério)

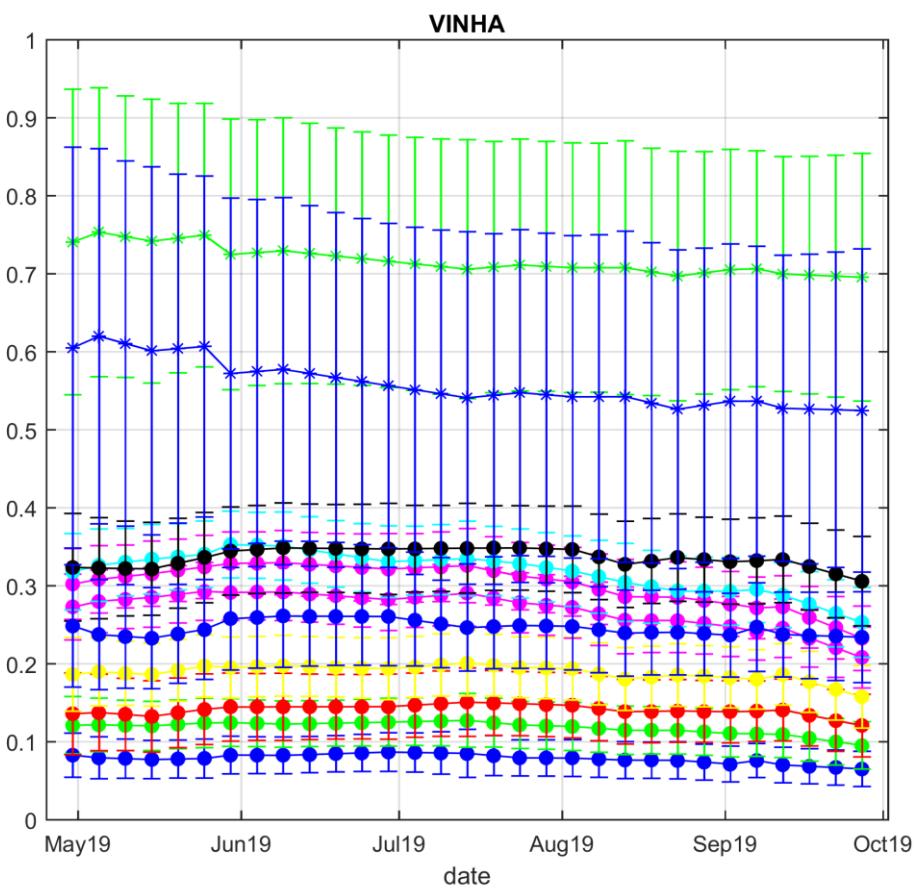
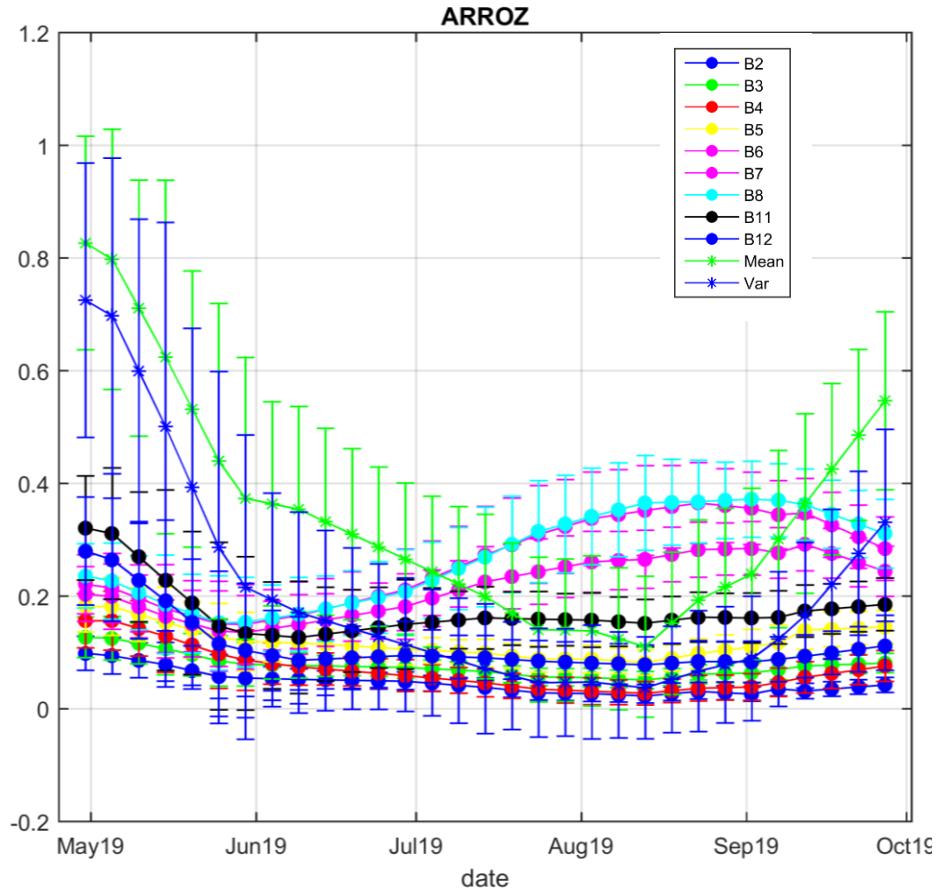
NDWI2: Água / não Água

NDVI: Vegetação / não Vegetação

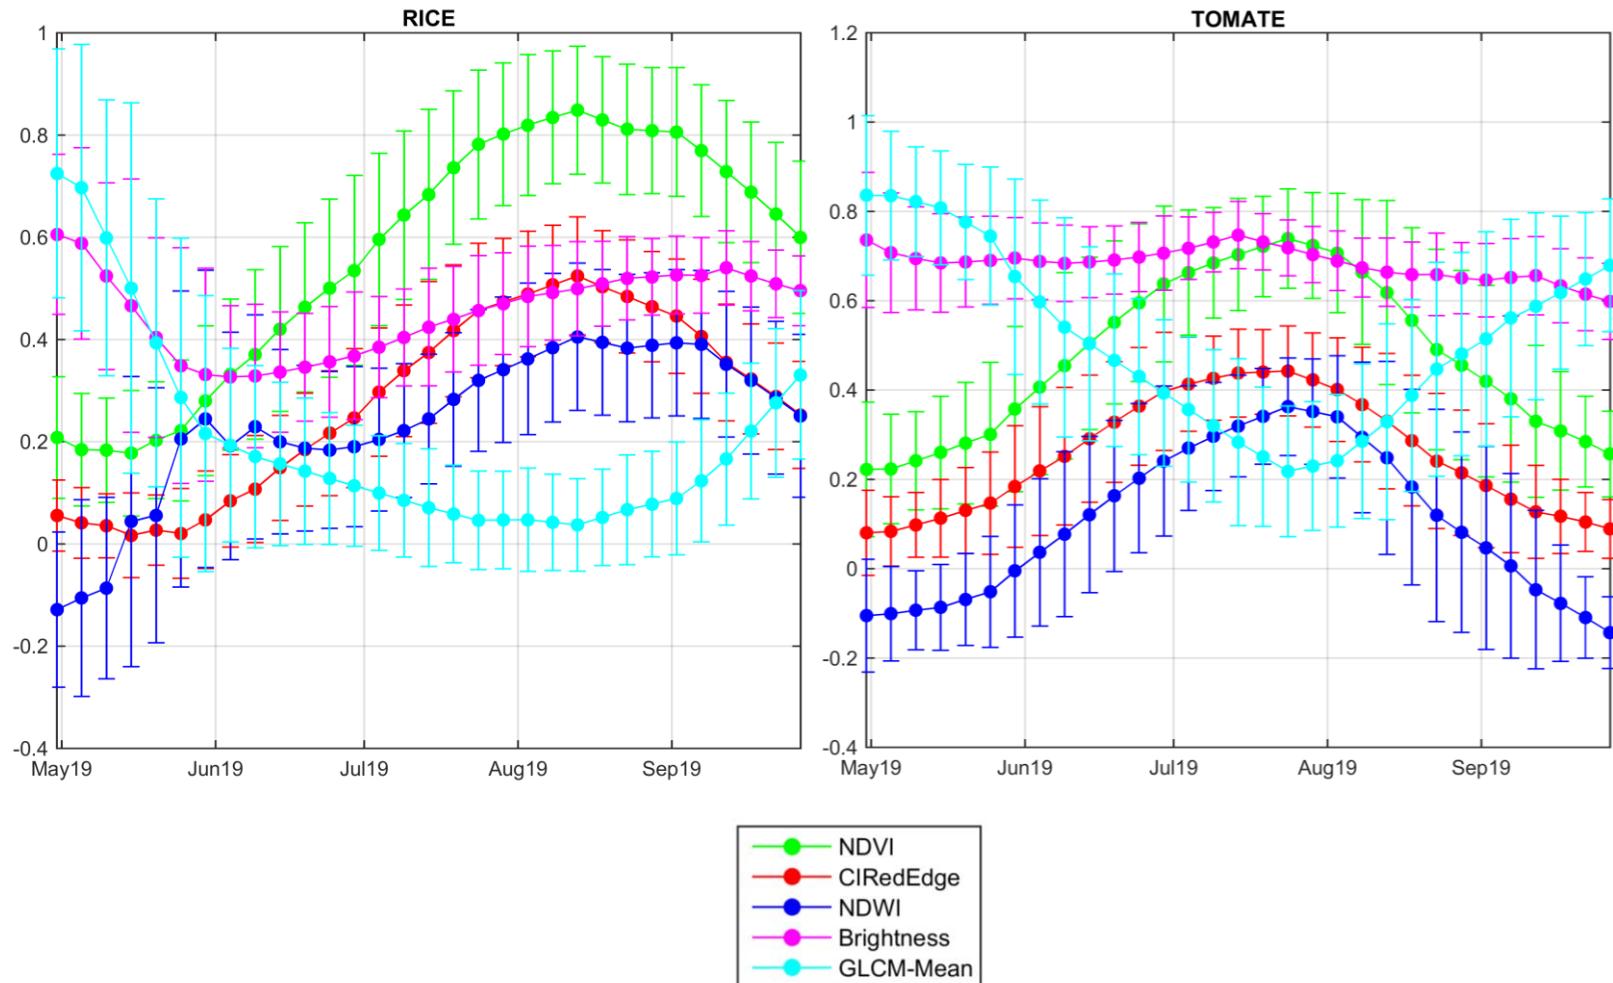
NDVI: Culturas temporárias/ Culturas Permanentes.

NDVI: Vitalidade da vegetação

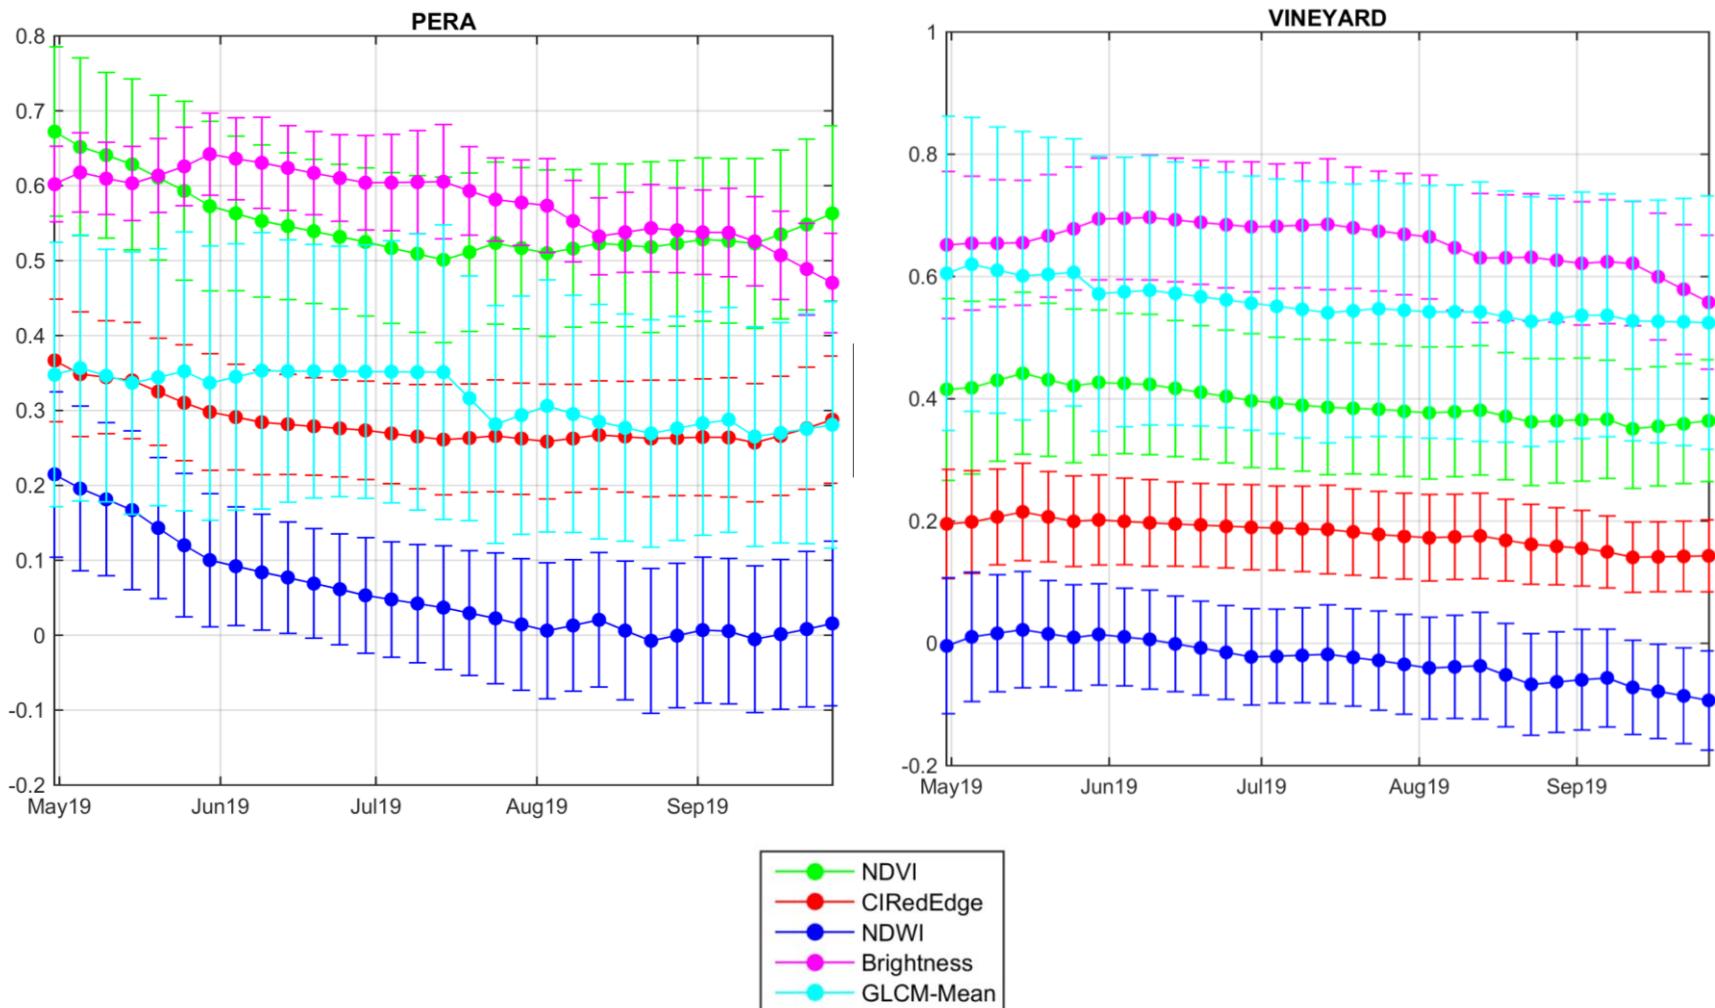
Spectral Signature

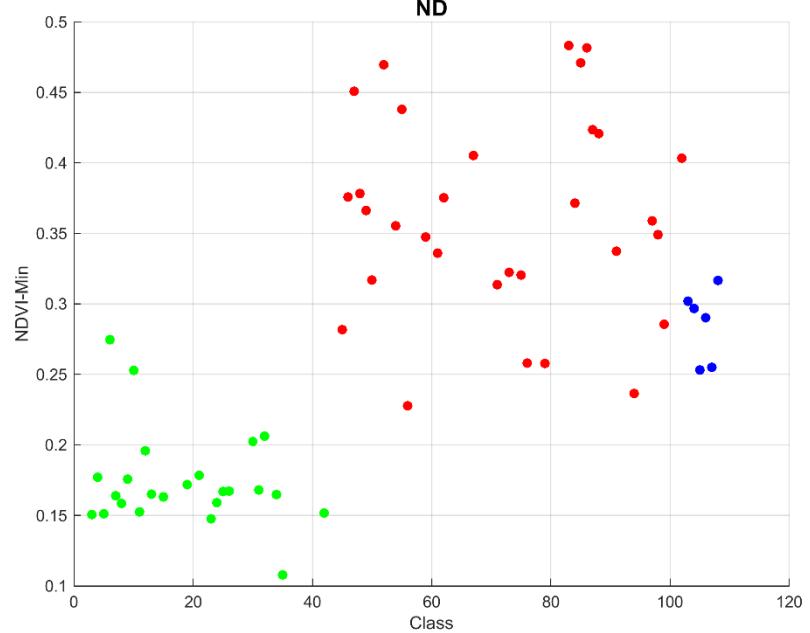
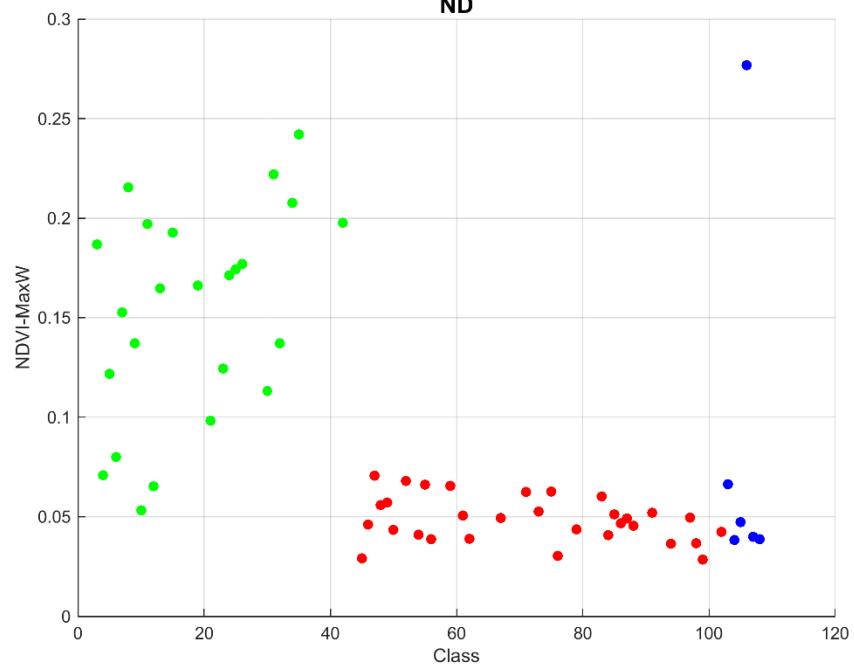
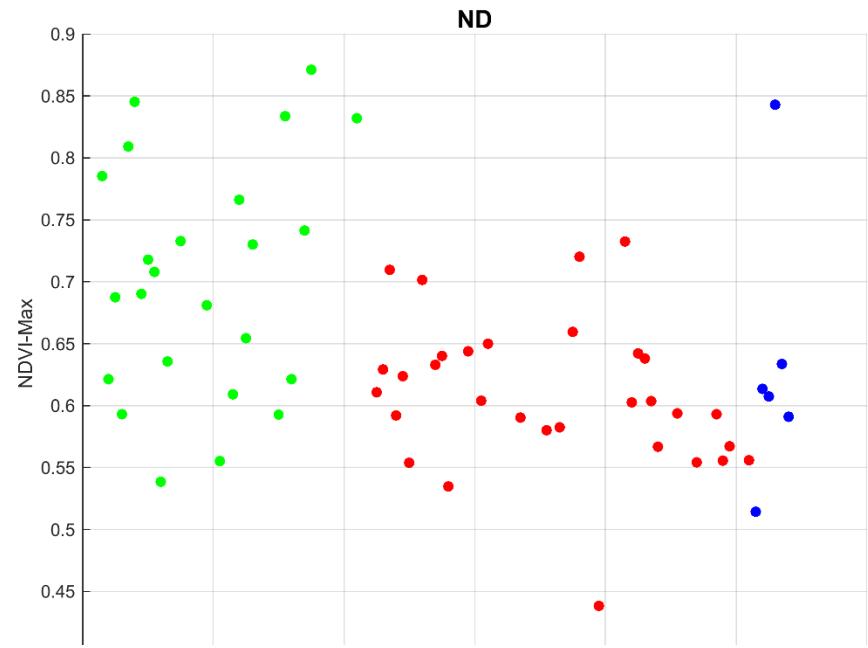


Culturas Temporárias



Culturas Permanentes

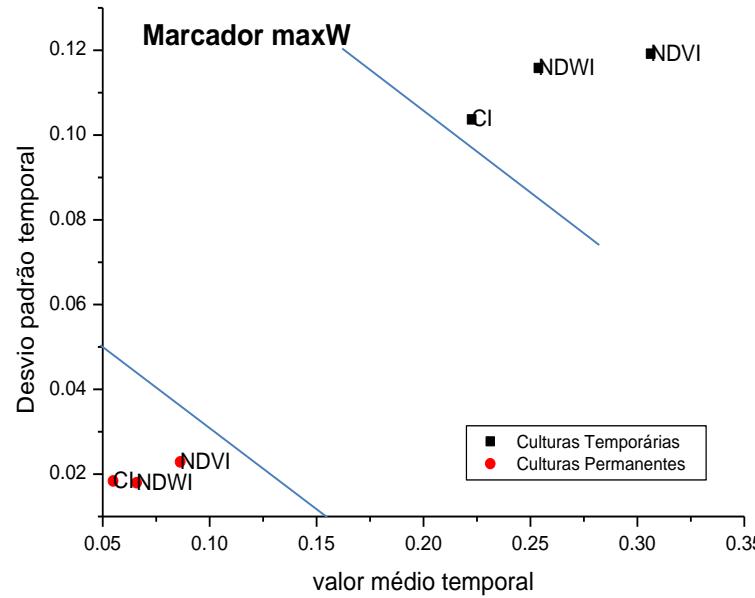




Métricas baseadas em indices
Min, Máx, Média, Std, maxW, MinW

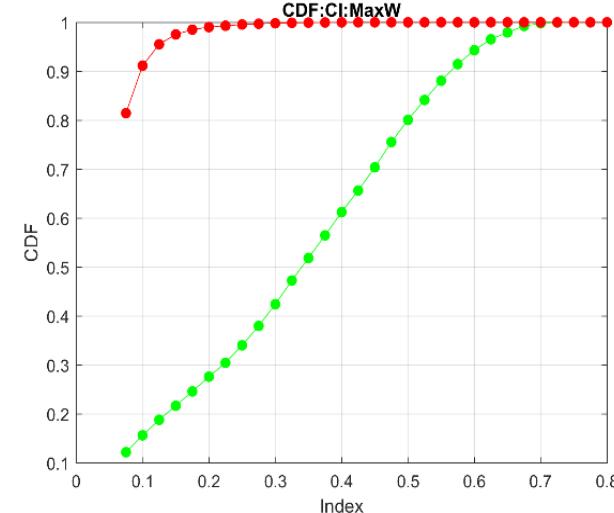
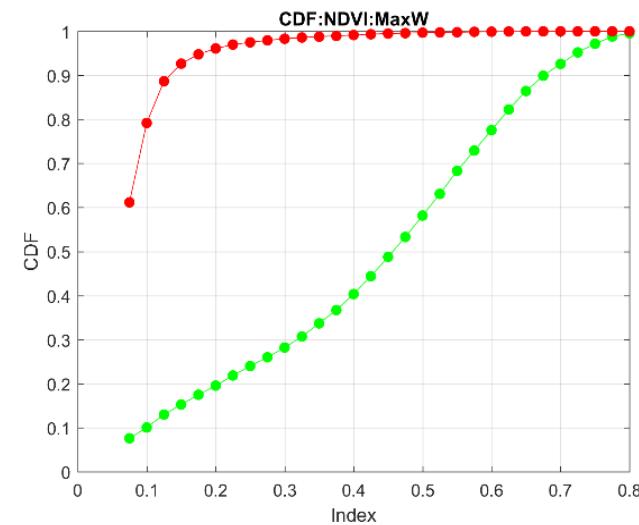
Verde: Culturas Temporárias
Vermelho: Culturas Permanentes
Azul: Vinha+ Olival+ ..

Função Distribuição Cumulativa

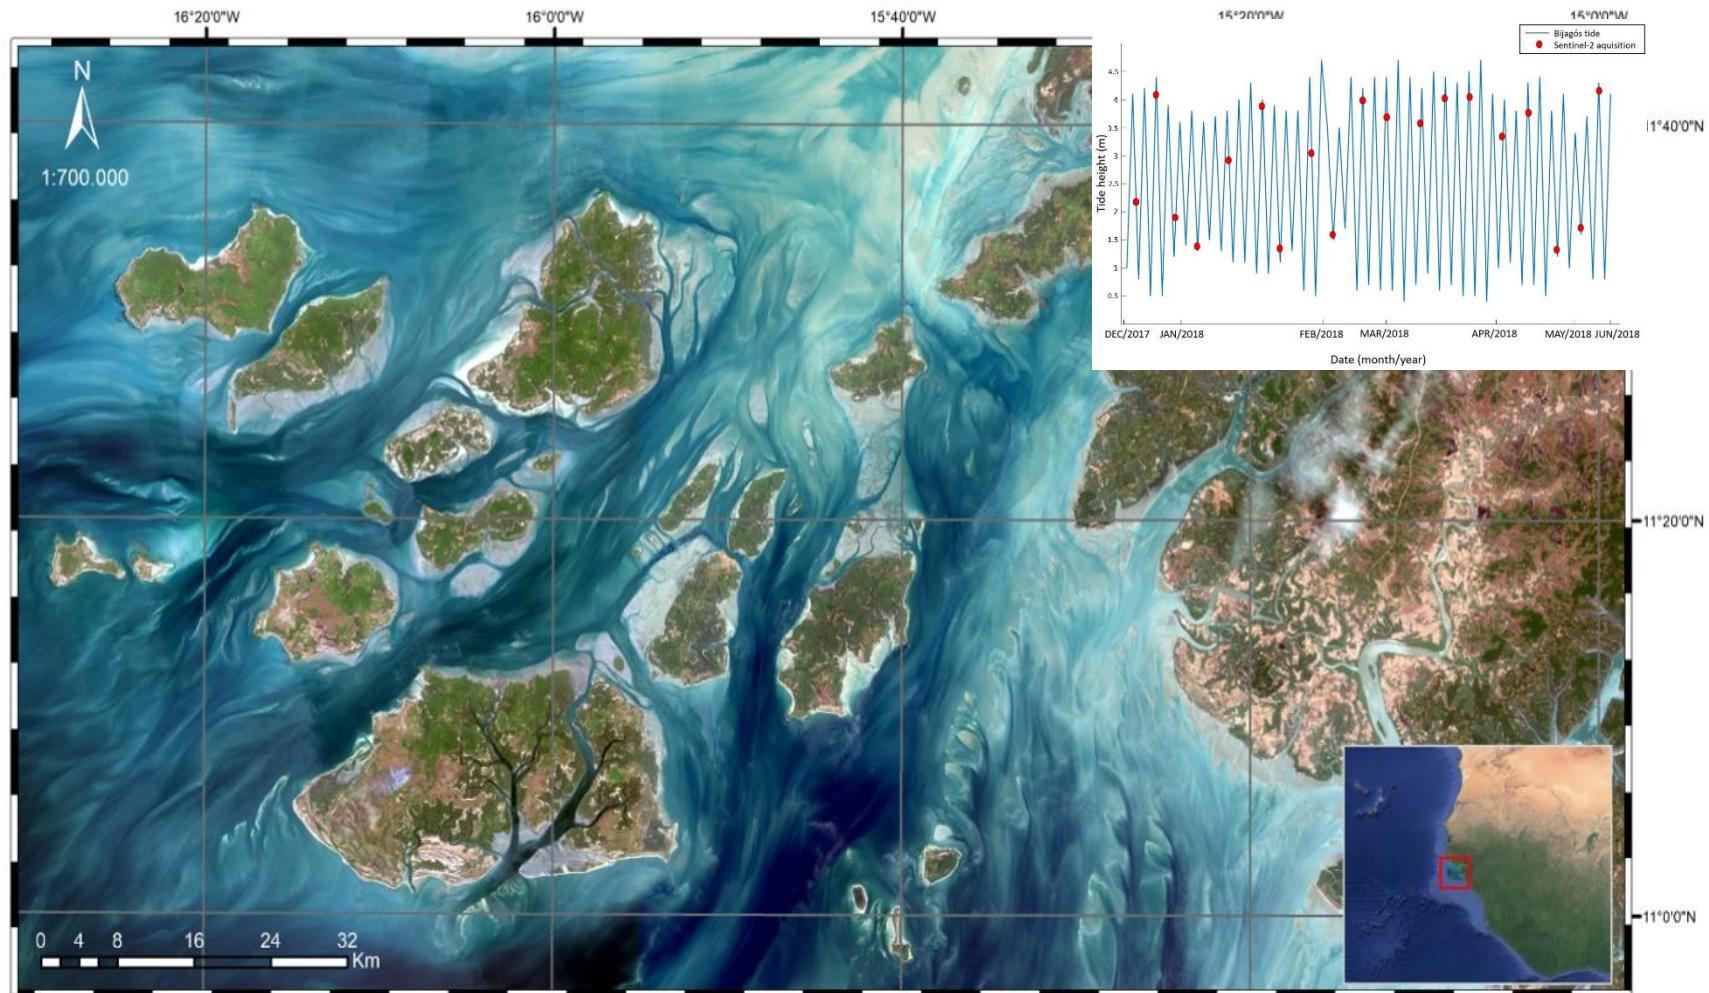


Verde: Culturas Temporárias

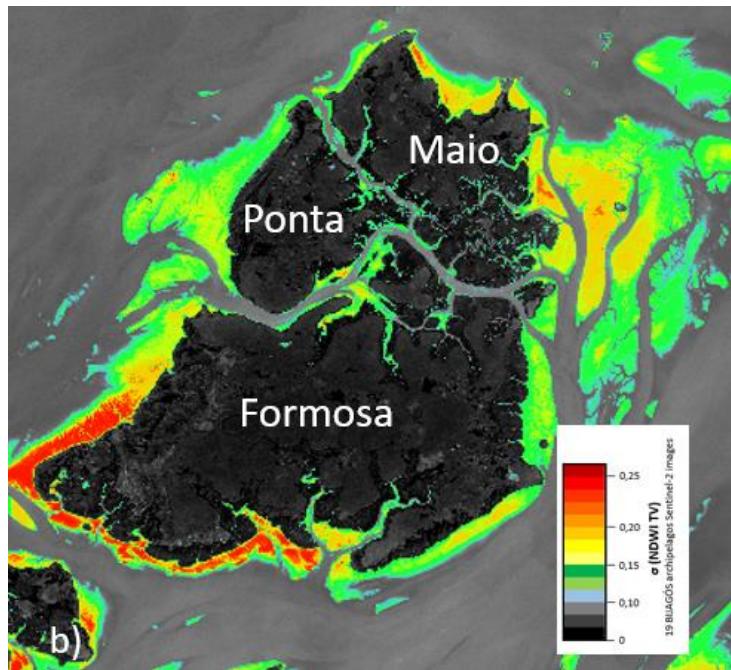
Vermelho: Culturas Permanentes



Intertidal bathymetry Bijagos



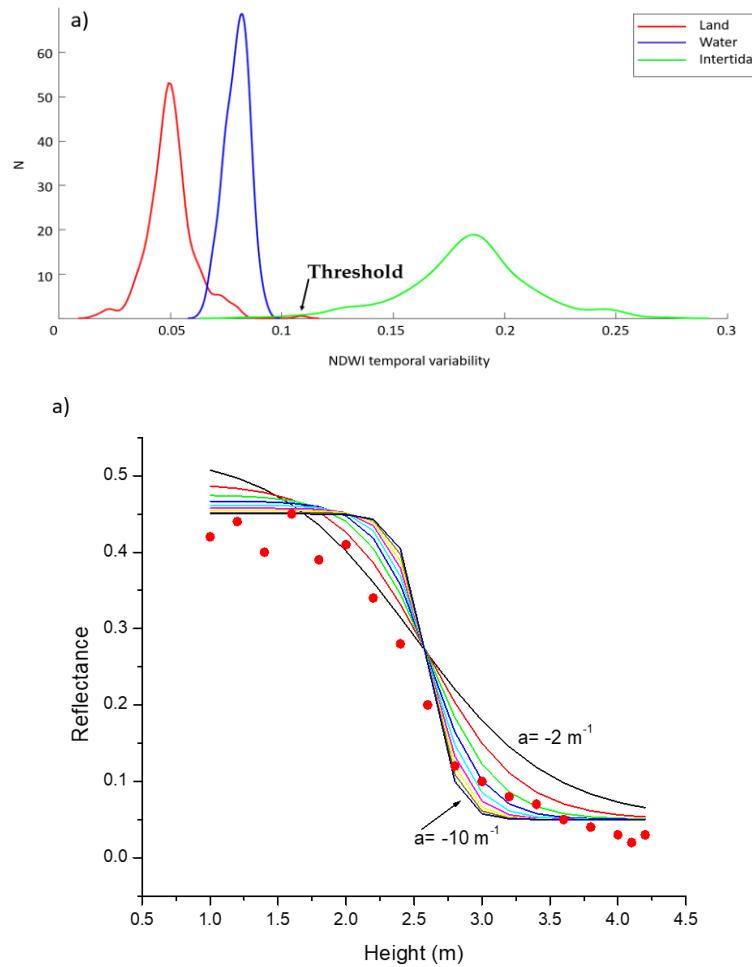
Culturas Permanentes

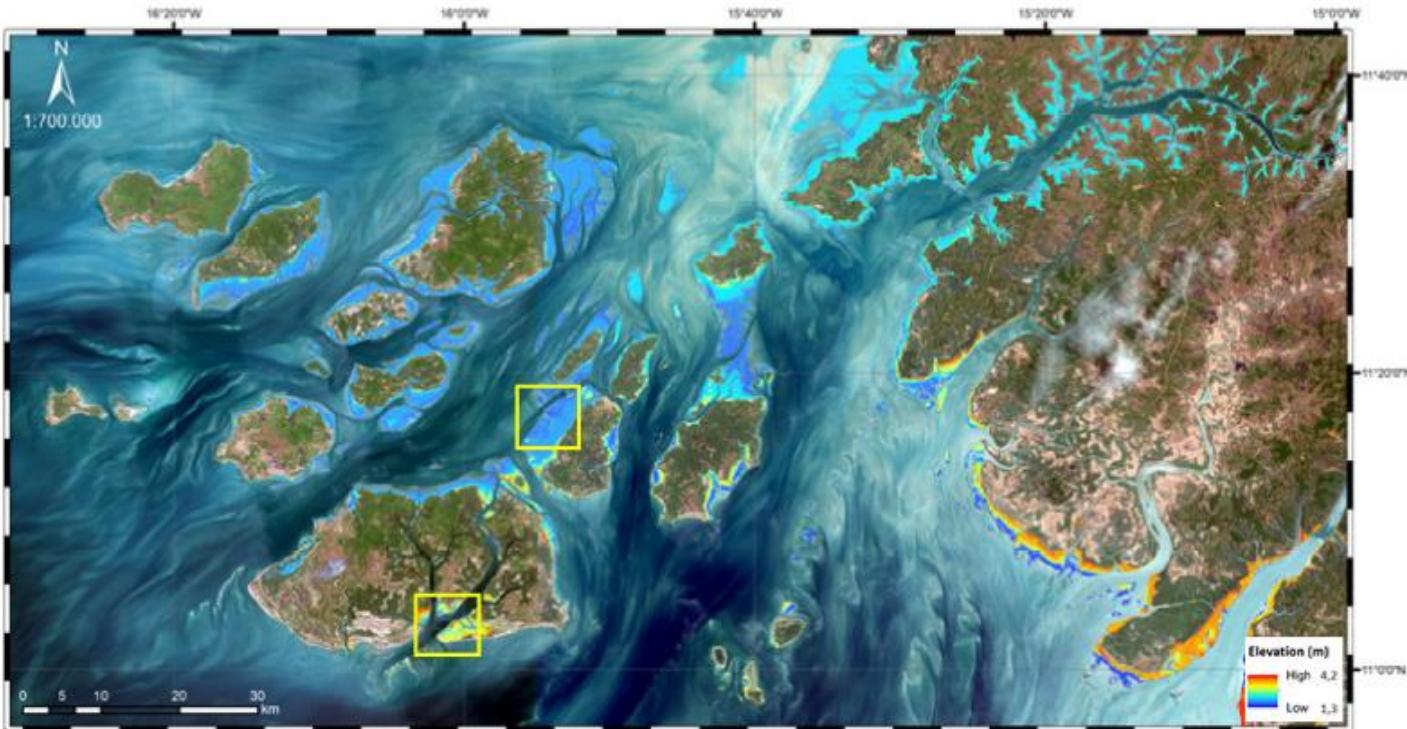


$$\sigma(x, y) = \sqrt{\frac{1}{M} \sum_{i=1}^M (NDWI_i - \bar{NDWI})^2}$$

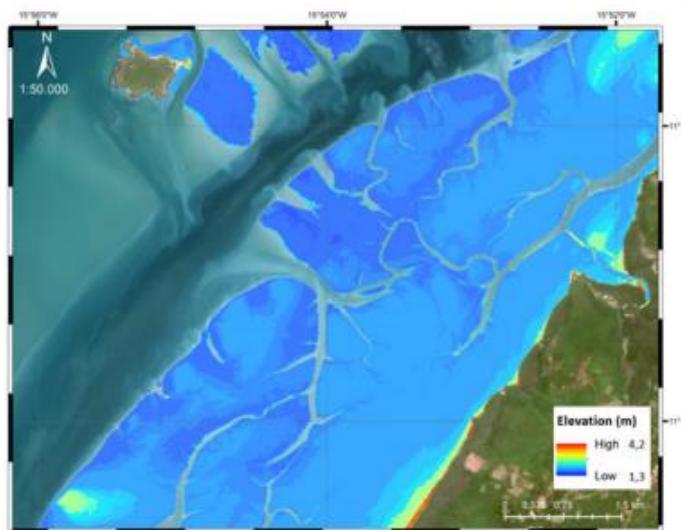
Regressão Logistica:

$$\rho_i(x, y) = \frac{k}{1 + e^{-a(h_i - h_t)}} + LowLim$$

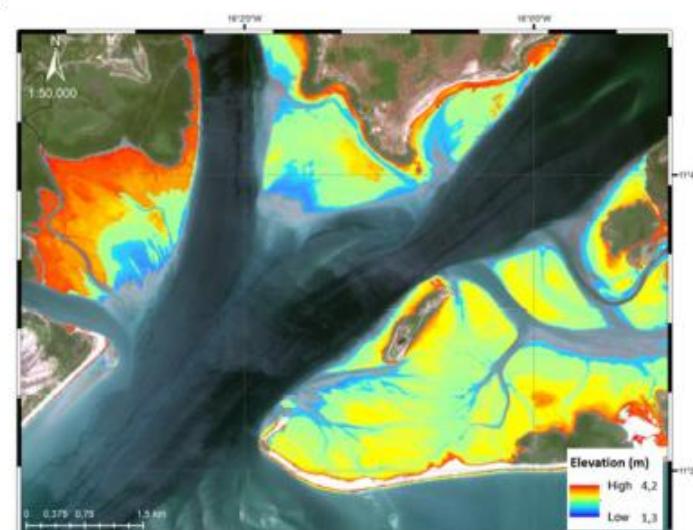




(a)



(b)



(c)

Período de exposição da zona intertidal



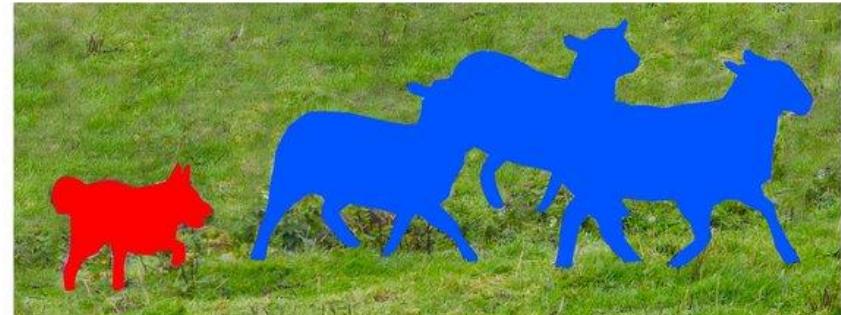
9.5 h
2.5 h



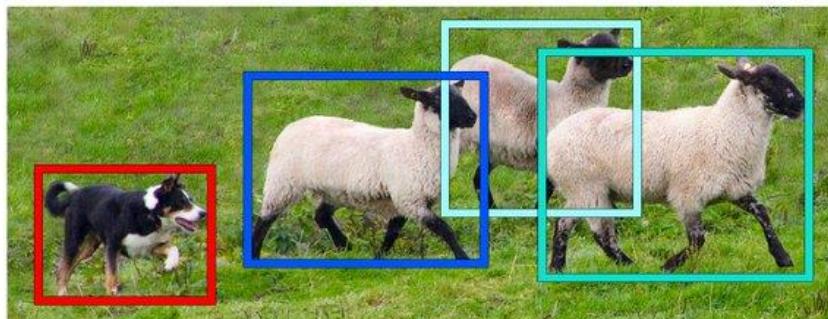
Image Classification



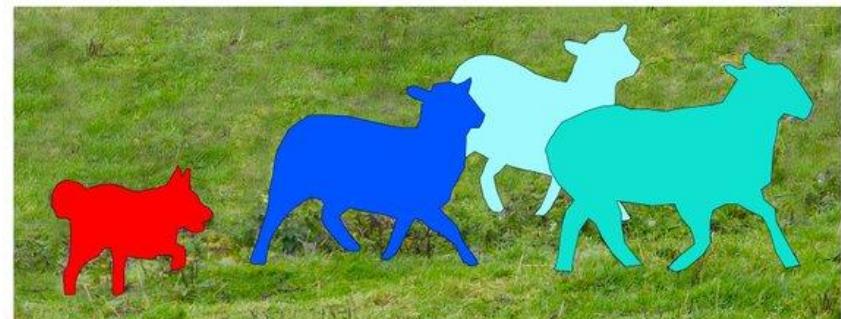
Image Recognition



Semantic Segmentation



Object Detection



Instance Segmentation

Segmentation in an image is the process of breaking down the digital image into multiple segments (that is divided into the set of different pixels into an image).



Image Classification



Image classification actually, refers to the task of extracting the information classes from a multiband raster image. It analyzes the numerical properties of various image features and organizes the data into the different categories — or you can say image classification is like image categorization.

In fact, **data classification** algorithms typically employ two phases of processing — training and testing.



Image Classification

A classificação de imagem

Is related with the assignment of the pixels to specific spectral class using the available spectral information.
This operation can be viewed as a mapping function

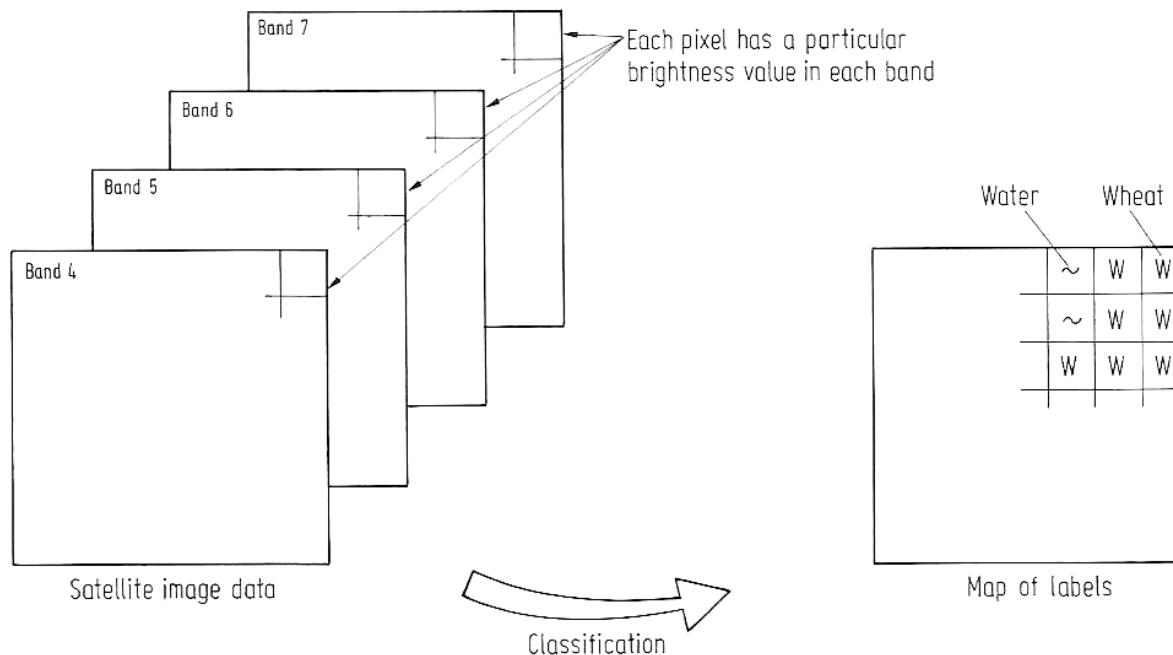


Image Classification

Podemos dividir os procedimentos de classificação de imagens em duas categorias:

UnSupervised

(clustering)

Os píxeis numa imagem são atribuídos a classes espectrais sem intervenção do utilizador, sem o conhecimento prévio da existência ou nome das classes

Supervised

Training areas

Na classificação supervisada é o utilizador que define as classes espectrais e que selecciona os dados treino.

Parametric

É assumido que as classes espectrais podem ser descritas por uma distribuição de probabilidade no espaço multiespectral.

Non-parametric

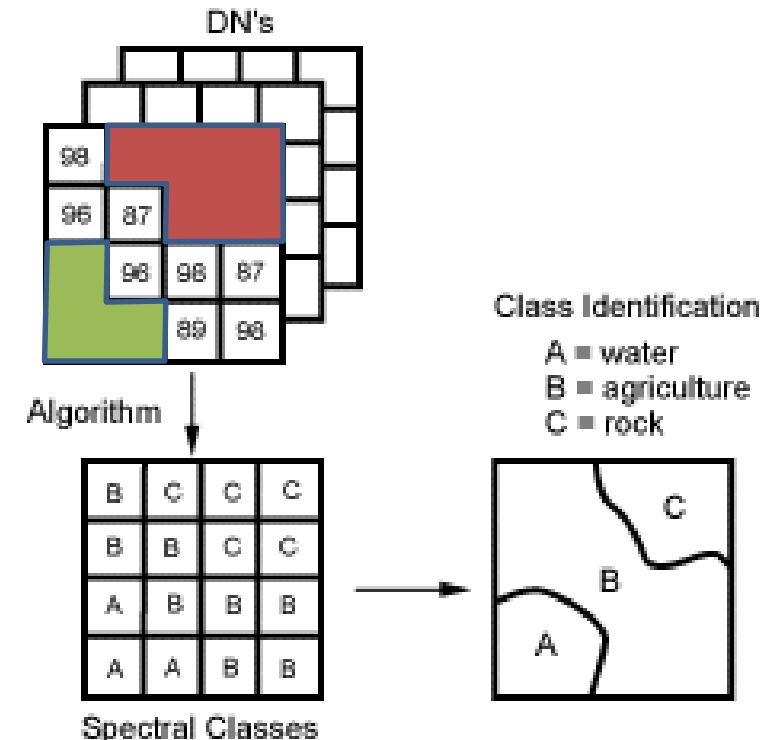
ISODATA
K-Means
Aprendizagem Automática

Unsupervised methods

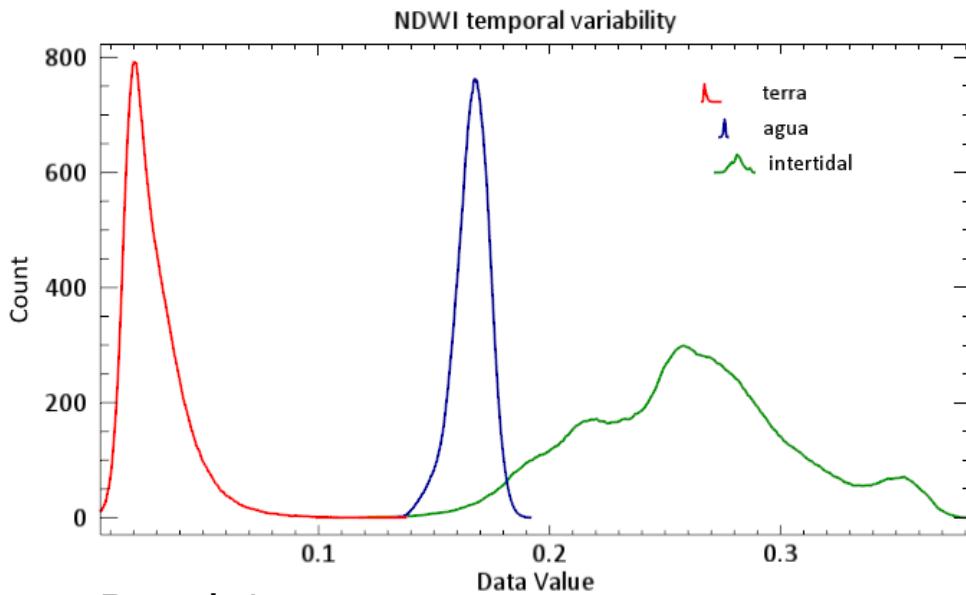
Não é necessário ter um conhecimento prévio do terreno, nem ter dados de treino.

Este método baseia-se em algoritmos que analisam todos os pixels e formam conjuntos de pixels (os chamados *cluster* ou padrões) apenas olhando aos valores dos pixels.

Em geral o utilizador pode escolher alguns parâmetros como o número máximo de padrões ou o número mínimo de pixels que é preciso para formar um *cluster*.

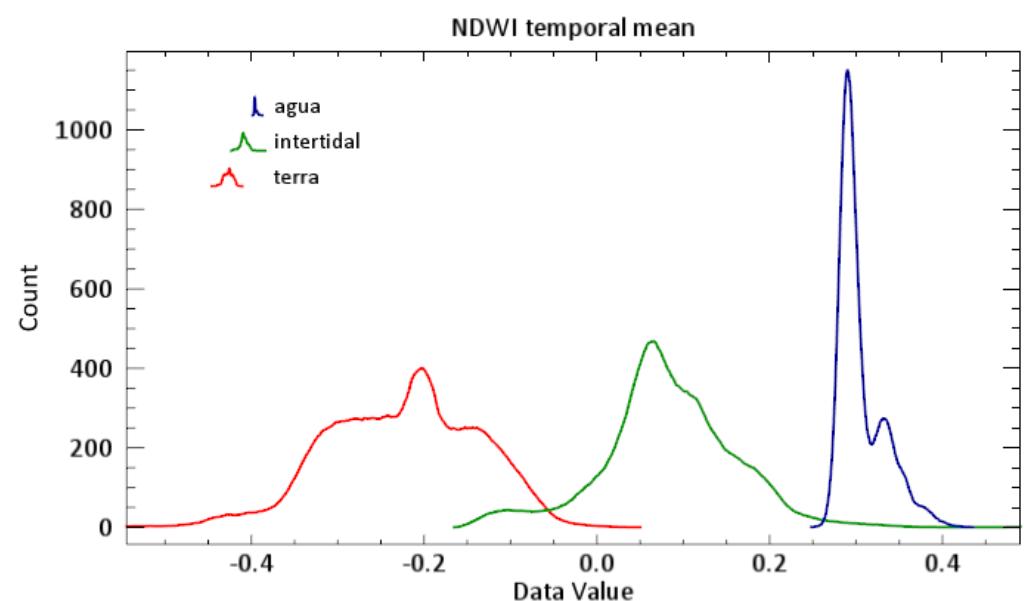


Unsupervised method– K-Means



Band 1

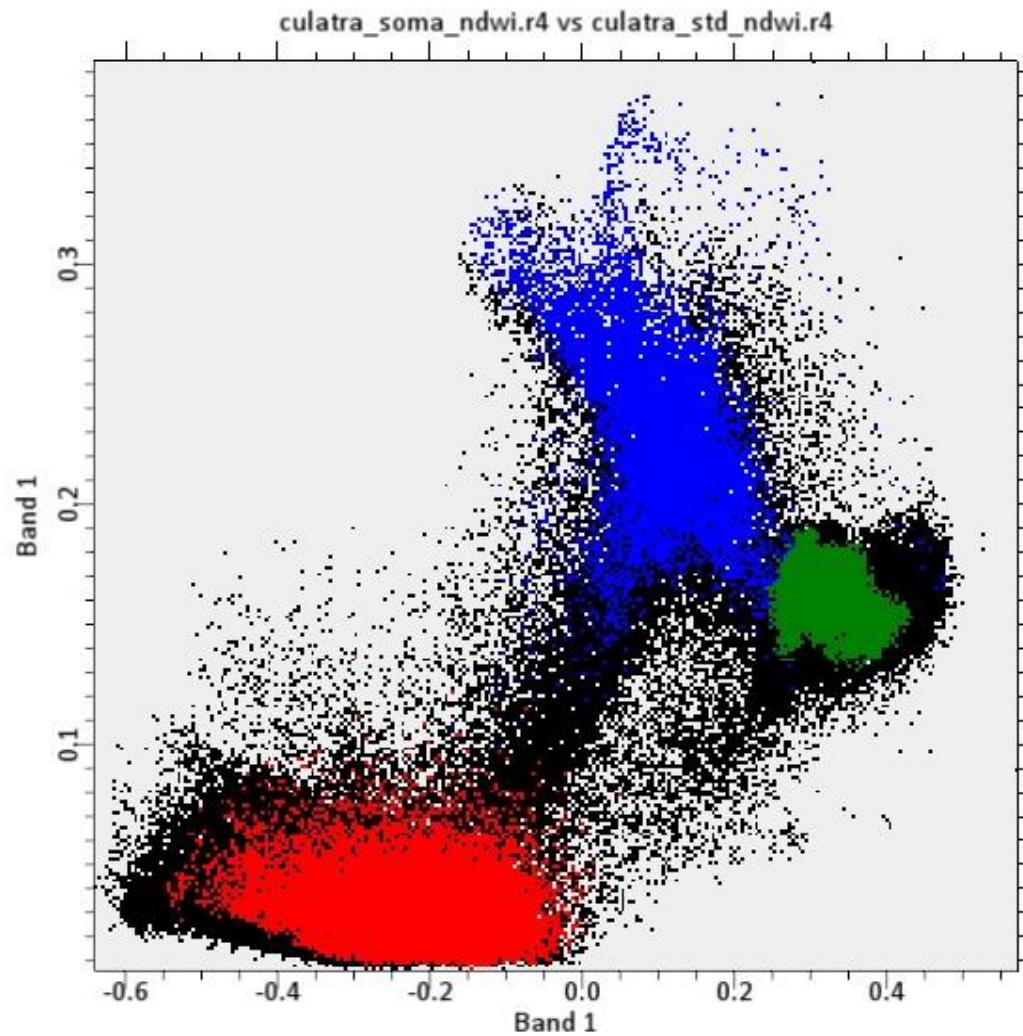
Two bands / 3 classes



Band 2

Unsupervised method– K-Means

Blue: water
Red: Land
Green: intertidal



Unsupervised method– K-Means

K-Means

Processo iterativo no qual são definidos o número M de classes e calculados valores médios para M classes distribuídas aleatoriamente no espaço e depois agregados iterativamente os restantes píxeis a essas classes usando a medida da mínima distância.

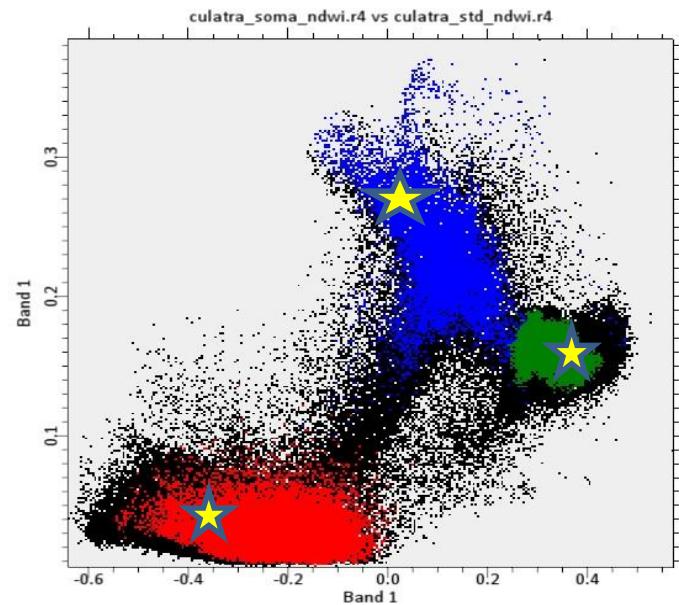
Cada iteração recalcula a média e reclassifica os píxeis relativamente à nova média

Todos os píxeis são classificados na classe mais próxima a menos que um limite seja especificado

O processo é continuado até que o número máximo de iterações seja atingido

Algoritmo K-Means

1. Selecionar k pontos como centróides iniciais
2. Formar k clusters associando cada objecto ao seu centróide mais próximo
3. Recalcular o centróide de cada cluster
4. Até que os centróides não apresentem mudanças

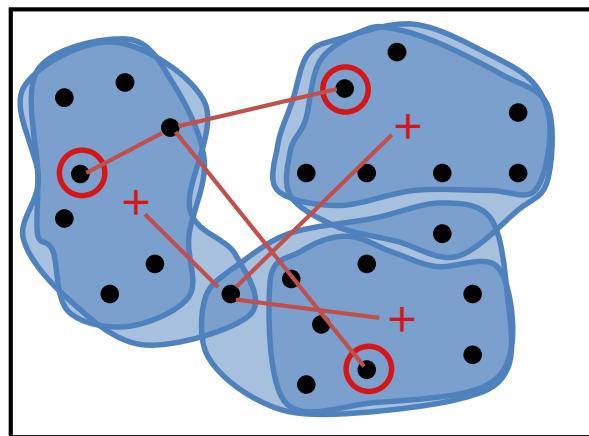


Centróide = centro de gravidade do cluster

Coordenada i = média aritmética das coordenadas i de seus objectos constituintes.

Algoritmo K-means

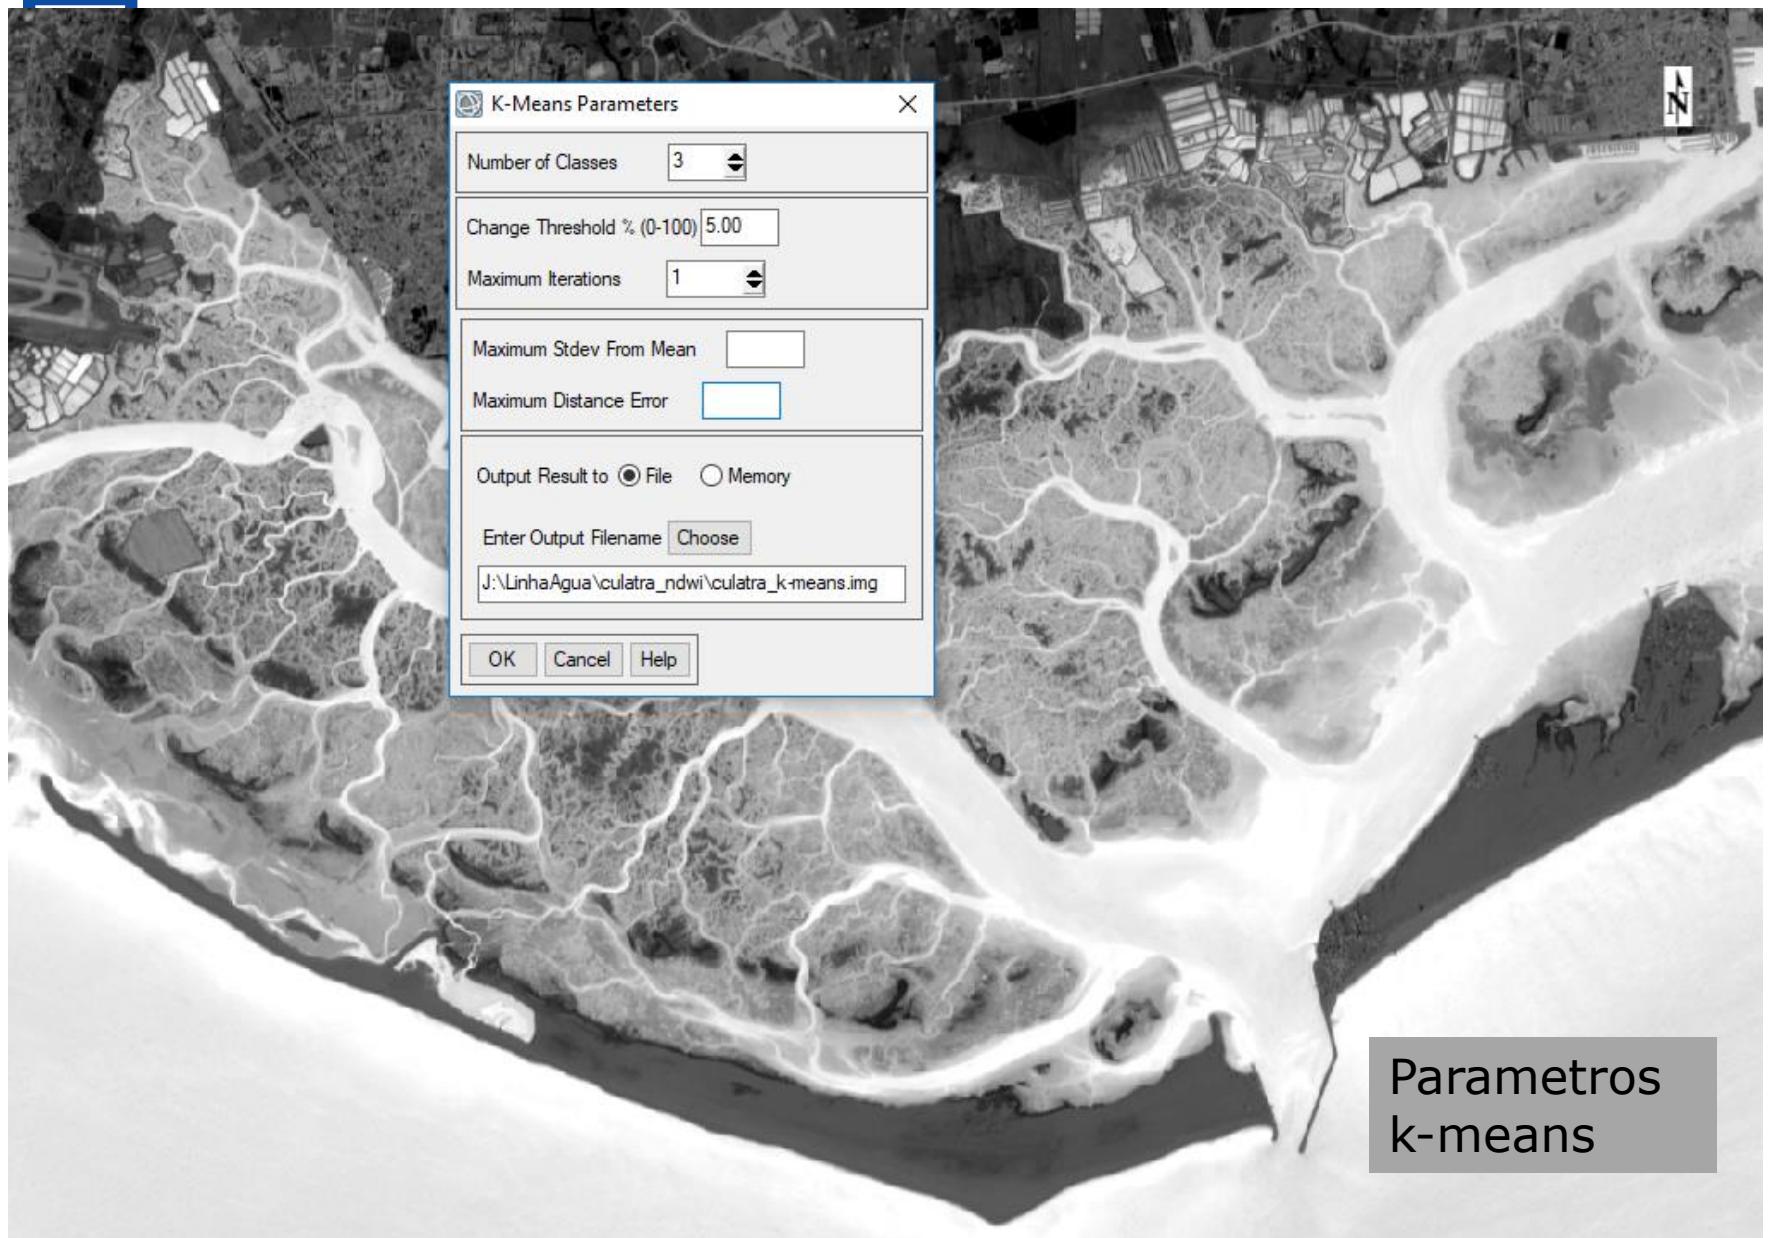
Exemplo K = 3

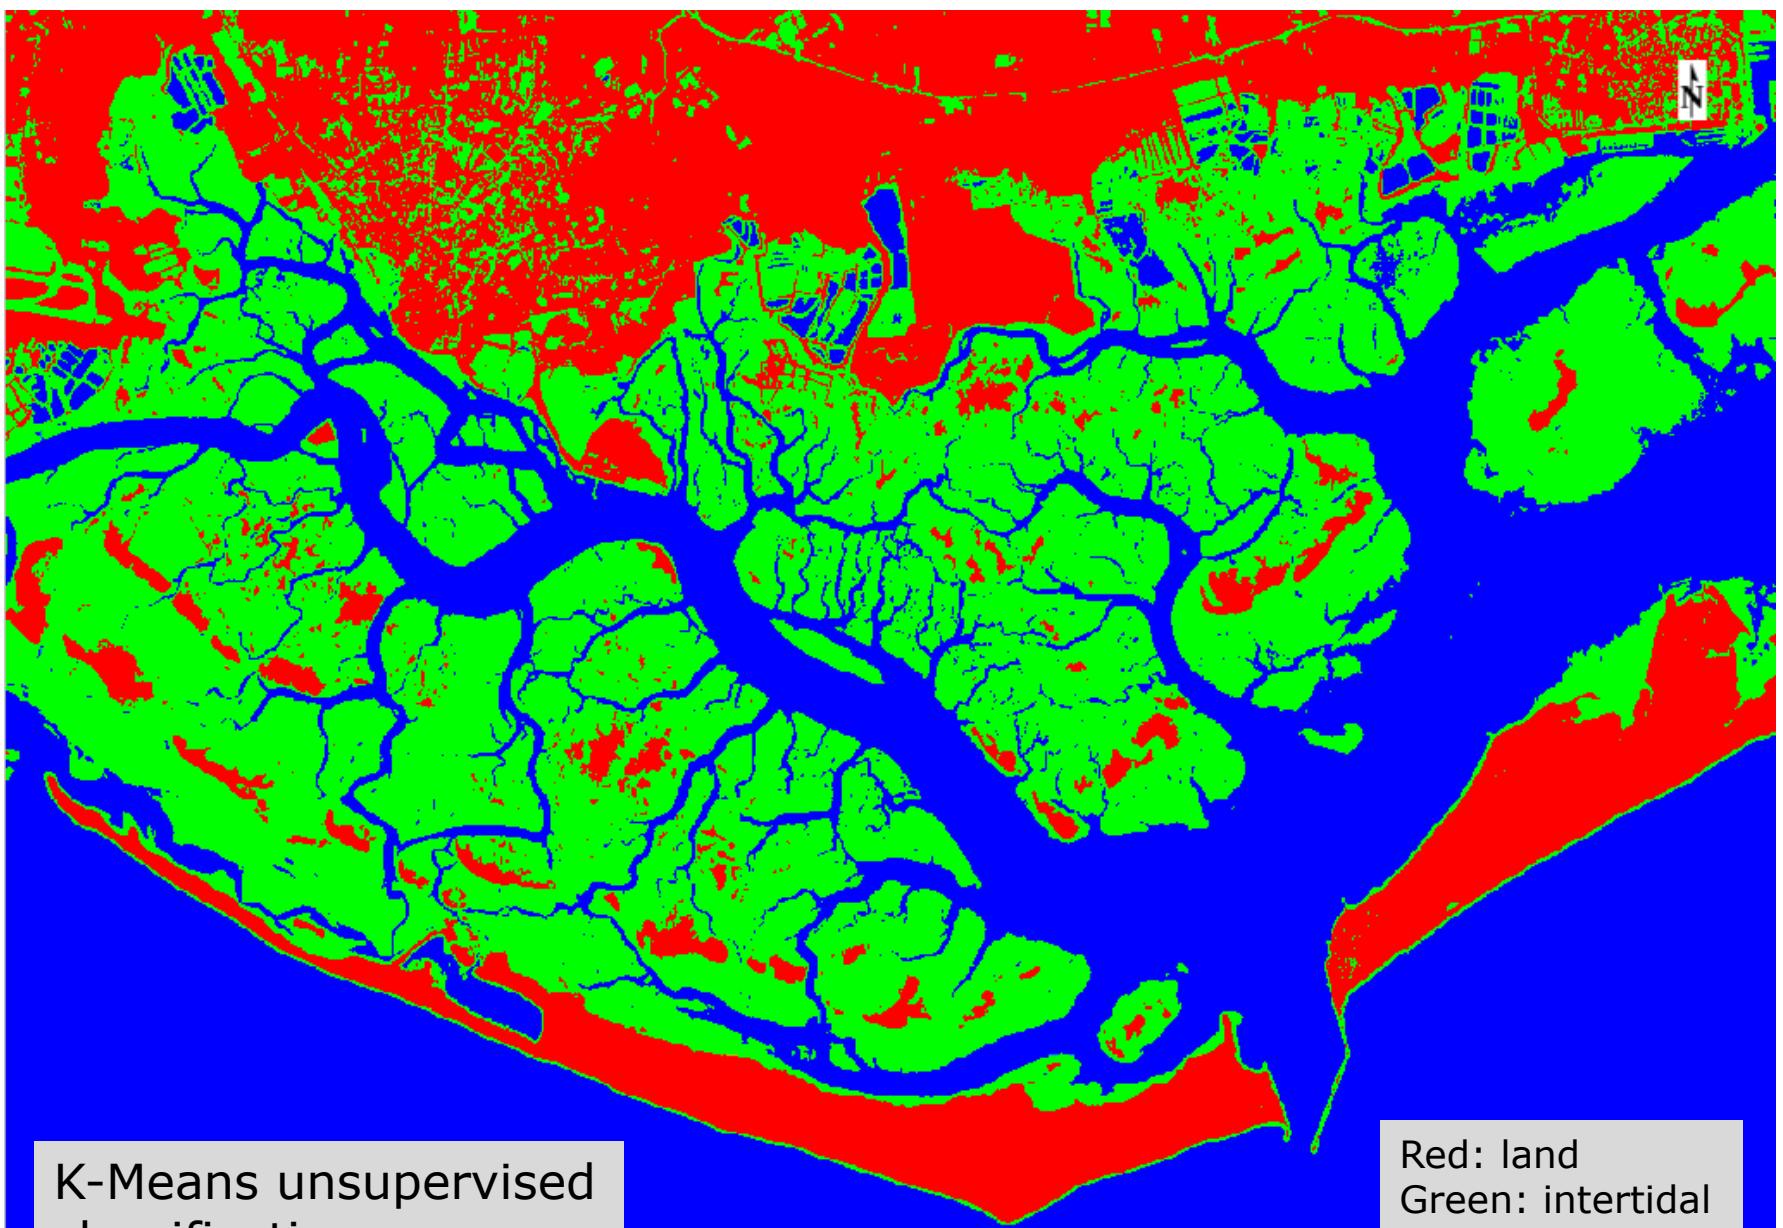


2^a Iteração



Banda 1 (media do NDWI) / banda 2 (Std do NDWI)

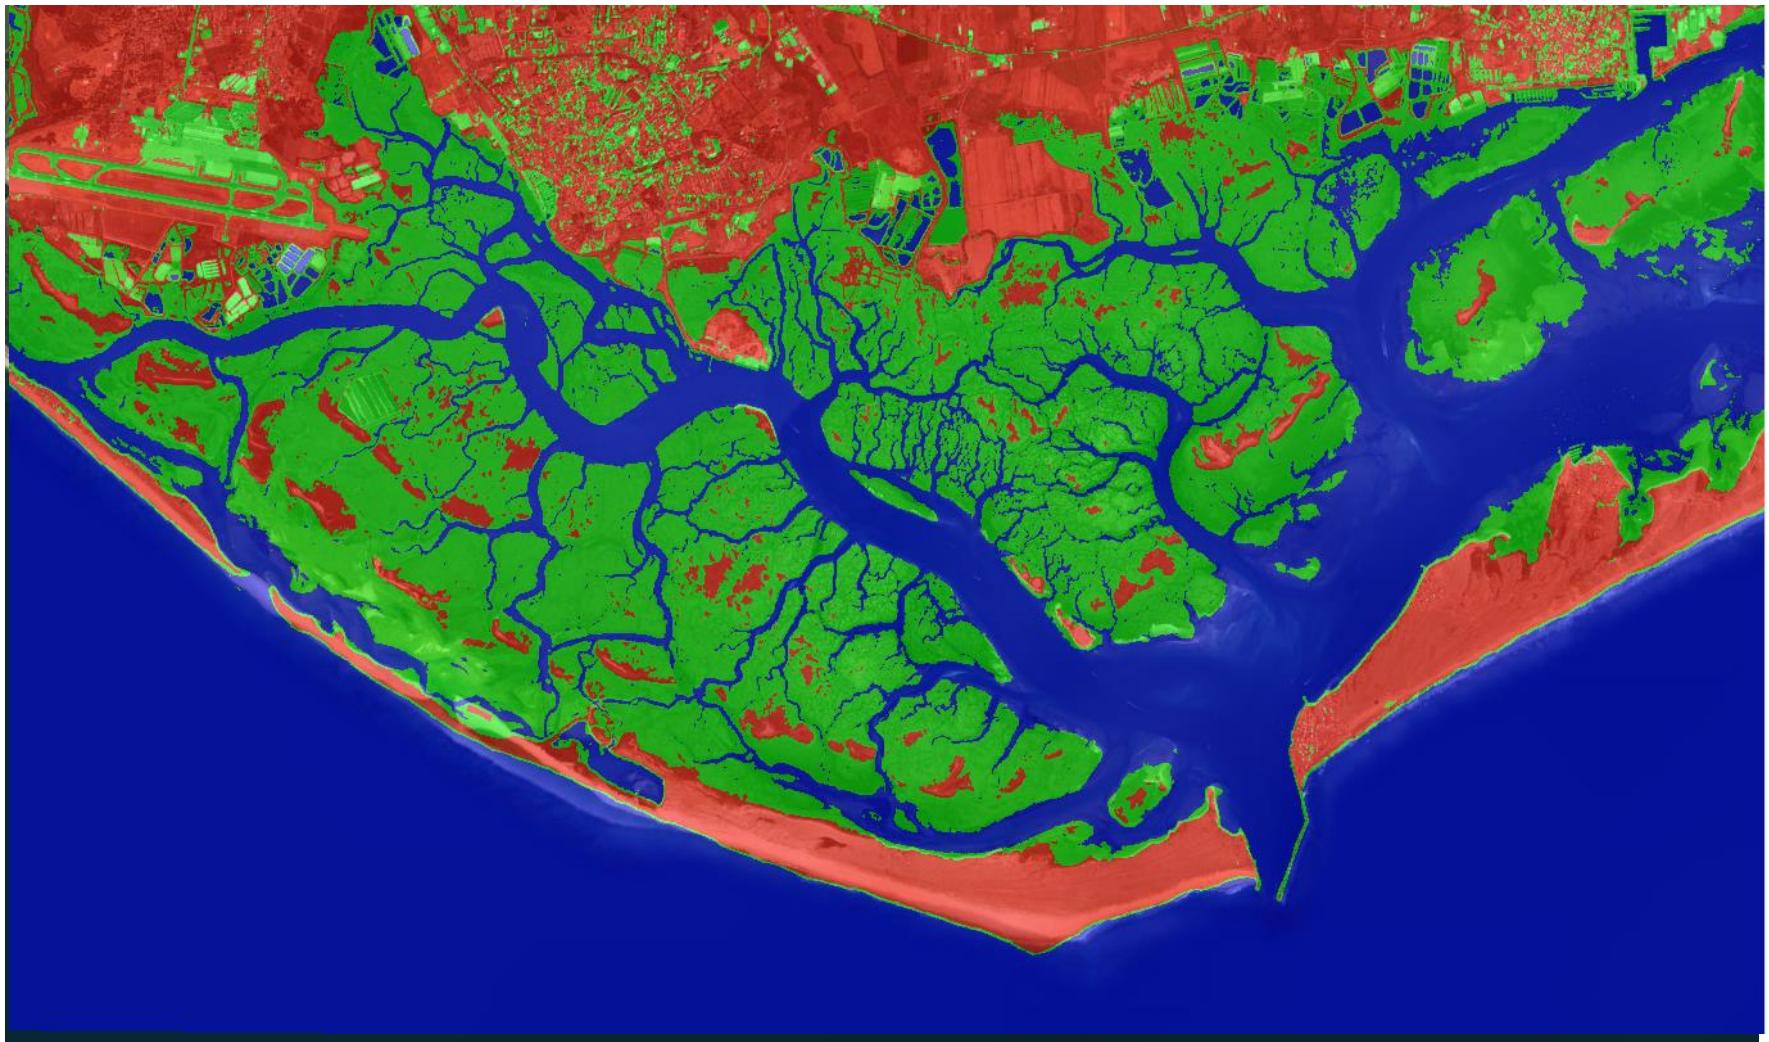




K-Means unsupervised
classification

Red: land
Green: intertidal
Blue: water

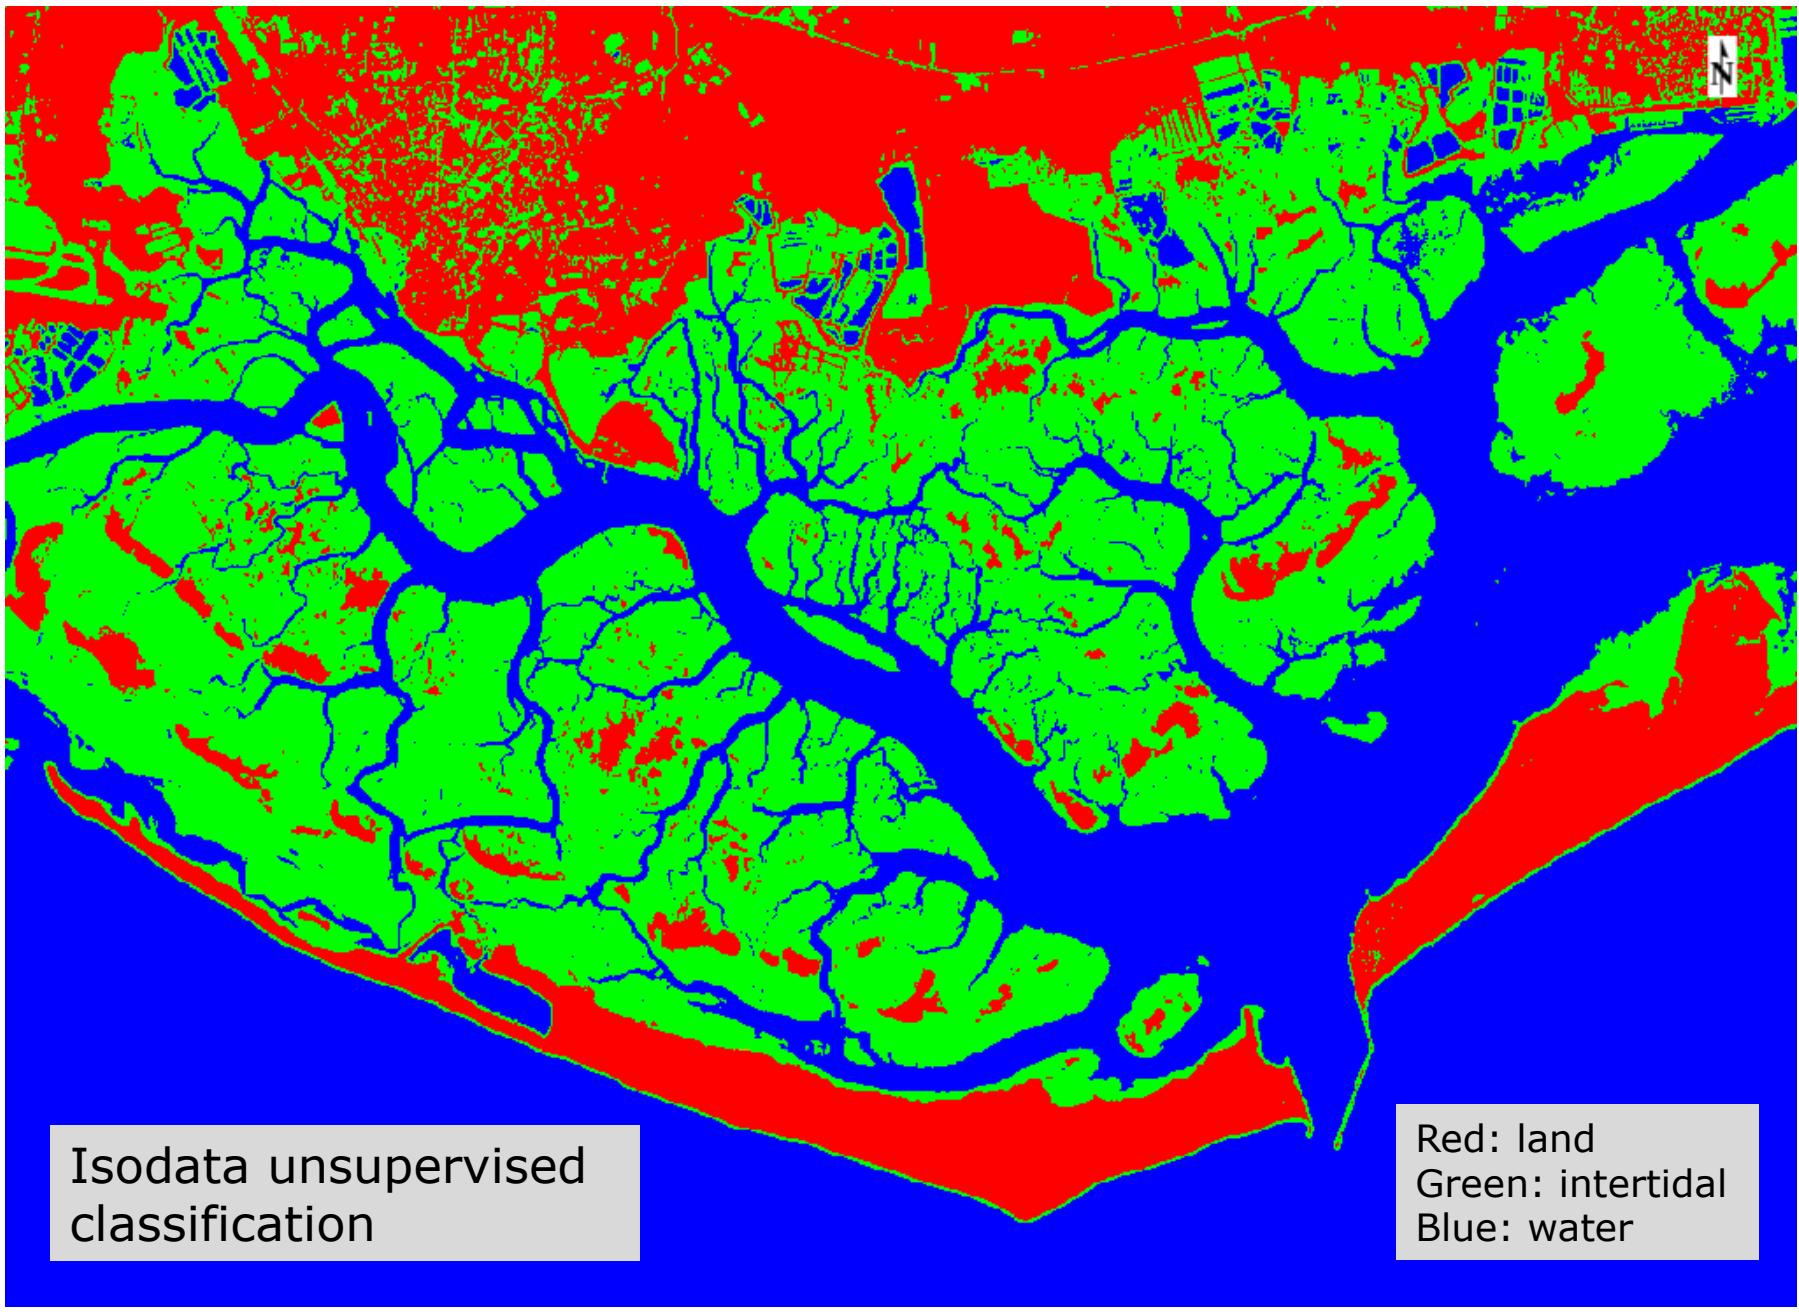
K-Means unsupervised classification



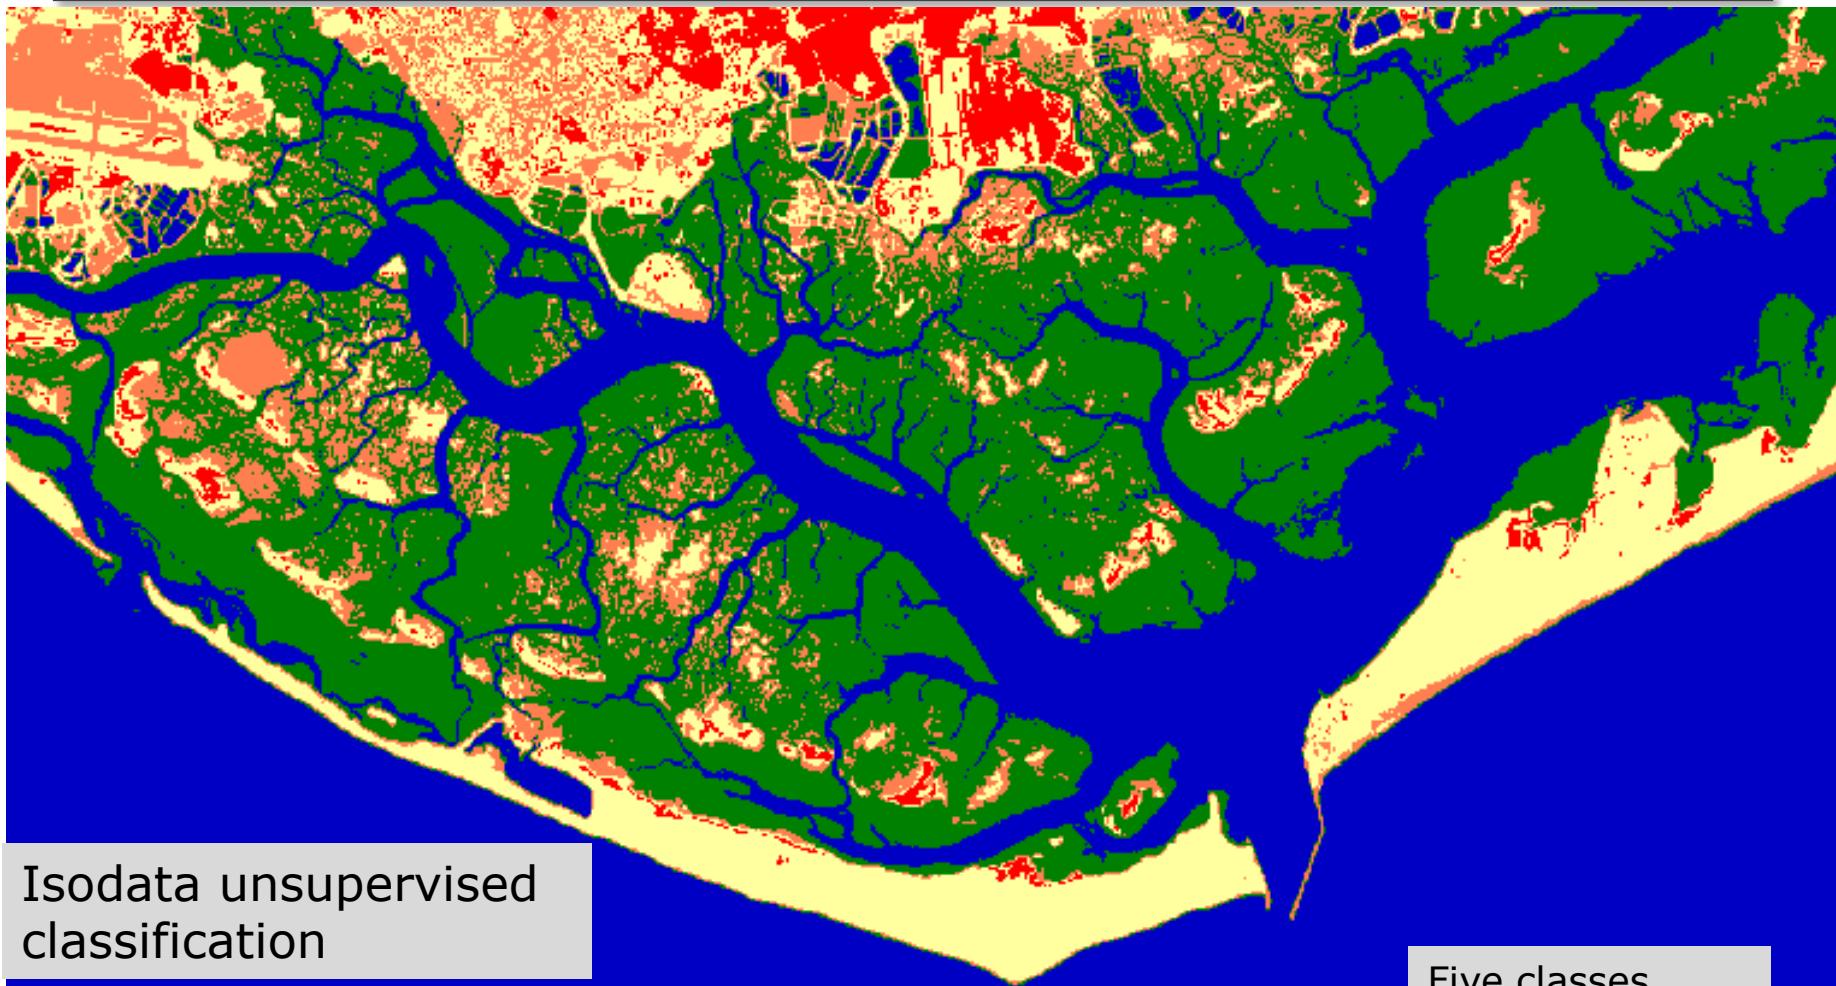
Unsupervised classification: ISODATA

ISODATA (*Iterative Self-Organizing Data Analysis Techniques*)

Idêntico ao anterior mas em que o número de clusters é automaticamente ajustado durante o processo iterativo por junção e/ou divisão de clusters com valores muito elevados do desvio padrão



ISODATA unsupervised classification



Supervised Classification

Passos na classificação supervisada

1. Escolher a legenda

Spectral Classes

Escolher os tipos de ocupação do solo nos quais a imagem será segmentada. Estas são as classes de informação e podem ser: água, região urbana, floresta, pinhal, etc..

2. Escolher os píxeis representativos de cada classe legenda

Sample data
Training data set

Estes píxeis são designados por **dados treino**. Os conjuntos de treino podem ser obtidos por visitas aos locais, mapas, fotografia aérea ou fotointerpretação de uma composição colorida dos dados imagem.



Ciências
ULisboa

Maximum Likelihood Classification



Supervised Classification

3. Usar os dados treino para estimar os parâmetros de um determinado algoritmo de classificação

Estes parâmetros serão as propriedades do modelo de probabilidades usado ou serão as equações que definem as partições no espaço multiespectral.

Os parâmetros para uma dada classe é muitas vezes referido como **assinatura (espetral)** dessa classe.

4. Classificar

Classificar cada píxel da imagem numa das classes definidas previamente (ponto 1) usando o classificador treinado. Todos os píxeis são classificados.

5. Calcular a exatidão e a tabela de confusão

(Confusion table)

Calcular a exatidão da classificação e produzir a tabela de confusão que resume os resultados da classificação.

Maximum Likelihood Classification

Máxima Verosimilhança

Bayes Classification

Representemos as classes espectrais de uma imagem por:

w_i , $i=1, \dots, M$, M número de classes

E representemos os píxeis pelo vector x :

$x = (x_1, x_2, \dots, x_N)$ Posição no espaço multiespetral

Em que x_1, x_2, \dots, x_N é o DN do píxel x nas bandas 1 a N

Maximum Likelihood Classification

Classificação de Bayes

A determinação da classe à qual um píxel na posição \mathbf{x} pertence pode ser visto como uma probabilidade condicional:

$$p(w_i | \mathbf{x}), \quad i=1,..M$$

Probabilidade de ser classe w_i dada a posição \mathbf{x}

A classificação é feita de modo que:

$$\mathbf{x} \in w_i \text{ se } p(w_i | \mathbf{x}) > p(w_j | \mathbf{x}) \text{ para todos os } j \neq i$$

Decision Rule

A pretendida $p(w_i | \mathbf{x})$ e a existente $p(\mathbf{x} | w_i)$ (estimada com dados de treino) estão relacionadas pelo Teorema de Bayes:

$$p(w_i | \mathbf{x}) = p(\mathbf{x} | w_i) \cdot p(w_i) / p(\mathbf{x})$$

Em que $p(w_i)$ é a probabilidade da classe w_i ocorrer na imagem. Se por exemplo 20% dos pixels de uma imagem pertencem à classe espectral w_i então $p(w_i) = 0.2$.

$p(\mathbf{x})$ é a probabilidade de um pixel ter uma determinada assinatura espectral \mathbf{x} . O valor de $p(x)$ é dado por:

$$p(x) = \sum_{i=1}^M p(x | w_i) p(w_i)$$

$p(x)$ não é importante na classificação.

Decision Rule

A regra de classificação pode ser escrita como:

$$\mathbf{x} \in w_i \quad \text{se} \quad p(\mathbf{x} | w_i) \cdot p(w_i) > p(\mathbf{x} | w_j) \cdot p(w_j) \text{ para todos os } j \neq i$$

Esta regra é mais interessante que a anterior uma vez que $p(\mathbf{x}|w_i)$ é conhecido dos dados treino e é aceitável que $p(w_i)$ também seja conhecido, ou pode ser estimado pelo conhecimento que temos da imagem.

Por conveniência matemática definimos

$$g_i(\mathbf{x}) = \ln \{ p(\mathbf{x}|w_i) p(w_i) \} = \ln p(\mathbf{x}|w_i) + \ln p(w_i)$$

Então a regra fica simplificada

$$\mathbf{x} \in w_i \quad \text{se} \quad g_i(\mathbf{x}) > g_j(\mathbf{x}) \text{ para todos os } j \neq i$$

$g_i(\mathbf{x})$ é referida por função discriminante

Normal multivariate classes

Assumimos que a distribuição de probabilidade para cada classe é do tipo multivariada normal. Isto é um pressuposto e não uma propriedade demonstrável das classes espectrais.

Vamos assumir que para N bandas:

$$p(\mathbf{x} | w_i) = 2\pi^{-N/2} \left| \sum_i \right|^{-1/2} e^{-\frac{1}{2}(x-m_i)^t \Sigma_i^{-1} (x-m_i)}$$

$$f_\sigma(x; \mu) = \frac{1}{\sqrt{2\pi}|\sigma|} e^{-(x-\mu)^2/2\sigma^2}.$$

Em que \mathbf{m} e Σ são o vector da média e a matriz covariância dos dados da classe w_i .

Usando a função discriminante resulta que o termo $-N/2 \ln (2\pi)$ é comum a todos os $g_i(x)$ e por isso não é discriminativo e será ignorado.

Normal multivariate classes

A função discriminante para classificação de máxima verosimilhança é então dada por:

$$g_i(x) = \ln p(w_i) - \frac{1}{2} \ln \left| \sum_i \right| - \frac{1}{2} (x - m_i)^t \Sigma_i^{-1} (x - m_i)$$

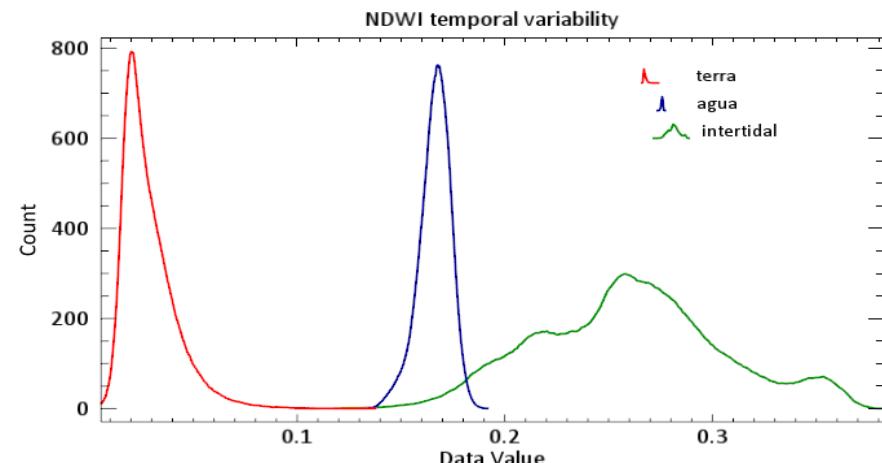
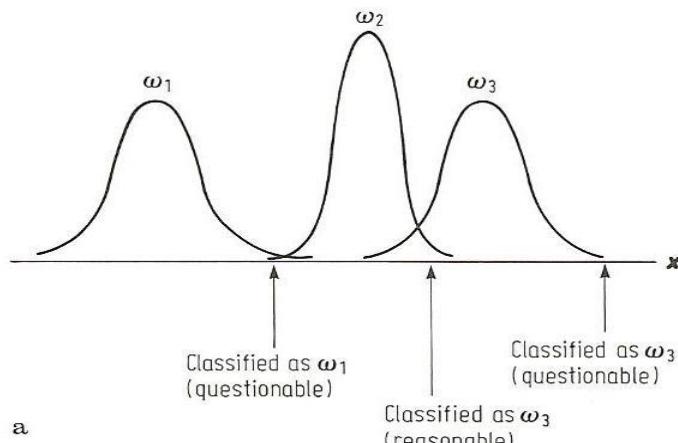
No caso de não se conhecer o valor de $p(w_i)$ deveremos assumir um valor igual para todas as classes e nesse caso como não será discriminante poderá ser excluído da equação. O mesmo pode ser feito ao valor $\frac{1}{2}$. Neste caso, a função discriminante fica:

$$g_i(x) = -\ln \left| \sum_i \right| - (x - m_i)^t \Sigma_i^{-1} (x - m_i)$$

Maximum Likelihood discriminant function

Limits

Os píxeis em qualquer ponto do espaço multiespectral serão classificados numa das classes espetrais, independentemente de quanto pequena seja a probabilidade de pertença a essa classe.



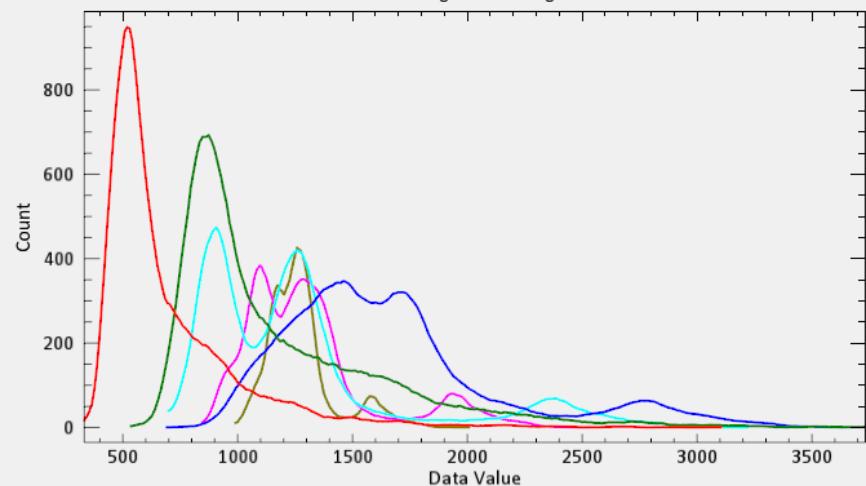
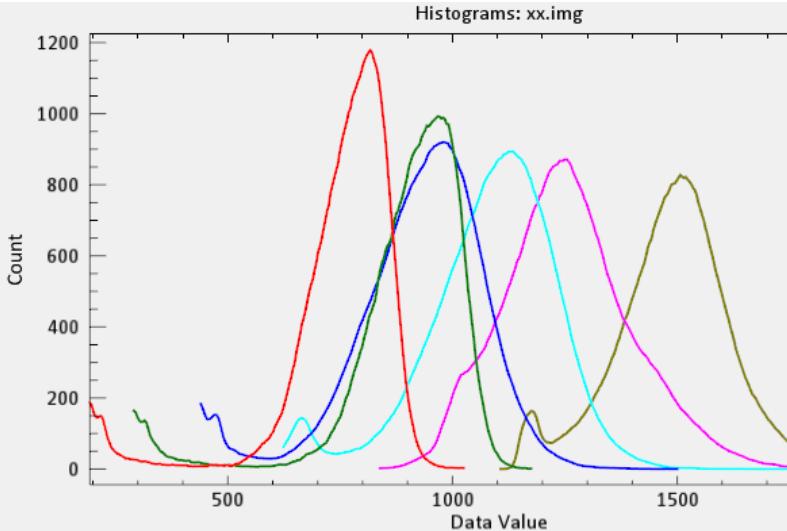
Isto pode acontecer se as classes são sobrepostas ou sabendo da existência de outras classes não dispomos de dados terreno suficientes para estimar os parâmetros da sua distribuição



Ciências
ULisboa

Maximum Likelihood Classification





X: Data Value Y: Data Value

X: Data Value Y: Data Value

Locate Stat Report Precision

aguia (aa)					
Basic Stats	Min	Max	Mean	StdDev	
Band 1	193	1027	749.51	135.02	
Band 2	291	1177	895.94	147.54	
Band 3	440	1501	927.05	148.40	
Band 4	624	1753	1087.74	145.36	
Band 5	839	1925	1258.07	143.22	
Band 6	1107	2018	1489.62	127.55	
Histogram	DN	Count	Total	Percent	Acc Pct
Band 1	193 - 196	30	30	0.05	0.05
Binsize=4	197 - 200	125	155	0.22	0.28
	201 - 204	246	401	0.44	0.71
	205 - 208	288	689	0.51	1.23
	209 - 212	260	949	0.46	1.69
	213 - 216	160	1109	0.28	1.98
	217 - 220	188	1297	0.33	2.31
	221 - 224	84	1381	0.15	2.46
	225 - 228	105	1486	0.19	2.65
	229 - 232	76	1562	0.14	2.78

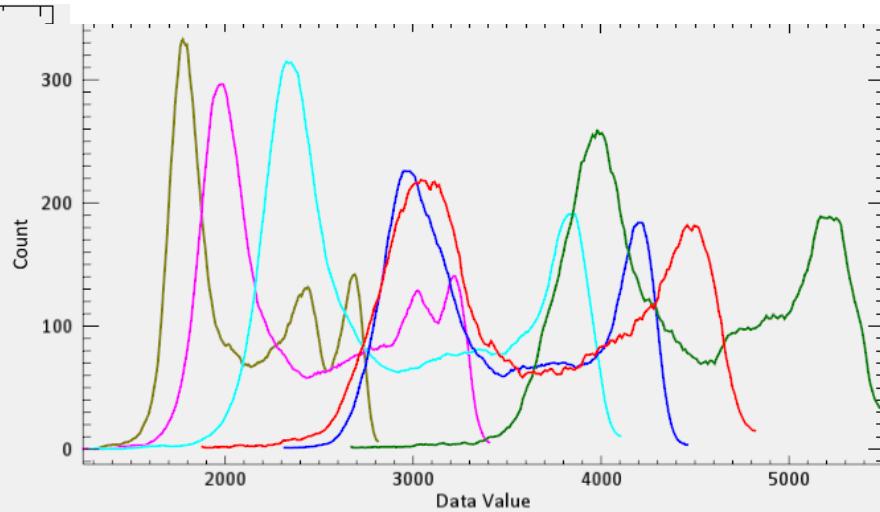
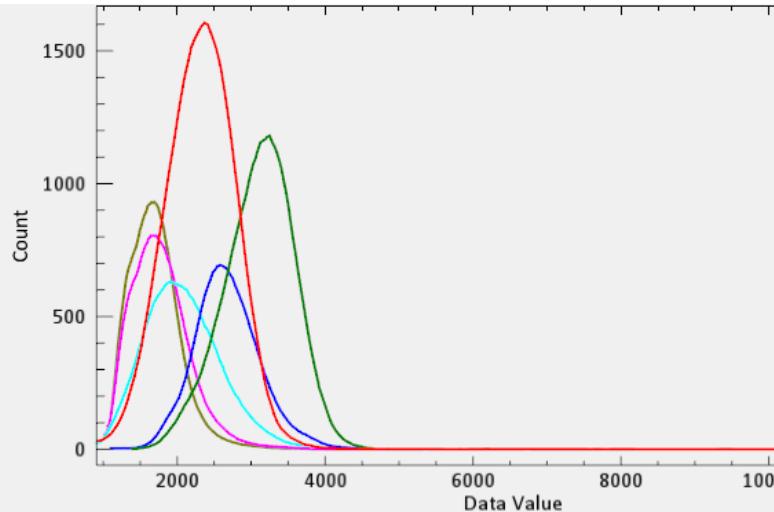
Water

Intertidal

- █ Histogram: Band 1
- █ Histogram: Band 2
- █ Histogram: Band 3
- █ Histogram: Band 4
- █ Histogram: Band 5
- █ Histogram: Band 6

Locate Stat Report Precision

Intertidal (aa)					
Basic Stats	Min	Max	Mean	StdDev	
Band 1	332	3107	698.89	297.80	
Band 2	536	3737	1182.28	455.11	
Band 3	692	3654	1676.95	492.43	
Band 4	698	3218	1275.94	467.87	
Band 5	846	2527	1310.99	291.09	
Band 6	991	2010	1277.22	149.54	
Histogram	DN	Count	Total	Percent	Acc Pct
Band 1	332 - 342	9	9	0.03	0.03
Binsize=11	343 - 353	4	13	0.02	0.05
	354 - 364	8	21	0.03	0.08
	365 - 375	24	45	0.09	0.17
	376 - 386	28	73	0.11	0.28
	387 - 397	16	89	0.06	0.35
	398 - 408	49	138	0.19	0.54
	409 - 419	125	263	0.49	1.02
	420 - 430	179	442	0.70	1.72
	431 - 441	241	683	0.94	2.66
	442 - 452	463	1146	1.80	4.46



Locate Stat ▾ Report Precision ▾

terra (aa)					
Basic Stats	Min	Max	Mean	StdDev	
Band 1	930	12207	2346.32	480.61	
Band 2	1395	9494	3126.68	479.18	
Band 3	1101	5307	2689.03	448.60	
Band 4	909	5512	2093.00	522.50	
Band 5	1014	5520	1788.89	401.38	
Band 6	1061	5500	1713.21	346.06	
Histogram	DN	Count	Total	Percent	Acc Pct
Band 1	930 - 974	20	20	0.05	0.05
Binsize=45	975 - 1019	16	36	0.04	0.09
	1020 - 1064	40	76	0.09	0.18
	1065 - 1109	28	104	0.07	0.25
	1110 - 1154	20	124	0.05	0.29
	1155 - 1199	52	176	0.12	0.42
	1200 - 1244	59	235	0.14	0.56
	1245 - 1289	76	311	0.18	0.74
	1290 - 1334	115	426	0.27	1.01
	1335 - 1379	140	566	0.33	1.34

Land

Sand (beach)

Locate Stat ▾ Report Precision ▾

areaia					
Basic Stats	Min	Max	Mean	StdDev	
Band 1	1879	4823	3622.46	656.10	
Band 2	2672	5512	4465.34	572.53	
Band 3	2316	4459	3458.32	519.28	
Band 4	1283	4109	2917.51	628.17	
Band 5	1244	3406	2430.99	493.78	
Band 6	1250	2811	2094.44	351.57	
Histogram	DN	Count	Total	Percent	Acc Pct
Band 1	1879 - 1890	4	4	0.02	0.02
Binsize=12	1891 - 1902	0	4	0.00	0.02
	1903 - 1914	0	4	0.00	0.02
	1915 - 1926	0	4	0.00	0.02
	1927 - 1938	4	8	0.02	0.04
	1939 - 1950	4	12	0.02	0.06
	1951 - 1962	0	12	0.00	0.06
	1963 - 1974	0	12	0.00	0.06
	1975 - 1986	0	12	0.00	0.06
	1987 - 1998	0	12	0.00	0.06
	1999 - 2010	0	12	0.00	0.06

- █ Histogram: Band 1
- █ Histogram: Band 2
- █ Histogram: Band 3
- █ Histogram: Band 4
- █ Histogram: Band 5
- █ Histogram: Band 6

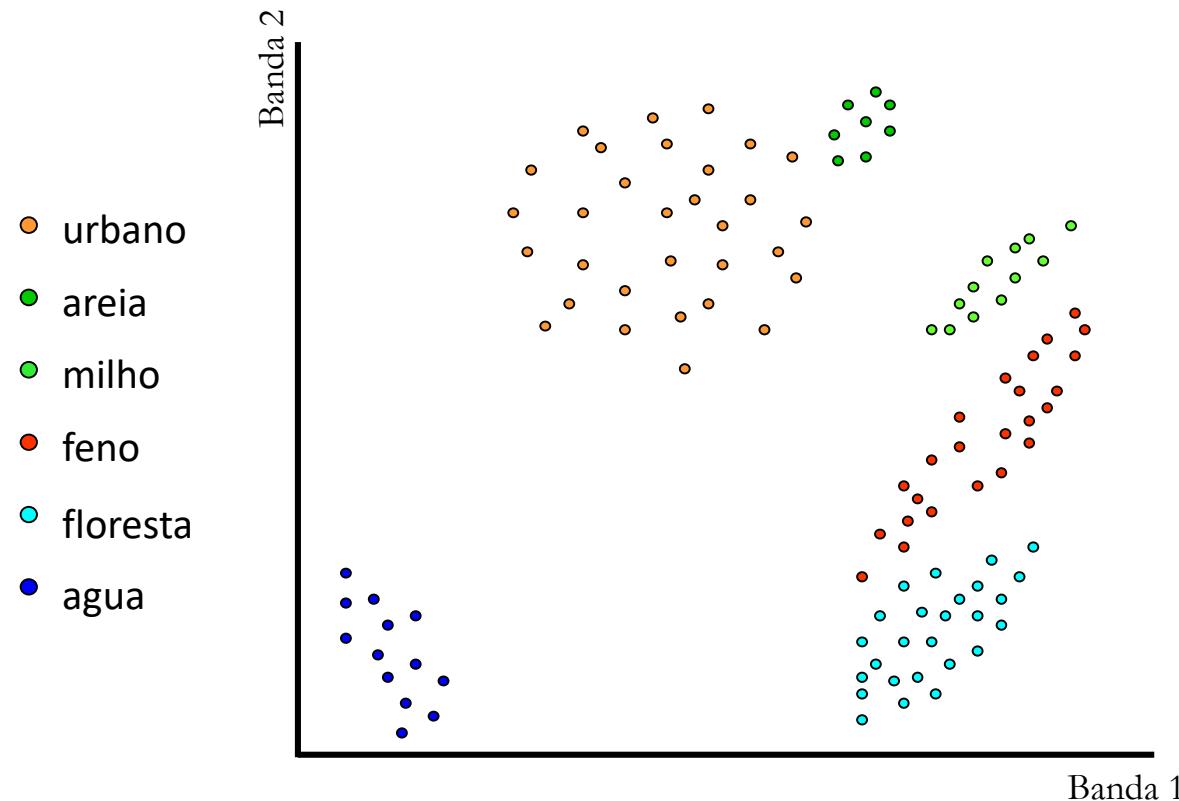
Maximum Likelihood Classification



$$g_i(x) = -\ln \left| \sum_i \right| - (x - m_i)^t \Sigma_i^{-1} (x - m_i)$$

Exemplo

Por simplicidade consideremos uma imagem com duas bandas.



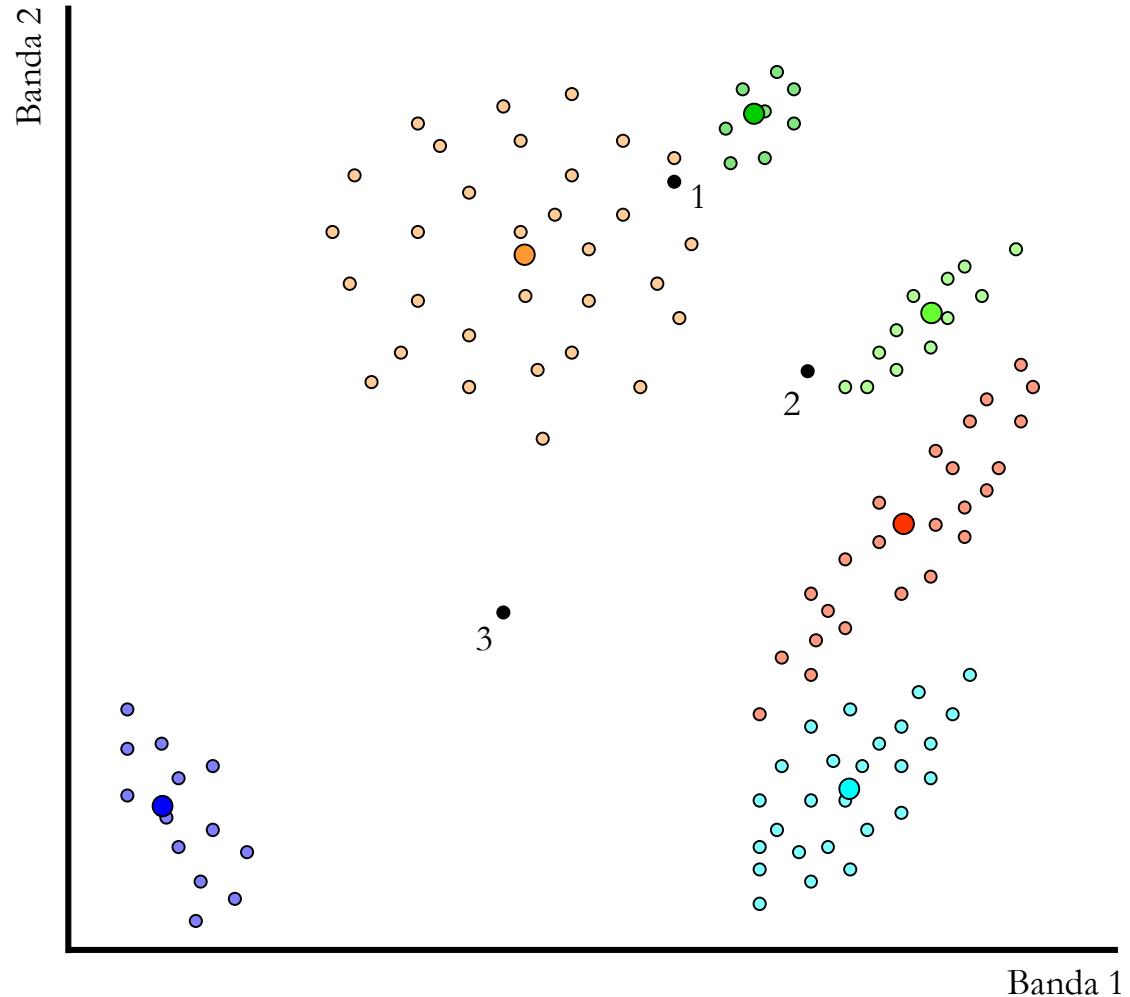
Foram recolhidos dados treino para 6 classes homogéneas. Todos os pontos da mesma cor representam as componentes do vector das amostras obtidas usando os *dados treino* referidos a um padrão.

Exemplo

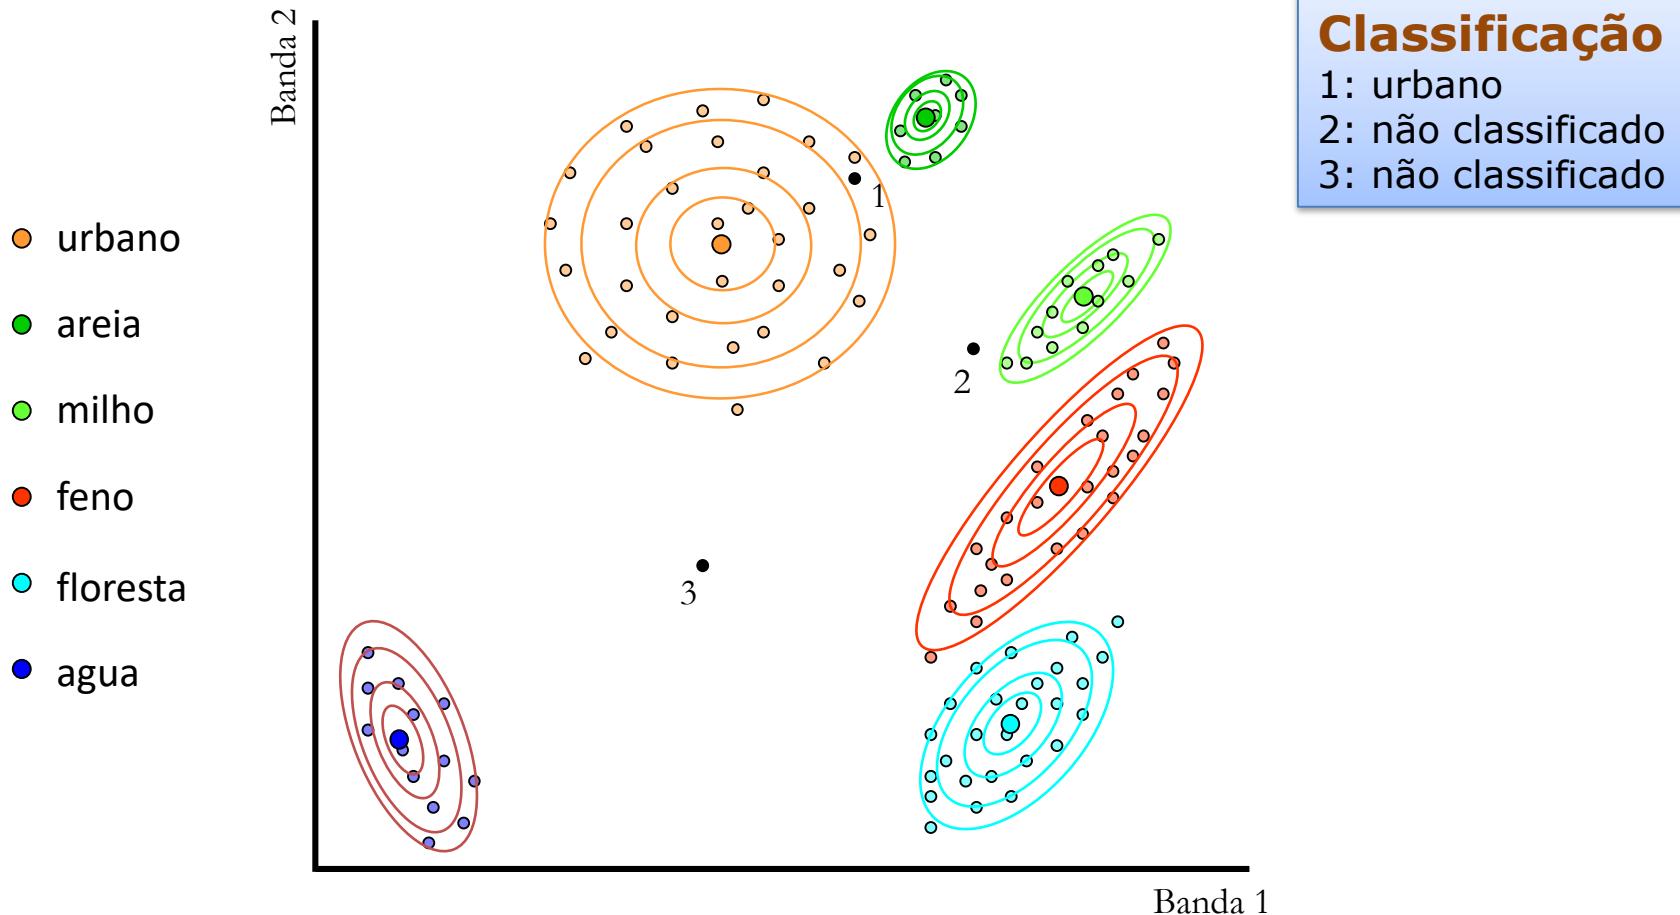
Pretendem-se
classificar os
pontos 1,2,3

- urbano
- areia
- milho
- feno
- floresta
- agua

São representados os valores
médios de cada classe
(círculos maiores).



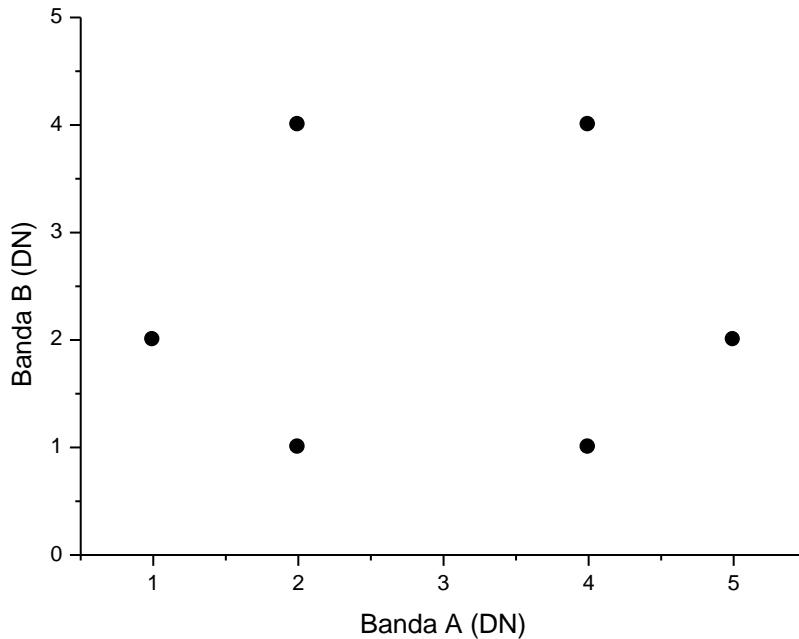
Maximum Likelihood



Exemplo

Determine o vetor da média, a função covariância e correlação

Conjunto de píxeis de uma classe



Banda A	Banda B
1	2
2	1
4	1
5	2
4	4
2	4

Ex. 6.1 Richards and Jia

$$M = \begin{bmatrix} 3.0 \\ 2.33 \end{bmatrix} \quad m = \frac{1}{k} \sum_{i=1}^k x_i$$

$$\Sigma_x = \frac{1}{k-1} \cdot \sum_{i=1}^k (x_i - m) \cdot (x_i - m)^t \quad \text{Covarianz der bands}$$

x	$(x - m)$	$(x - m) \cdot (x - m)^t$
$\begin{bmatrix} 1 \\ 2 \end{bmatrix}$	$\begin{bmatrix} +2.0 \\ -0.33 \end{bmatrix}$	$\begin{bmatrix} 4.0 & 0.66 \\ 0.66 & 0.11 \end{bmatrix}$
$\begin{bmatrix} 2 \\ 1 \end{bmatrix}$	$\begin{bmatrix} -1.0 \\ -1.33 \end{bmatrix}$	$\begin{bmatrix} 1.0 & 1.33 \\ 1.33 & 1.77 \end{bmatrix}$
\vdots		
$\begin{bmatrix} 2 \\ 4 \end{bmatrix}$	$\begin{bmatrix} -1.0 \\ 1.67 \end{bmatrix}$	$\begin{bmatrix} 1.0 & -1.67 \\ -1.67 & 2.79 \end{bmatrix}$

Soma das matrizes

$$\Sigma_x = \begin{bmatrix} 2.4 & 0 \\ 0 & 1.87 \end{bmatrix}$$

Banda A Banda B

1	2
2	1
4	1
5	2
4	4
2	4

$$\begin{array}{c}
 \alpha \\
 \hline
 \begin{bmatrix} 1 \\ 2 \\ 1 \\ \vdots \\ 2 \\ 4 \end{bmatrix} \\
 \begin{bmatrix} -2.0 \\ -0.33 \\ -1.0 \\ -1.33 \\ -1.0 \\ 1.67 \end{bmatrix} \\
 \begin{bmatrix} 4.0 & 0.66 \\ 0.66 & 0.11 \\ 3.0 & 1.33 \\ 1.33 & 1.77 \\ 1.0 & -1.67 \\ -1.67 & 2.79 \end{bmatrix}
 \end{array}$$

Soma das matrizes

$$\sum_{\alpha} = \begin{bmatrix} 2.4 & 0 \\ 0 & 1.87 \end{bmatrix}$$

A matriz correlação é calculada como $r_{ij} = c_{ij} / \sqrt{c_{ii} c_{jj}}$

ou seja: $r_{11} = 2.4 / \sqrt{2.4 \times 2.4} = 2.4 / 2.4 = 1.0$

$$r_{12} = r_{21} = 0$$

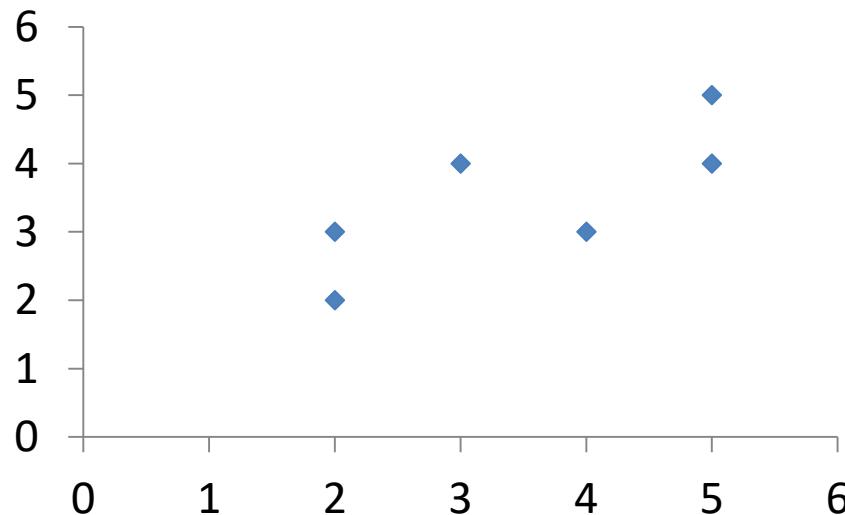
$$r_{22} = 1.87 / \sqrt{1.87 \times 1.87} = 1.0$$

$$R = \begin{bmatrix} 1.0 & 0 \\ 0 & 1.0 \end{bmatrix}$$

Não há correlações entre as bandas

Exemplo

Determine o vetor da média, a função covariância e correlação



Banda A	Banda B
2	2
2	3
4	3
3	4
5	4
5	5

$$\bar{m} = \begin{bmatrix} 3,5 \\ 3,5 \end{bmatrix} \quad \bar{m} = \frac{1}{k} \sum_{i=1}^k m_i$$

$$\sum_s = \frac{1}{k-1} \sum_{i=1}^k (m_i - \bar{m}) \cdot (m_i - \bar{m})^t \quad \text{Covariance} \rightarrow \text{bands}$$

Pixel 1

x	$(x - \bar{m})$	$(x - \bar{m})(x - \bar{m})^t$
$\begin{bmatrix} 2 \\ 2 \end{bmatrix}$	$\begin{bmatrix} -1.5 \\ -1.5 \end{bmatrix}$	$\begin{bmatrix} 2.25 & 2.25 \\ 2.25 & 2.25 \end{bmatrix}$

$\begin{bmatrix} 2 \\ 3 \end{bmatrix}$	$\begin{bmatrix} -1.5 \\ -0.5 \end{bmatrix}$	$\begin{bmatrix} 2.25 & 0.75 \\ 0.75 & 0.25 \end{bmatrix}$
--	--	--

$\begin{bmatrix} 4 \\ 3 \end{bmatrix}$	$\begin{bmatrix} 0.5 \\ -0.5 \end{bmatrix}$	$\begin{bmatrix} 0.25 & -0.25 \\ -0.25 & 0.25 \end{bmatrix}$
--	---	--

$\begin{bmatrix} 3 \\ 4 \end{bmatrix}$	$\begin{bmatrix} -0.5 \\ 0.5 \end{bmatrix}$	$\begin{bmatrix} 0.25 & -0.25 \\ -0.25 & 0.25 \end{bmatrix}$
--	---	--

$\begin{bmatrix} 5 \\ 4 \end{bmatrix}$	$\begin{bmatrix} 1.5 \\ 0.5 \end{bmatrix}$	$\begin{bmatrix} 2.25 & 0.75 \\ 0.75 & 0.25 \end{bmatrix}$
--	--	--

$\begin{bmatrix} 5 \\ 5 \end{bmatrix}$	$\begin{bmatrix} 1.5 \\ 1.5 \end{bmatrix}$	$\begin{bmatrix} 2.25 & 2.25 \\ 2.25 & 2.25 \end{bmatrix}$
--	--	--

$$\frac{1}{k-1} \cdot \sum_{i=1}^k (\downarrow) = \begin{bmatrix} 1.9 & 1.1 \\ 1.1 & 1.1 \end{bmatrix}$$

Covariance $R = \begin{bmatrix} 1 & 0.76 \\ 0.76 & 1 \end{bmatrix}$

A covariance entre bands
é 76%.

Banda A	Banda B
2	2
2	3
4	3
3	4
5	4
5	5

Maximum Likelihood classification

Classe 1		Classe 2		Classe 3	
Banda A	Banda B	Banda A	Banda B	Banda A	Banda B
16	13	8	8	19	6
18	13	9	7	19	3
20	13	6	7	17	8
11	12	8	6	17	1
17	12	5	5	16	4
8	11	7	5	14	5
14	11	4	4	13	8
10	10	6	3	13	1
4	9	4	2	11	6
7	9	3	2	11	3

Determine a função discriminante para o classificador da máxima verosimilhança

e classifique os pixéis:

P1 (5,9)

P2 (9,8)

P3(15, 9)

Ver matlab: mv01.m

Exercício Máximo Verossimilhança
(pag 246, Richards and Jrc)

Função discriminante: $g_i(x) = -\ln |\Sigma_i| - (x - m_i)^T \Sigma_i^{-1} (x - m_i)$

$i \in \text{classes}$

$x \in \omega_i$ se $g_i(x) > g_j(x) \quad \forall j$

m_i e Σ_i são o valor médio e a covariância dos dados treino da classe ω_i :

Classe 1

$$m = \begin{bmatrix} 12.5 \\ 11.3 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 28.05 & 7.38 \\ 7.38 & 2.4 \end{bmatrix}$$

$$|\Sigma| = 14.29$$

Classe 2

$$m = \begin{bmatrix} 6.0 \\ 4.9 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 4.0 & 3.4 \\ 3.4 & 4.5 \end{bmatrix}$$

$$|\Sigma| = 6.31$$

Classe 3

$$m = \begin{bmatrix} 15.0 \\ 4.8 \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} 9.1 & -0.1 \\ -0.1 & 6.5 \end{bmatrix}$$

$$|\Sigma| = 59.2$$

$P_{ixel}(5,9)$ $P_{ixel}(9,8)$

$$g_1(9,8) = -14.196$$

$$g_2(9,8) = -4.262$$

$$g_3(9,8) = -9.83$$

$$g_2(9,8) > g_3(9,8) > g_1(9,8)$$

$\therefore P_{ixel}(9,8) \in \text{classe 2}$

 $P_{ixel}(15,9)$

$$g_1(15,9) = +20$$

$$g_2(15,9) = -30$$

$$g_3(15,9) = -7.1$$

$$g_1(15,9) > g_3(15,9) > g_2(15,9)$$

$\therefore P_{ixel}(15,9) \in \text{classe 3}$

Minimum Distance

A qualidade do classificador da máxima verosimilhança depende da exactidão na determinação do vector da média e da função covariância para cada classe espectral.

Esta determinação é dependente de ter um suficiente número de dados treino para cada uma dessas classes.

Quando não dispomos de um numero suficiente de dados para treino é preferível usar um classificador que não requeira uma função covariância mas que dependa apenas da posição média das classes espetrais. A média é sempre mais bem determinada que a covariância.



O classificador da distancia mínima satisfaz este requisito.

(distancia mínima ao valor médio da classe)

Classificador Distância Mínima

Assumindo m_i ($i=1,..M$) como o valor médio de cada classe, determinado de dados treino, e \mathbf{x} a posição do pixel a ser classificado.

Calculamos o conjunto de distâncias euclidianas:

$$d(\mathbf{x}, m_i)^2 = (\mathbf{x} - m_i)^t (\mathbf{x} - m_i) \quad i=1,..M$$

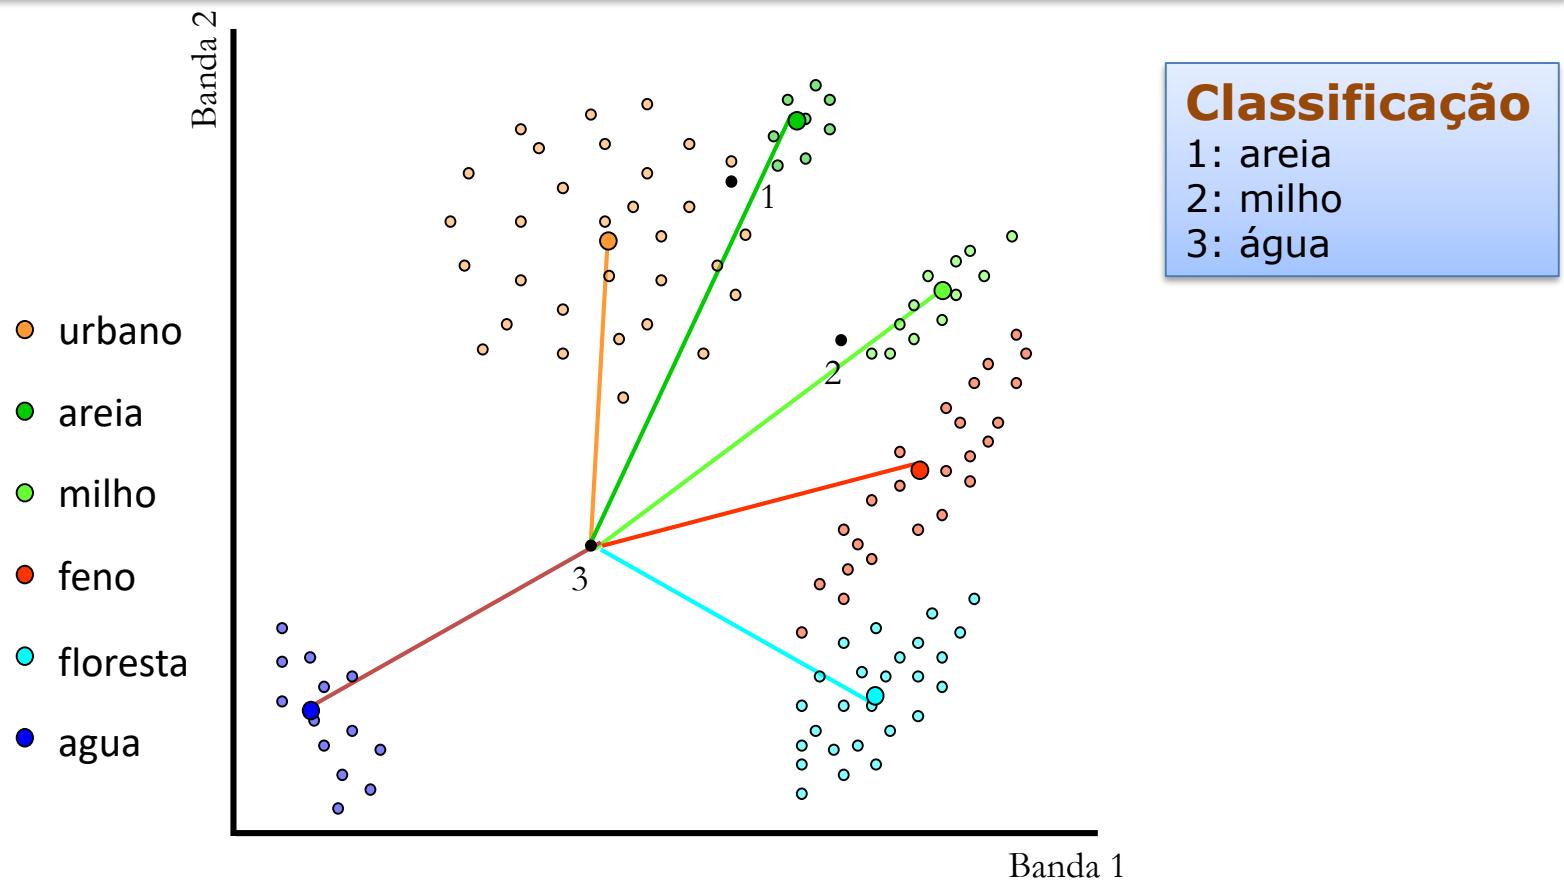
Expandindo o produto dá:

$$d(\mathbf{x}, m_i)^2 = \mathbf{x} \cdot \mathbf{x} - 2m_i \cdot \mathbf{x} + m_i \cdot m_i$$

A classificação é realizada na base de que:

$$\mathbf{x} \in w_i \text{ se } d(x, m_i)^2 < d(x, m_j)^2 \text{ para todo } j \neq i$$

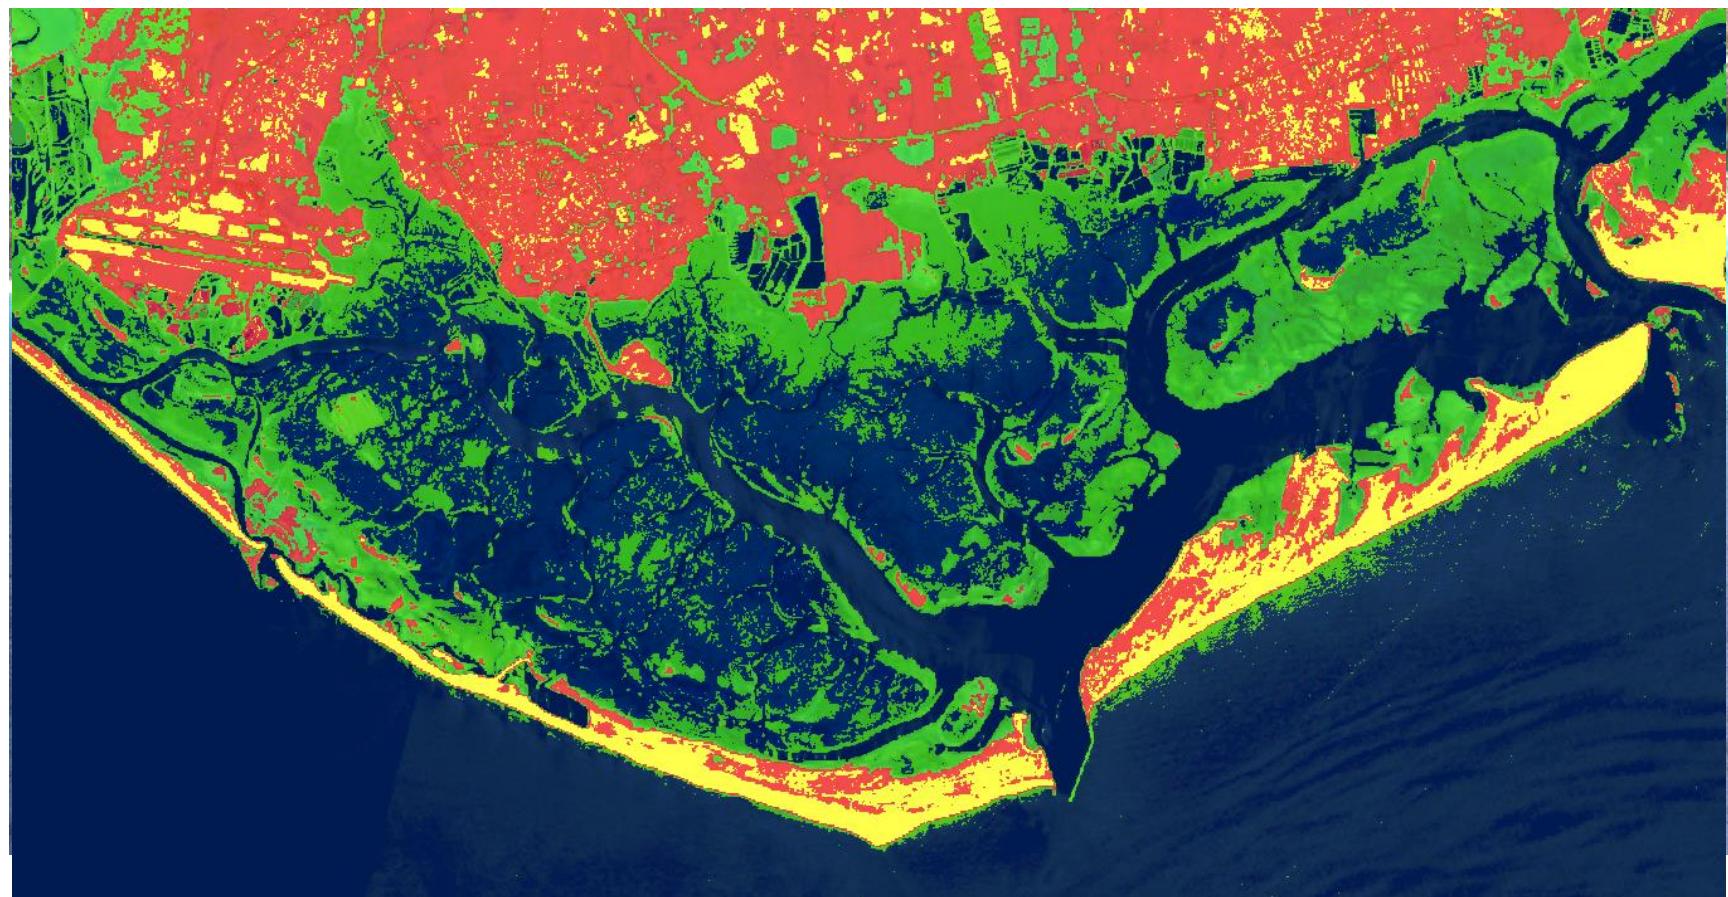
Classificador Distância Minima



Desvantagem: a associação dum pixel ao padrão mais perto poderia introduzir efeitos desagradáveis como por exemplo associar um pixel ao padrão mais perto mas que é bastante “afastado” e portanto com um valor radiométrico (DN) bastante diferente.



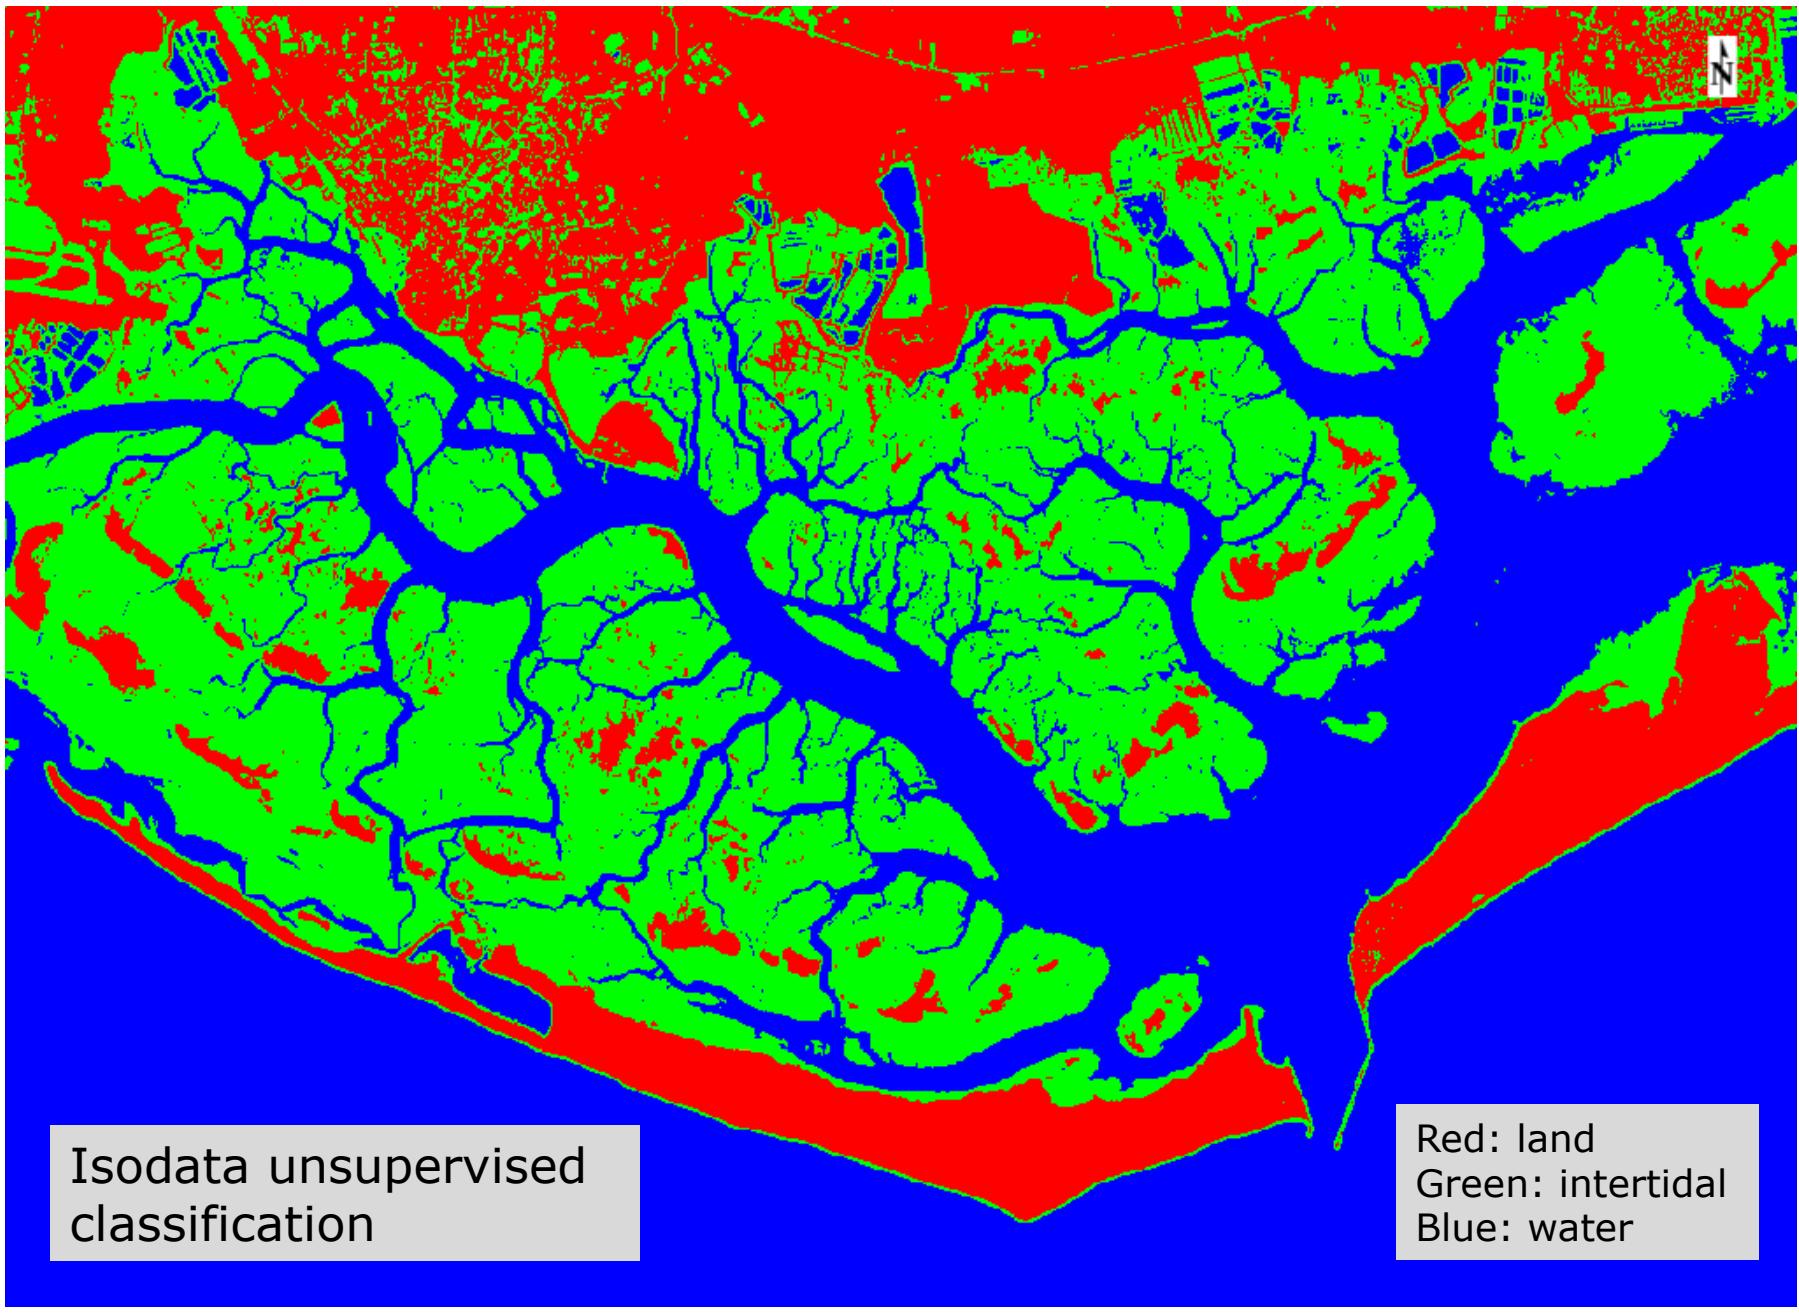
Minimum Distance



Maximum Likelihood Classification



$$g_i(x) = -\ln \left| \sum_i \right| - (x - m_i)^t \Sigma_i^{-1} (x - m_i)$$



Mahalanobis Classifier

Consideremos agora o caso em que todas as covariâncias são iguais $\Sigma_i = \Sigma$ para todo o i . O termo $\ln \Sigma_i$ deixa de ser discriminante e podemos eliminá-lo. A distância fica reduzida a:

$$d(x, m_i)^2 = (x - m_i)^t \Sigma^{-1} (x - m_i)$$

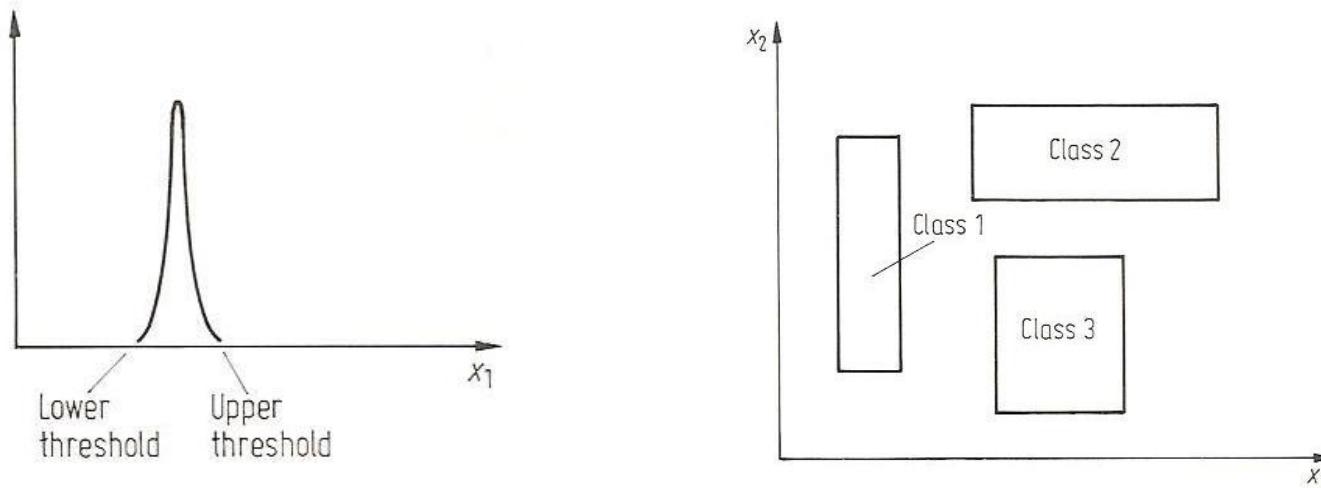
Este é o classificador **distância Mahalanobis**. (raiz quadrada da equação anterior)

Assumindo um constrangimento adicional em que $\Sigma = \sigma^2 I$ o classificador Mahalanobis reduz-se a um classificador de distância mínima.

A vantagem do classificador de Mahalanobis sobre a máxima verosimilhança é que é mais rápido e mantém algum grau na sensibilidade à direcção através da função covariância Σ que pode ser uma covariância média de todas as classes ou um modelo.

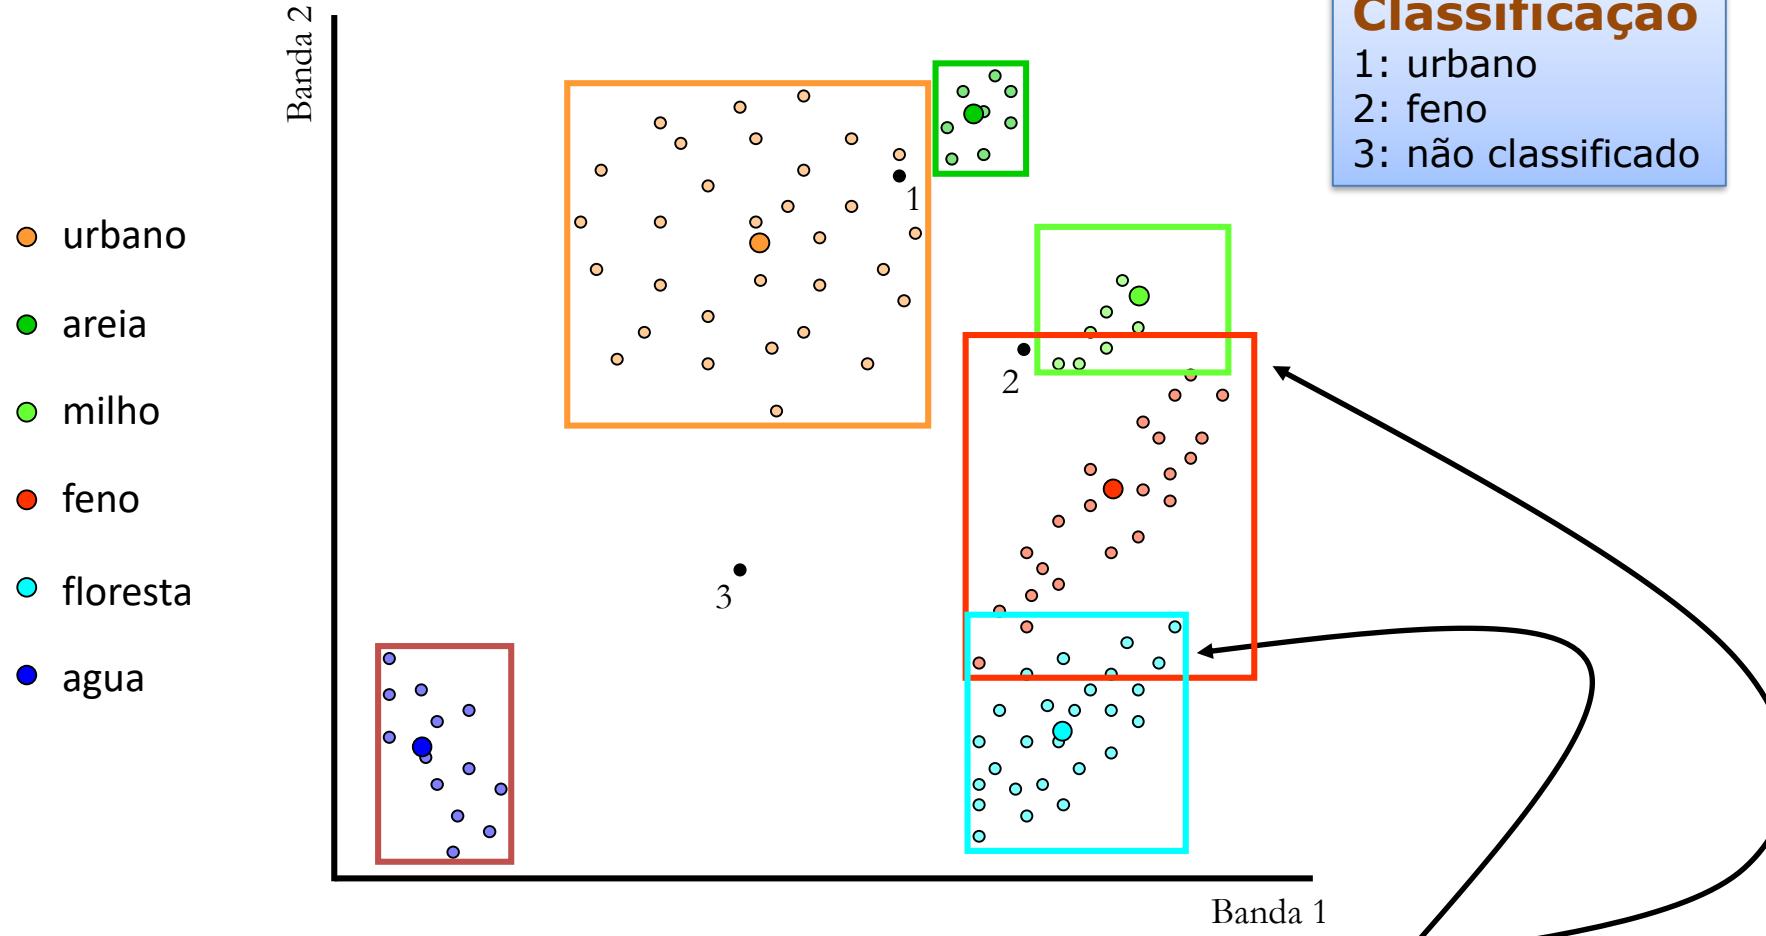
Classificador Paralelepípedo

O classificador do paralelepípedo é treinado por análise dos histogramas de componentes espectrais com base nos dados treino



Histograma das componentes bidimensionais de dados treino corresponde a uma única classe espectral. Os limites inferiores e superiores são identificados como os vértices e um paralelepípedo.

Parallelepipiped Classifier



Desvantagem: nem sempre é possível classificar um pixel de maneira unívoca.

Exemplo (distância mínima)

Classe 1		Classe 2		Classe 3	
Banda A	Banda B	Banda A	Banda B	Banda A	Banda B
16	13	8	8	19	6
18	13	9	7	19	3
20	13	6	7	17	8
11	12	8	6	17	1
17	12	5	5	16	4
8	11	7	5	14	5
14	11	4	4	13	8
10	10	6	3	13	1
4	9	4	2	11	6
7	9	3	2	11	3

Determine a função discriminante para o classificador da distância mínima

e classifique os pixels:

P1 (5,9)

P2 (9,8)

P3(15, 9)

Exemplo (Paralelepípedo)

Classe 1		Classe 2		Classe 3	
Banda A	Banda B	Banda A	Banda B	Banda A	Banda B
16	13	8	8	19	6
18	13	9	7	19	3
20	13	6	7	17	8
11	12	8	6	17	1
17	12	5	5	16	4
8	11	7	5	14	5
14	11	4	4	13	8
10	10	6	3	13	1
4	9	4	2	11	6
7	9	3	2	11	3

Diga os limites
do classificador
paralelepípedo

e classifique os
pixels:

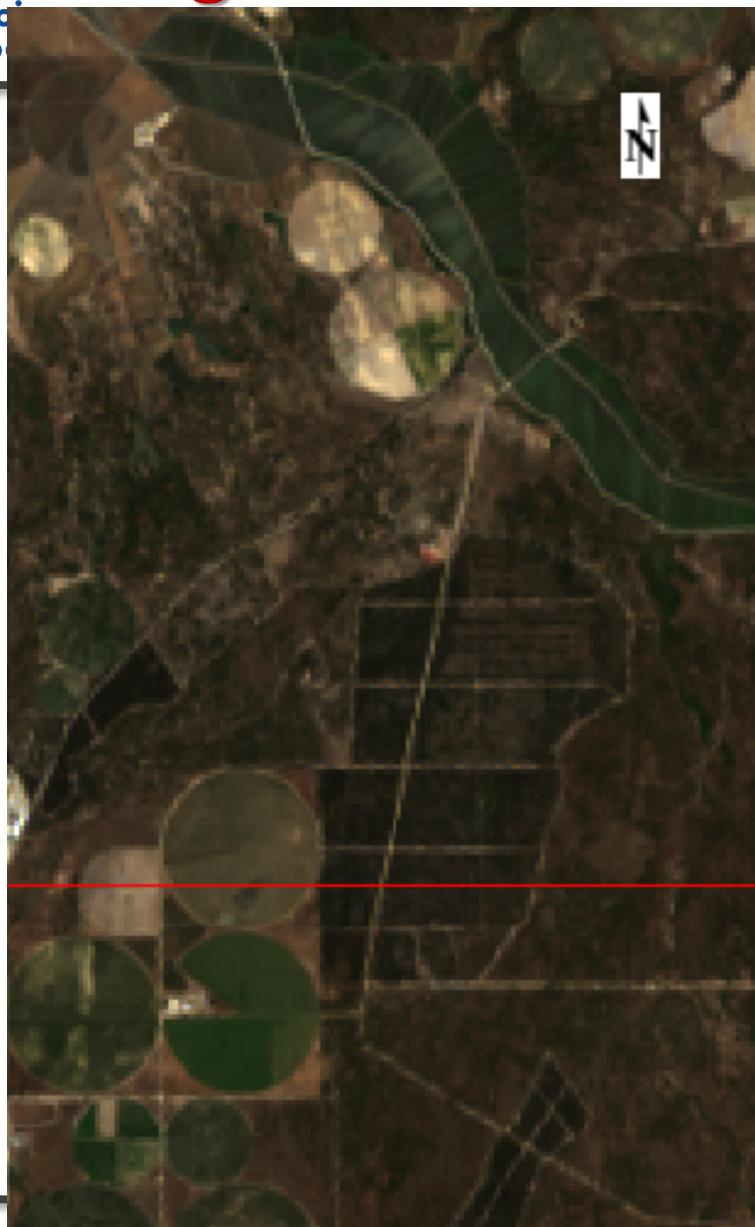
P1 (5,9)

P2 (9,8)

P3(15, 9)

P4 (3,7)

Algoritmos de Classificação do ENVI



Toolbox

Search the toolbox

/Classification/Supervised Classification

Favorites

Anomaly Detection

Band Algebra

Change Detection

Classification

- Classification Workflow
- Decision Tree
- Endmember Collection
- Post Classification
- Raster Color Slices

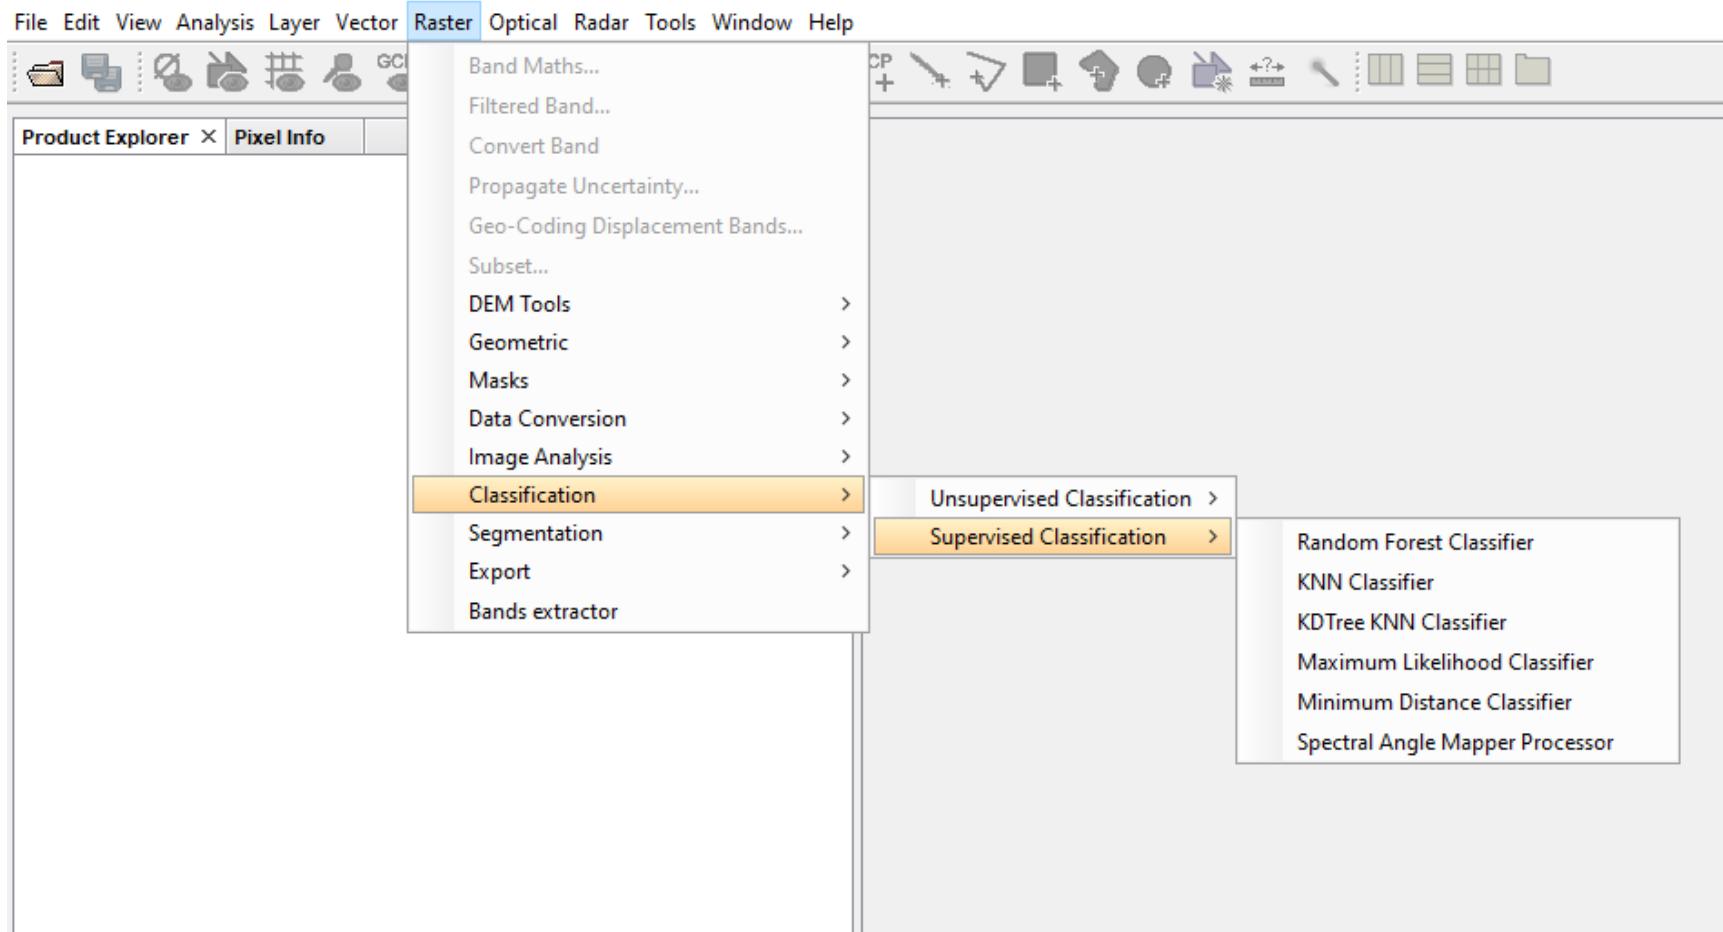
Supervised Classification

- Adaptive Coherence Estimator Classification
- Binary Encoding Classification
- Constrained Energy Minimization Classification
- Mahalanobis Distance Classification
- Maximum Likelihood Classification
- Minimum Distance Classification
- Neural Net Classification
- Orthogonal Subspace Projection Classification
- Parallelepiped Classification
- Spectral Angle Mapper Classification
- Spectral Information Divergence Classification
- Support Vector Machine Classification

Unsupervised Classification

Feature Extraction

Algoritmos de Classificação do SNAP



Classification accuracy assessment

A avaliação baseia-se **na tabela de contingências** que compara, numa amostra de pixels, o resultado da classificação efetuada pelo computador e a verdadeira ocupação do solo obtida por um outro qualquer processo independente (fotografias, imagens, mapas).

Há dois possíveis tipos de erro:

Omissão

Pixels que deveriam ser atribuídos a uma classe e foram erradamente atribuídos a outra classe. Por exemplo um pixel que pertence à classe “água” e não foi atribuído à classe água.

Comissão

Pixels atribuídos a uma classe e que deveriam ser atribuídos a outra classe. Por exemplo um pixel classificado como “água” na realidade pertence a uma das outras três classes (solo nu, floresta ou solo cultivado).

Classification accuracy assessment

Ao longo da diagonal do quadro de contingências está o numero de píxeis correctamente classificados para cada uma das quatro classes (padrões) deste exemplo.

↑
Classificação i

Classes conhecidas → j

	Água	Solo nu	Solo cultivado	Floresta
Água	187	40	7	0
Solo nu	11	246	12	9
Solo cultivado	0	21	239	39
Floresta	0	0	140	49

A linha i-ésima fornece o número dos píxeis que na imagem classificadas são associados à classe i-ésima.

A coluna j-ésima fornece o número de todos os píxeis que no mapa de referência são associados à classe j-ésima.

Classification accuracy assessment

Classes conhecidas → j

	Água	Solo nu	Solo cultivado	Floresta
Água	187	40	7	0
Solo nu	11	246	12	9
Solo cultivado	0	21	239	39
Floresta	0	0	140	49

E_{ii} é o número de píxeis que foram correctamente classificados

E_{ij} é o número de píxeis que é conhecido pertencer à classe j, mas que foram classificados pelo classificador como pertencentes à classe i.

(p.e. 11 píxeis de água foram classificados como solo nu)

Classification accuracy assessment

A percentagem de píxeis correctamente classificados é dada por

$$\sum_{i=1}^N E_{ii} \Bigg/ \sum_{i=1}^N \sum_{j=1}^N E_{ij}$$

		Classes conhecidas → j			
		Água	Solo nu	Solo cultivado	Floresta
↑ Classificação i	Água	187	40	7	0
	Solo nu	11	246	12	9
	Solo cultivado	0	21	239	39
	Floresta	0	0	140	49

Exatidão Global (Overall Accuracy)

No exemplo do quadro de contingências em cima a percentagem de píxeis correctamente classificados é 70.6%.

$$N = 4$$

$$\text{Soma } E_{ii} = 187 + 246 + 239 + 49 = 672$$

$$\text{Soma } E_{ij} = 40 + 7 + 11 + 12 + 9 + 21 + 39 + 140 + 672 = 951$$

$$EG = 672/951 = 0.706$$

User accuracy / Precision

No que diz respeito o utilizador é definida a **exatidão do utilizador** como

$$E_{ii} \Big/ \sum_{j=1}^N E_{ij}$$

Água : 79.9%

Solo Nu : 88.5%;

Solo Cultivado : 79.9%

Floresta: 25.9%

Classes conhecidas → j

	Água	Solo nu	Solo cultivado	Floresta		
↑ Classificação i						
Água	187	40	7	0	79.9	20.1
Solo nu	11	246	12	9	88.5	11.5
Solo cultivado	0	21	239	39	79.9	20.1
Floresta	0	0	140	49	25.9	74.1

↑ Comissão

A exatidão do utilizador de 79.9% para a água diz ao utilizador que 79.9% dos pixels classificados como água são na realidade associados a pontos sobre a superfície terrestre realmente cobertos de água.

Para o utilizador é importante o que está classificado correctamente!

Producer accuracy / Recall /Revocação

No que diz respeito o produtor é definida a **exatidão do produtor** como

$$E_{ii} \Big/ \sum_{i=1}^N E_{ij}$$

Água : 94.4%

Solo Nu : 80.1%;

Solo Cultivado : 60.1%

Floresta: 50.5%

		Classes conhecidas → j			
		Água	Solo nu	Solo cultivado	Floresta
Classificação ↑ i	Água	187	40	7	0
	Solo nu	11	246	12	9
	Solo cultivado	0	21	239	39
	Floresta	0	0	140	49
		94.4	80.1	60.1	50.5
		5.6	19.9	49.9	49.5
		Omissão			

A exatidão do produtor de 50.5% para a floresta diz ao produtor que apenas 50.5% da área de floresta (píxeis identificados como floresta) foi classificada como floresta.

Para o produtor é importante o que está no terreno e foi correctamente classificado!



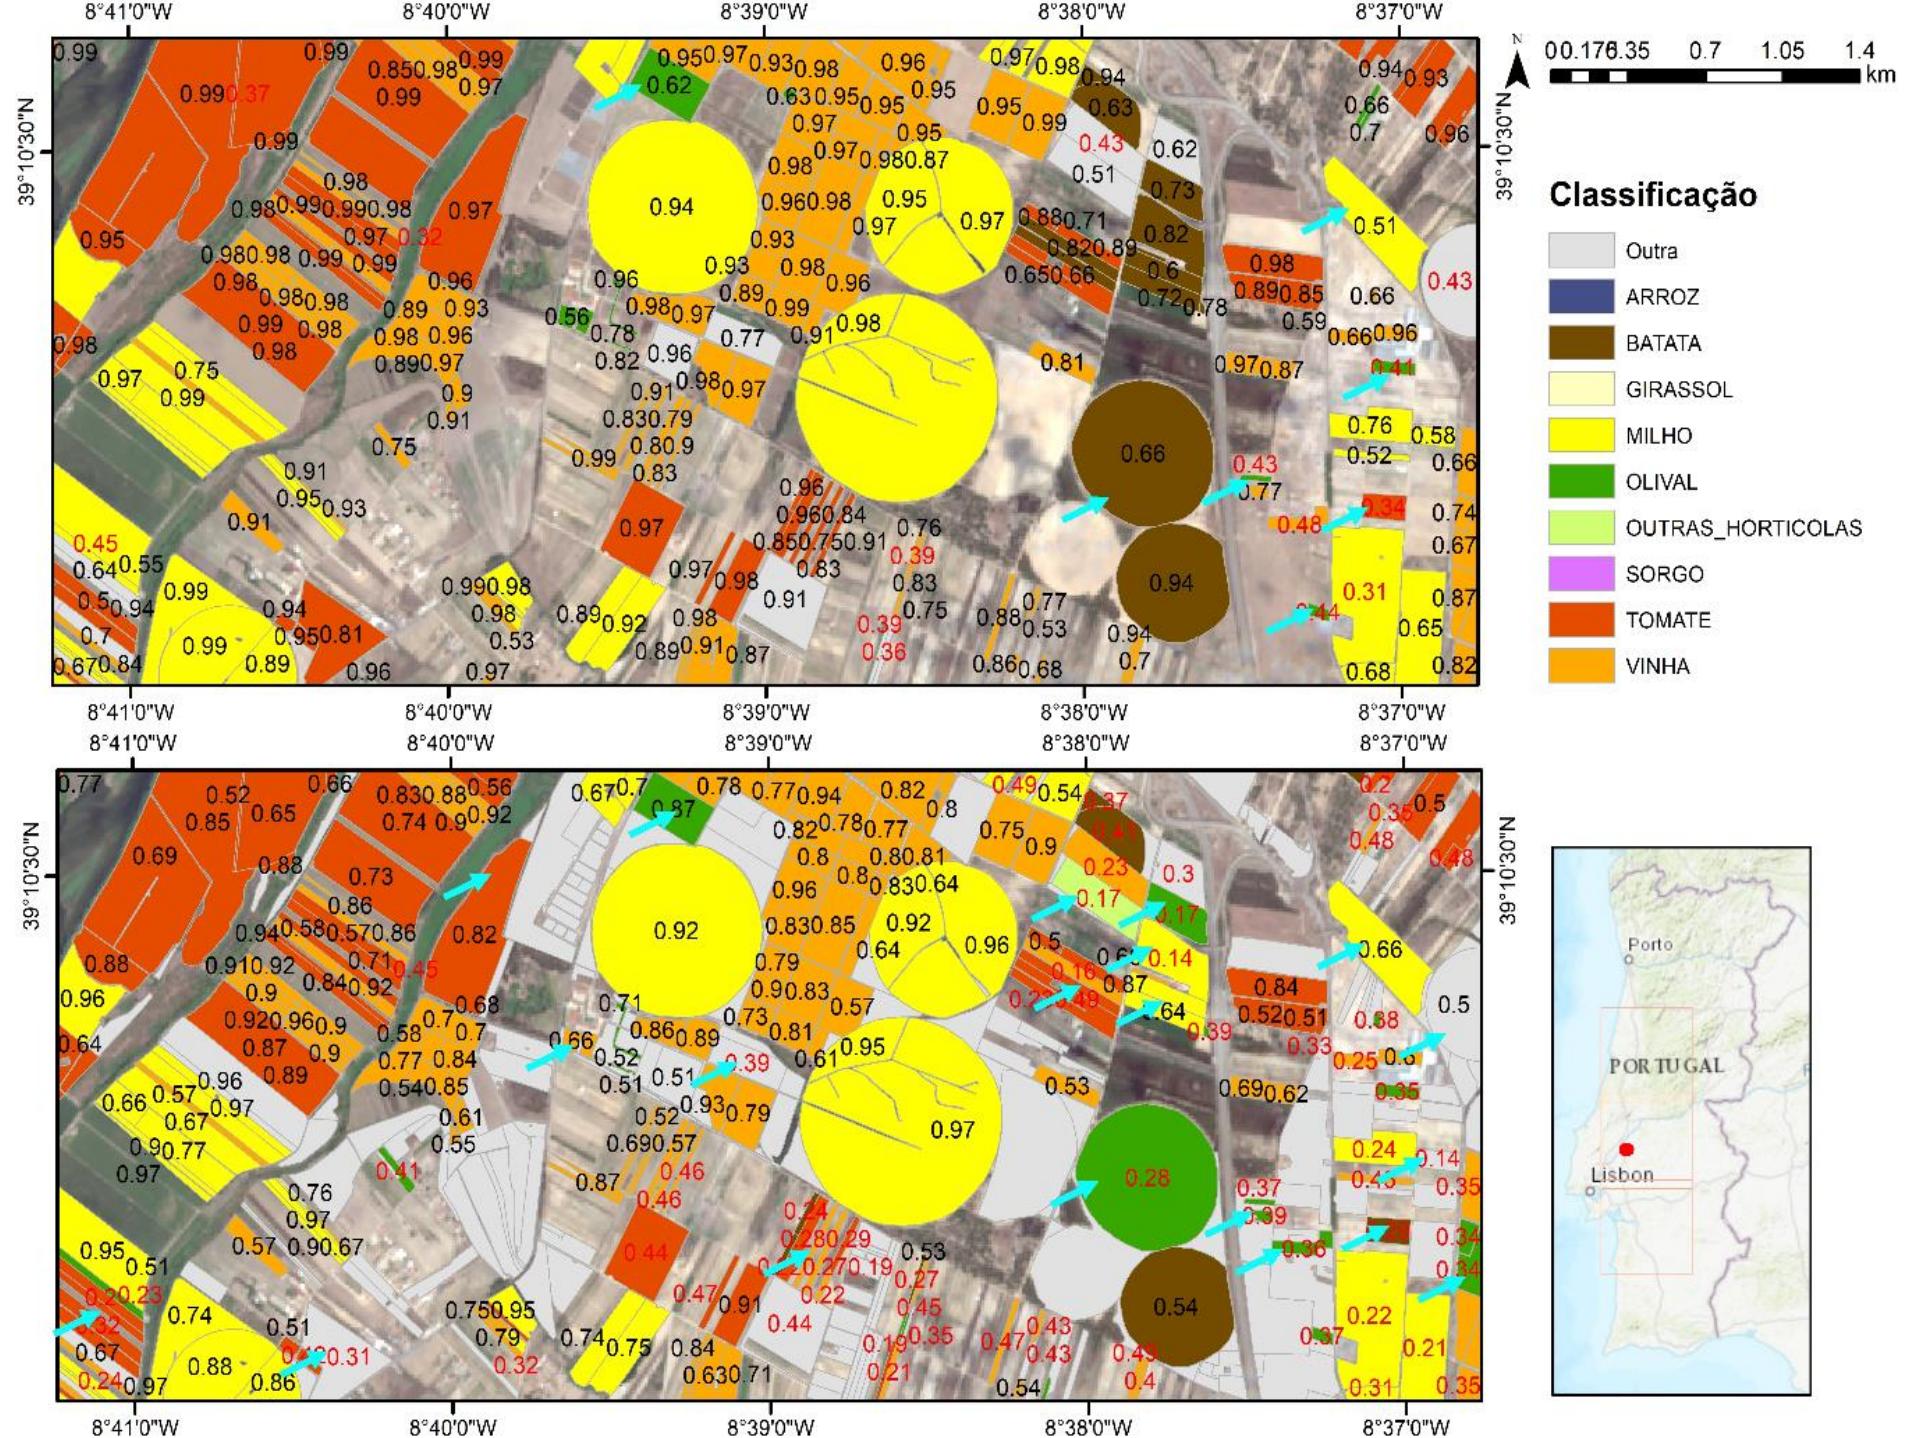
F1-score

O F1-score, com valores entre 0 e 1, corresponde à média ponderada entre precisão (exatidão do utilizador, EU) e revocação (exatidão do produtor, EP), dando igual peso aos dois valores:

$$\text{F1score} = 2 * \frac{EU_i * EP_i}{EU_i + EP_i}$$

O F1-score é obtido para cada classe, sendo calculada a média aritmética simples para obter um valor único (*macro-averaged F1-score*).

Tendo em conta o número de amostras de cada classe, considera-se mais interessante olhar para o F1-score ponderado (*weighted F1-score*).





Matriz Confusão

	ABO	ARRAZ	BAT	COUVE	FEIJAO	GIRASS	GRAO	MELAO	MILHO	OLIV	HORT	PIM	SORG	TO	VINHA	Total	Freq (%)	Revocação (%)	F1-score (%)
ABO	31	0	3	0	1	0	0	2	64	10	2	0	0	2	34	151	0.46	20.53	32.0
ARROZ	0	2929	0	0	0	0	0	0	39	15	0	0	2	0	1	2986	9.07	98.09	99.0
BAT	2	0	217	0	4	0	0	0	123	78	3	1	0	2	50	483	1.47	44.93	56.0
COUVE	0	0	6	34	3	1	0	1	26	6	3	0	0	5	10	95	0.29	35.79	51.0
FEIJAO	0	1	1	0	11	0	0	0	89	10	2	0	1	3	21	139	0.42	7.91	13.0
GIRASS	0	2	1	0	0	236	0	0	9	41	0	0	0	14	13	316	0.96	74.68	83.0
GRAO	0	1	7	0	0	1	29	0	3	48	0	0	0	0	9	98	0.3	29.59	45.0
MELAO	0	0	1	0	0	2	0	40	2	1	1	1	0	18	8	74	0.22	54.05	64.0
MILHO	2	12	17	0	6	1	0	0	5706	294	8	6	0	10	210	6274	19.06	90.95	89.0
OLIV	0	0	1	0	0	1	0	1	83	14235	3	0	1	0	592	14917	45.31	95.43	91.0
HORT	3	0	19	4	4	0	0	2	253	173	19	4	0	9	189	679	2.06	2.8	5.0
PIM	0	1	2	0	0	0	0	0	14	3	1	52	0	5	3	82	0.25	63.41	67.0
SORG	0	3	1	0	0	3	0	0	64	32	0	0	54	1	27	185	0.56	29.19	44.0
TOM	0	1	2	0	0	1	0	0	11	4	0	1	0	585	9	614	1.87	95.28	90.0
VINHA	1	1	1	0	0	0	0	0	85	1407	1	0	0	1	4078	5577	16.94	73.12	75.0
Total	40	2955	294	39	30	250	30	51	6609	16401	43	74	58	679	5290	32920			
Precisão (%)	77.5	99.1	73.8	87.2	36.7	94.4	96.7	78.43	86.34	86.79	44.19	70.3	93.1	86.2	77.09	100	NA	NA	NA

Exatidão da classificação

